

Санкт–Петербургский государственный университет

Корельский Дмитрий Сергеевич

Выпускная квалификационная работа

Разработка рекомендательной системы севооборота

Уровень образования: магистратура

Направление подготовки: Программирование и информационные
технологии

Образовательная программа: Технологии искусственного интеллекта и Big
Data

Научный руководитель:

Митрофанов Евгений Павлович

Рецензент:

Санкт-Петербург

2026 г.

Содержание

Введение	5
Постановка задачи	6
Обзор литературы	8
Глава 1. Архитектура решения	13
1.1. Общая структура системы	13
1.2. Уровень данных и подготовки выборки	14
1.3. Предиктивное ядро	15
1.4. Рекомендательный слой	16
1.5. Слой оценки уверенности	17
1.6. Слой интерпретации рекомендаций	17
1.7. Пространственный демонстрационный слой	18
1.8. Организация решения	19
Глава 2. Данные и подготовка выборки	19
2.1. Источник данных	19
2.2. Предобработка исходных данных	20
2.3. Формирование оконной выборки	20
2.4. Фильтрация редких целевых классов	21
2.5. Разделение на обучающую, валидационную и тестовую вы- борки	22
2.6. Итоговое признаковое представление	24
Глава 3. Базовые модели и выбор предиктивного ядра	25
3.1. Назначение базовых моделей	25
3.2. Простые базовые подходы	25
3.2.1 Подход <code>most_frequent</code>	25
3.2.2 Подход <code>last_crop</code>	26
3.3. Марковская модель первого порядка	26
3.4. CatBoost как основная предиктивная модель	27
3.5. Эксперимент с расширенным набором признаков	27
3.6. Эксперимент с графовым переранжированием	28
3.7. Сравнение подходов и выбор основной модели	29

Глава 4. Рекомендательный слой и оценка качества	30
4.1. Переход от классификации к ранжированному списку кандидатов	30
4.2. Метрики рекомендательной постановки	31
4.3. Сравнение CatBoost и Markov-1 в рекомендательном режиме	32
4.4. Поклассовый анализ качества рекомендаций	33
4.5. Интерпретация результатов	35
Глава 5. Уверенность рекомендаций и калибровка	35
5.1. Роль слоя оценки уверенности в рекомендательной системе	35
5.2. Результаты по группам уверенности	37
5.3. Интерпретация слоя оценки уверенности	38
5.4. Калибровка вероятностей	38
5.5. Место анализа уверенности в общей логике работы	40
Глава 6. Граф знаний и интерпретация рекомендаций	41
6.1. Роль слоя интерпретации в работе	41
6.2. Общая структура графа знаний	42
6.3. Типы связей в графе	43
6.4. Интерпретационные правила	43
6.5. Интерпретация на уровне отдельных кандидатов	45
6.6. Показатель графовой поддержки и его интерпретация	45
6.7. Согласованность между моделью и интерпретационным слоем	46
6.8. Место графа знаний в общей логике работы	47
Глава 7. Анализ отдельных примеров	48
7.1. Роль анализа отдельных примеров в работе	48
7.2. Пример с высокой уверенностью	50
7.3. Пример со средней уверенностью	50
7.4. Пример с низкой уверенностью	51
7.5. Сложный пример с расхождением сигналов	52
7.6. Общая интерпретация рассмотренных примеров	54
Глава 8. Расширение графа знаний с использованием литературных источников	55
8.1. Роль дополнительного литературного слоя	55

8.2. Источники данных для этапа	56
8.3. Используемые внешние агрономические источники	56
8.4. Способ интеграции литературных правил в граф	57
8.5. Результаты на тех же примерах	58
8.6. Интерпретация результатов и ограничения	60
Глава 9. Пространственная демонстрация результатов	60
9.1. Назначение пространственной демонстрации	60
9.2. Выбор локальной области на карте	61
9.3. Анализ полей внутри выбранной области	62
Глава 10. Направления дальнейшего развития	63
Заключение	65
Список литературы	67

Введение

Севооборот относится к числу базовых практик земледелия, поскольку последовательность культур на одном и том же поле влияет на дальнейшее использование участка и на характер принимаемых агрономических решений. Выбор следующей культуры обычно не является случайным: он связан с предшествующей историей поля, особенностями региона и накопленными закономерностями смены культур. Поэтому анализ таких последовательностей представляет интерес как с практической, так и с исследовательской точки зрения.

Развитие цифровых источников данных в сельском хозяйстве делает возможным переход от ручного анализа к более формализованным методам обработки исторической информации по полям. Если ранее решение о следующей культуре в основном принималось на основе опыта специалиста и локальных наблюдений, то наличие накопленных последовательностей культур позволяет использовать методы анализа данных и машинного обучения для поиска устойчивых паттернов и формирования рекомендаций.

Наряду с этим для систем подобного рода важна интерпретируемость результата. В прикладном сценарии пользователю недостаточно знать только рекомендуемую культуру; важно также понимать, насколько уверенно сделана рекомендация и какие факторы поддерживают или ослабляют отдельных кандидатов. Поэтому при разработке подобных систем актуальной становится не только задача прогнозирования, но и задача объяснения полученного результата.

В данной работе рассматривается построение исследовательского прототипа рекомендательной системы для поддержки выбора следующей культуры на конкретном поле.

Работа сочетает методы анализа последовательностей культур, многоклассового прогнозирования, рекомендательных систем и интерпретации результатов. Такой подход позволяет рассматривать задачу выбора следующей культуры не только как задачу предсказания, но и как задачу поддержки принятия решений.

Целью работы является разработка и исследование прототипа объяс-

нимой рекомендательной системы, формирующей ранжированный список культур-кандидатов для следующего года на основе исторических последовательностей культур на поле.

Структура работы соответствует логике построения исследовательского прототипа. В первой главе рассматриваются постановка задачи, её границы и место среди существующих подходов. Далее описываются архитектура решения, используемые данные и этапы их подготовки. Затем представлены методы построения модели, формирования рекомендаций, оценки уверенности и интерпретации результатов. В заключительных разделах приводятся экспериментальная оценка, демонстрация работы системы и анализ ограничений предложенного подхода.

Постановка задачи

В данной работе выбор следующей культуры рассматривается как определение очередного звена в последовательности культур на конкретном поле. Такая задача относится к числу базовых задач, связанных с организацией севооборота, поскольку от нее зависят как параметры ближайшего сельскохозяйственного сезона, так и дальнейшая логика использования поля.

В прикладной постановке выбор следующей культуры определяется не одним фактором, а совокупностью обстоятельств. К ним относятся предшествующая история поля, агрономические ограничения, природно-климатические условия, особенности региона, а также экономические и управленческие соображения. Поэтому полная постановка задачи сближается с задачей планирования и оптимизации севооборота.

В рамках данной работы такая полная постановка не рассматривается. За пределами работы остаются вопросы, требующие одновременного учета свойств почвы, погодных сценариев, ресурсных ограничений, экономических критериев и долгосрочной структуры посевов. Следовательно, работа не направлена на построение полноценного агрономического оптимизатора.

Вместо этого в работе рассматривается более узкая задача: построение прототипа рекомендательной системы выбора следующей культуры на основе исторических последовательностей культур. Предполагается, что такие последовательности содержат наблюдаемые закономерности смены культур и

могут использоваться как эмпирическая основа для формирования рекомендаций.

Входом системы в данной постановке является историческая последовательность культур на поле, рассматриваемая вместе с общим контекстом, необходимым для интерпретации наблюдаемой последовательности. Выходом системы является ранжированный список культур-кандидатов для следующего года. Такой формат результата соответствует логике систем поддержки принятия решений, в которых пользователю требуется не окончательное предписание, а набор правдоподобных вариантов для последующего анализа с учетом внешних ограничений, не представленных непосредственно в модели.

Важной частью рассматриваемой постановки является объяснимость результата. В рамках работы предполагается, что рекомендация должна сопровождаться интерпретируемым контекстом, позволяющим сопоставлять предложенные варианты и учитывать причины, по которым они были включены в список кандидатов. Тем самым система не заменяет агронома, а используется как инструмент поддержки принятия решений, помогающий сузить пространство вариантов и упорядочить их для дальнейшего экспертного анализа.

Выбранная постановка сохраняет самостоятельную исследовательскую и прикладную ценность. Она позволяет проверить, насколько исторические последовательности культур пригодны для прогноза следующего шага, перейти от одновариантного предсказания к рекомендательному ранжированию и дополнить результат механизмом интерпретации, необходимым для его содержательного анализа.

В рамках данной постановки цель конкретизируется как разработка прототипа системы, которая по истории культур на поле формирует ранжированный список вероятных культур-кандидатов для следующего года и сопровождает рекомендации пояснениями.

Более подробная формализация задачи, описание используемых данных, архитектуры решения, методов построения модели и подходов к оценке качества приводятся в последующих главах.

Для достижения поставленной цели в работе решаются следующие за-

дачи:

- изучить существующие подходы к прогнозированию и рекомендации культур;
- подготовить данные о последовательностях культур;
- разработать модель прогнозирования следующей культуры;
- преобразовать модельный прогноз в ранжированный список кандидатов;
- разработать механизм интерпретации сформированных рекомендаций;
- оценить качество модели и сформированных рекомендаций.

Таким образом, рассматриваемая задача объединяет предсказательную составляющую, рекомендательное ранжирование и интерпретацию результата, что определяет общий замысел дальнейшей разработки системы.

Обзор литературы

Севооборот в агрономической практике рассматривается как планируемая последовательность культур, выращиваемых на одном и том же участке в течение некоторого периода времени. Такая последовательность задаёт не только порядок смены культур, но и способ управления состоянием поля: почвенным плодородием, органическим веществом, водным режимом, давлением вредителей, болезней и сорняков. В стандарте USDA NRCS севооборот определяется как планируемая последовательность культур на одном участке во времени, а среди целей такой практики выделяются снижение эрозии, поддержание здоровья почвы, управление питательными веществами, повышение эффективности использования влаги и снижение давления вредителей [22]. Поэтому выбор следующей культуры можно рассматривать не только как агрономическую задачу, но и как задачу поддержки принятия решений, в которой необходимо учитывать историю поля, региональный контекст, ограничения и неопределённость результата.

В исследованиях и прикладных системах встречаются разные постановки этой задачи. Наиболее широкая из них связана с построением полного плана севооборота на несколько лет вперёд. Например, система *Fruchtfolge* формирует рекомендации по выбору культур и внесению органических удобрений

для отдельных полей на основе оптимизационной модели хозяйства, учитывающей характеристики полей, расстояния, трудовые ресурсы и регуляторные ограничения [15]. Другие работы рассматривают севооборот как задачу последовательного планирования: используются матрицы пригодности последующих культур, значения предшественников, потребность культур в азоте, экономические характеристики и набор агрономических правил [6]. В более поздних исследованиях также изучаются объяснимые и устойчивые варианты обучения с подкреплением, где случайные возмущения награды имитируют внешние факторы, например погодные условия или изменения рыночных цен [8]. Многоцелевая постановка планирования севооборота также рассматривается в моделях смешанно-целочисленного линейного программирования, где одновременно учитываются доход, использование земли и разнообразие культур [17]. Эти работы показывают, что полноценное планирование севооборота требует богатого набора входных данных и формального описания ограничений, тогда как в данной работе рассматривается более узкая задача рекомендации следующей культуры.

Отдельное направление связано не с построением полного плана, а с оценкой переходов между культурами. В таких работах анализируется, насколько предшествующая культура благоприятна для последующей, а результат может быть представлен в виде матрицы переходов или матрицы значений предшественников. Например, подход AI4CROPR использует данные дистанционного зондирования, показатели NDVI, погодные, почвенные и управленческие признаки для оценки значений предшественников и построения матриц севооборота [7]. Такая постановка близка к графовому представлению севооборота, поскольку фактически описывает связи между культурами и их возможную силу.

Наиболее близкая к данной дипломной работе линия исследований рассматривает выбор культуры как задачу прогноза следующего состояния поля по его исторической последовательности. В такой постановке входом модели является история культур за несколько предыдущих лет, отражающая устойчивые паттерны использования поля. В работе Osman et al. предложена модель на основе Markov Logic Networks для раннего картирования культур: авторы используют последовательность культур за предыдущие 3–5 лет и

показывают, что такая информация позволяет предсказывать культуру поля до начала сезона, а также совмещать обучение по историческим данным с экспертными правилами [14]. Эта работа важна для данной постановки, поскольку подтверждает саму возможность использования истории культур как самостоятельного источника предиктивной информации.

Похожая логика используется в исследованиях на основе данных USDA NASS Cropland Data Layer. Cropland Data Layer представляет собой ежегодный слой сельскохозяйственного землепользования, который позволяет получать последовательности культур во времени и анализировать повторяющиеся схемы использования сельскохозяйственных территорий [3]. На базе таких данных строятся модели предсезонного прогнозирования культур. Например, Yaramasu et al. применяют глубокие нейронные сети к историческим данным CDL и показывают, что модель способна учитывать пространственно-временные закономерности и предсказывать тип культуры до начала сезона [24]. Близкое направление представлено работами USDA NASS по Crop Sequence Boundaries: этот набор данных формирует оценки границ полей, площадей культур и севооборотов на территории США, что делает его релевантным для задач, где объектом анализа является поле или участок с историей выращивания культур [21]. Сравнение высокопорядковых марковских цепей и глубоких нейронных сетей на данных о культурных последовательностях также показывает, что более сложные модели могут использовать длинные временные ряды и превосходить простые вероятностные подходы [18].

Существует и другой класс рекомендательных систем, в которых культура выбирается не по истории поля, а по текущим почвенным, погодным или сенсорным данным. Например, AgroXAI строит рекомендации культур на основе погодных и почвенных условий региона и дополняет результат локальными и глобальными объяснениями с использованием методов объяснимого искусственного интеллекта [20]. В мультимодальных системах, таких как AgroSense, могут объединяться изображения почвы и структурированные признаки, включая содержание питательных элементов, кислотность и количество осадков [16]. Также встречаются системы, где рекомендация культуры совмещается с прогнозом урожайности, погодных факторов и рисков заболеваний [2]. Эти работы близки по общей идее аграрных рекомендаций, однако

они отвечают преимущественно на вопрос о пригодности культуры для заданных условий, тогда как в данной работе рассматривается выбор следующей культуры после конкретной истории поля.

Для интерпретации результатов в сельскохозяйственных системах поддержки решений всё чаще используются графы знаний и онтологические модели. Например, онтология СЗРО предназначена для описания процессов планирования и производства в растениеводстве и связывает культуры, участки, технологические операции, стадии развития растений и другие элементы предметной области [5]. Более крупные геопространственные графы знаний, такие как KnowWhereGraph, показывают возможность объединения климатических, почвенных, пространственных и сельскохозяйственных данных в единой семантической структуре [19]. Для пользовательского представления результатов важны также визуализации: обзоры сельскохозяйственных систем поддержки решений показывают, что карты, панели мониторинга и визуализация неопределённости являются важными средствами анализа и интерпретации результата [9]. В данной работе эти идеи используются в компактном виде: граф знаний служит не самостоятельной моделью выбора культуры, а слоем интерпретации уже сформированного списка кандидатов, а пространственная демонстрация показывает результаты на уровне отдельных полей.

Отдельную роль в работе играют внешние агрономические источники, использованные не для обучения предиктивной модели, а для расширения интерпретационного слоя графа знаний. Для литературного слоя используются источники, согласованные с географией исходного датасета USDA NASS CSB/CDL. Стандарт USDA NRCS Conservation Crop Rotation задаёт общие правила разнообразия севооборота, ограничения повторов культур, учёта роли бобовых культур и ограничения повторного использования пара [22]. Исследование Kluger et al. используется для поддержки переходов между corn и soybeans в американском контексте [13], а материалы Oklahoma State University Extension — для осторожного предупреждающего сигнала при переходе corn → wheat, связанном с риском фузариоза колоса (Fusarium Head Blight) [10].

Дополнительно современные исследования по оценке эффектов пред-

шественников подчёркивают, что такие эффекты зависят от последовательности культур, погоды и региона [12]. Поэтому литературные правила в данной работе рассматриваются как интерпретационные сигналы, а не как универсальные агрономические предписания.

Помимо научных работ, существуют коммерческие цифровые платформы управления хозяйством. John Deere Operations Center, Climate FieldView, harvio FIELD MANAGER и Agworld ориентированы на широкий круг задач: хранение и анализ данных о полях, планирование операций, построение карт, формирование предписаний, мониторинг сезона и совместную работу участников производственного процесса [11, 4, 23, 1]. По сравнению с такими платформами данная работа не является готовым коммерческим продуктом и не стремится заменить систему управления хозяйством. Её вклад состоит в более узком исследовательском модуле: по истории поля и базовым признакам формируется ранжированный список культур-кандидатов, сопровождаемый оценкой уверенности и интерпретационным контекстом.

Таким образом, рассмотренные источники позволяют выделить место данной работы среди существующих подходов. Полные оптимизационные системы и методы обучения с подкреплением решают задачу многолетнего планирования севооборота и требуют более богатого набора данных. Рекомендательные системы по почве и погоде оценивают пригодность культур для заданных условий, но обычно не фокусируются на истории поля. Коммерческие платформы шире по функциональности, но не раскрывают отдельно воспроизводимый исследовательский контур рекомендации следующей культуры. В данной работе рассматривается самостоятельная постановка: прогноз следующей культуры по исторической последовательности поля преобразуется в рекомендательный список, после чего результат дополняется оценкой уверенности, графовой интерпретацией и пространственным представлением.

Глава 1. Архитектура решения

1.1 Общая структура системы

Разрабатываемая в работе система построена как последовательный исследовательский конвейер, в котором каждый этап решает отдельную подзадачу и передаёт результат следующему этапу через устойчивые артефакты. Такой подход позволяет отделить подготовку данных от обучения моделей, оценку качества — от интерпретации, а предиктивное ядро — от демонстрационного пользовательского слоя. В результате архитектура решения имеет модульный характер: система не сводится к одной модели, а состоит из нескольких взаимосвязанных уровней, каждый из которых выполняет собственную функцию.




Рис. 1: Общая архитектура предложенной рекомендательной системы

На рисунке 1 показана общая последовательность этапов: от исходных данных USDA NASS CSB/CDL и подготовки оконной выборки до формирования рекомендаций, оценки уверенности, интерпретации результатов и

пространственной демонстрации.

Архитектура построена вокруг последовательной передачи артефактов между этапами. После подготовки данных формируется оконная выборка, используемая для обучения модели. Результатом работы предиктивного ядра является распределение вероятностей по классам культур. На его основе формируется ранжированный список кандидатов, который затем дополняется оценкой уверенности и интерпретационными признаками. Завершающий слой использует эти артефакты для визуального представления результата.

Содержательно архитектура решения включает следующие уровни:

- уровень данных;
- уровень подготовки и представления выборки;
- уровень предиктивной модели;
- уровень рекомендаций;
- уровень уверенности;
- уровень интерпретации рекомендаций;
- уровень пространственной демонстрации.

Каждый из этих уровней будет кратко рассмотрен далее.

1.2 Уровень данных и подготовки выборки

Нижний уровень архитектуры образуют исходные данные USDA NASS CSB/CDL и процедуры их подготовки. На этом уровне решаются задачи чтения исходного массива, сопоставления кодов культур, фильтрации нерелевантных классов и формирования рабочего представления данных. Именно здесь закладывается основа всей последующей системы, поскольку от способа подготовки данных зависит и качество модели, и интерпретируемость результата.

После базовой очистки данные преобразуются из годовых последовательностей в оконную выборку. Каждое наблюдение представляется как переход от истории культур за несколько предыдущих лет к целевой культуре следующего года. В рассматриваемой работе это представление имеет вид

$$(c_{t-3}, c_{t-2}, c_{t-1}) \rightarrow c_t$$

где c_{t-3} , c_{t-2} и c_{t-1} обозначают культуры на поле в три предыдущих года, а c_t — целевую культуру следующего года.

Такое преобразование позволяет перейти от исходной таблицы по годам к задаче предсказания следующего шага в последовательности культур. На этом же уровне выполняется фильтрация редких целевых классов и фиксируется итоговое пространство культур, с которым далее работают все последующие компоненты системы.

Таким образом, уровень подготовки данных выполняет две основные функции. Во-первых, он делает данные пригодными для машинного обучения. Во-вторых, он задаёт единый и воспроизводимый входной контракт для всех последующих этапов. Это особенно важно, поскольку в работе сравниваются разные подходы, и такое сравнение возможно только при использовании общей, заранее зафиксированной выборки.

1.3 Предиктивное ядро

Центральным элементом архитектуры является предиктивное ядро, задача которого — по истории культур и дополнительным признакам поля оценить вероятности следующих культур. В качестве основной предиктивной модели в работе используется CatBoost. Выбор именно этой модели связан с тем, что задача имеет табличную природу и включает как категориальные, так и числовые признаки. В рамках архитектуры CatBoost рассматривается как предиктивное ядро системы, формирующее распределение вероятностей по классам культур.

На вход предиктивного ядра поступает подготовленное табличное представление наблюдения, включающее историю культур и дополнительные признаки поля.

На выходе модель возвращает вектор вероятностей по целевым классам. Этот результат сам по себе уже позволяет решать задачу классификации с выбором наиболее вероятного класса, однако в данной работе он используется шире: как основа для последующего рекомендательного и интерпретационного анализа.

Важно подчеркнуть, что предиктивное ядро в архитектуре отделено

от остальных слоёв. Это означает, что оценка уверенности, интерпретация рекомендаций и пространственная визуализация не заменяют модель и не подменяют её ранжирование, а работают поверх уже рассчитанного модельного результата. Такая декомпозиция делает архитектуру более прозрачной и позволяет отдельно анализировать роль каждого уровня.

1.4 Рекомендательный слой

Следующий уровень архитектуры связан с переходом от обычной классификации к рекомендательной постановке. Если предиктивная модель возвращает вероятности по всем классам, то рекомендательный слой преобразует этот результат в ранжированный список кандидатов. На практике это означает, что вместо единственного наиболее вероятного класса система формирует список из k наиболее вероятных культур.

В прикладной логике этот переход является принципиальным. Для поддержки принятия решений важен не только наиболее вероятный вариант, но и несколько альтернатив, которые могут быть дополнительно оценены пользователем. Поэтому рекомендательный слой выполняет не просто техническую сортировку вероятностей, а переводит модельный выход в формат, удобный для дальнейшего использования.

На данном уровне результат может быть описан как переход от распределения вероятностей по классам к упорядоченному списку кандидатов:

$$P(y \mid x) = (p_1, p_2, \dots, p_m) \rightarrow R_k(x) = (c_{(1)}, c_{(2)}, \dots, c_{(k)})$$

где $c_{(1)}, c_{(2)}, \dots, c_{(k)}$ — культуры, соответствующие наибольшему модельным вероятностям $p_{(1)} \geq p_{(2)} \geq \dots \geq p_{(k)}$, а k задаёт размер рекомендательного списка.

В дальнейшем именно этот список кандидатов становится основным объектом анализа: он используется при оценке качества рекомендательной постановки и при формировании интерпретационного контекста.

1.5 Слой оценки уверенности

После формирования списка кандидатов к архитектуре добавляется слой оценки уверенности. Его задача состоит в том, чтобы различать случаи, где рекомендации модели выглядят более устойчивыми, и случаи, где результат следует интерпретировать осторожнее. Таким образом, слой оценки уверенности дополняет сам список кандидатов информацией о степени надёжности модельного вывода.

С архитектурной точки зрения этот слой использует уже рассчитанные вероятности модели и преобразует их в более прикладной формат. На выходе пользователь получает не только список кандидатов, но и сигнал о том, относится ли случай к более уверенным или менее уверенным рекомендациям. Это важно потому, что одинаковый по форме список из k кандидатов может иметь разную степень практической надёжности.

Одним из базовых сигналов уверенности является максимальная вероятность среди классов:

$$\hat{p}_{\max}(x) = \max_c P(y = c \mid x)$$

В данной работе она рассматривается не как абсолютная гарантия корректности рекомендации, а как дополнительный индикатор устойчивости результата.

Введение слоя оценки уверенности делает систему ближе к реальному сценарию поддержки принятия решений. Пользователь видит не только, какие культуры предложены моделью, но и насколько устойчивым выглядит данный прогноз. В архитектуре это означает, что предиктивное ядро и рекомендательный слой дополняются ещё одним уровнем, отвечающим за представление неопределённости результата.

1.6 Слой интерпретации рекомендаций

Слой интерпретации рекомендаций используется для пояснения кандидатов, сформированных рекомендательным слоем. Он построен на основе графа знаний, в котором представлены культуры, укрупнённые группы культур, регионы, переходные закономерности и интерпретационные признаки.

На вход данного слоя поступает ранжированный список культур-кандидатов. Для каждого кандидата графовый слой формирует дополнительный контекст: типичность перехода, принадлежность к группе культур, наличие поддерживающих сигналов или предупреждений. Благодаря этому результат работы системы представляется не только как список вероятных культур, но и как набор пояснений, помогающих интерпретировать рекомендацию.

С архитектурной точки зрения слой интерпретации выполняет следующие функции:

- связывает культуры-кандидаты с укрупнёнными группами культур и региональным контекстом;
- добавляет сигналы поддержки или предупреждения для отдельных переходов;
- формирует пояснения, которые могут быть использованы при анализе рекомендаций.

Графовый слой не является самостоятельным оптимизатором севооборота. В предложенной архитектуре он выполняет интерпретационную функцию и используется поверх результатов предиктивной модели.

1.7 Пространственный демонстрационный слой

Верхний уровень архитектуры представляет собой пространственный демонстрационный слой. Его назначение состоит в том, чтобы связать результаты рекомендательной системы с конкретными полями и представить их в форме, удобной для анализа. В отличие от табличного вывода, карта позволяет рассматривать рекомендации в пространственном контексте: видеть расположение полей, выбирать интересующую область и переходить к анализу отдельных участков.

Пространственный слой использует геометрию полей или их пространственные представления, а также результаты, полученные на предыдущих этапах архитектуры. Для выбранного поля могут отображаться список рекомендованных культур, оценка уверенности и интерпретационный контекст.

Таким образом, пространственный слой показывает возможный сценарий использования системы: выбор области на карте, просмотр полей и анализ рекомендаций для конкретного участка.

1.8 Организация решения

Практическая реализация архитектуры организована как последовательность воспроизводимых этапов, представленных в виде Jupyter Notebook. Промежуточные результаты сохраняются в виде артефактов, что позволяет отделить подготовку данных, обучение модели, оценку качества, интерпретацию и пространственную демонстрацию, а также повторно использовать результаты отдельных этапов без полного пересчёта конвейера.

Глава 2. Данные и подготовка выборки

2.1 Источник данных

В работе используются данные **USDA NASS CSB/CDL** за 2017–2024 годы. CDL предоставляет годовые классы культур, а CSB-слой используется как источник полевых идентификаторов, площади и пространственного контекста. Такой набор данных позволяет перейти от анализа отдельных наблюдений к анализу историй использования конкретных полей.

Выбор данных USDA NASS CSB/CDL обусловлен их открытостью, масштабом и воспроизводимостью. Данный набор предоставляет последовательные сведения о культурах на уровне полей за несколько лет и тем самым позволяет проверить методологию построения рекомендательной системы на устойчивой экспериментальной базе. Для российской территории открытый стандартизованный аналог уровня «поле — год — культура» отсутствует в публичном доступе. Поэтому данные USDA NASS CSB/CDL рассматриваются как экспериментальная основа для разработки и проверки подхода. Перенос предложенной методологии на российский контекст требует локальных данных, адаптации агрономических правил и дополнительной экспертной валидации.

На уровне исходной записи данные содержат:

- идентификатор поля;
- площадь поля;
- региональные признаки;
- пространственные координаты;
- годовые значения культурных классов за несколько последовательных лет.

2.2 Предобработка исходных данных

На первом этапе исходные данные были приведены к виду, пригодному для последующего моделирования. Основная задача предобработки состояла в том, чтобы перейти от исходных CDL-кодов к более интерпретируемому представлению культур и удалить классы, не соответствующие целевой постановке исследования. Для каждого года выполнялось сопоставление кодов с названиями культур и их укрупненными группами. После этого из выборки исключались нерелевантные для задачи классы, например неаграрные или неопределённые категории. Итогом этого этапа стал очищенный датасет, сохранённый как промежуточный артефакт воспроизводимого конвейера.

По метаданным артефакта после базовой очистки выборка имеет следующие характеристики:

- 8 110 870 строк;
- 33 столбца;
- 8 годовых CDL-столбцов, соответствующих годам 2017–2024.

Предобработка на этом этапе была необходима не только для очистки исходного массива, но и для формирования единообразного представления культур, пригодного для дальнейшего анализа временных последовательностей.

2.3 Формирование оконной выборки

После очистки исходная таблица была преобразована в оконный датасет, который используется для обучения модели. Вместо того чтобы работать

с отдельной строкой как с изолированным наблюдением, каждая запись была преобразована в окно вида

$$(c_{t-3}, c_{t-2}, c_{t-1}) \rightarrow c_t$$

где c_{t-3} , c_{t-2} и c_{t-1} соответствуют столбцам history_1, history_2, history_3, а c_t — целевой культуре target.

Пример нескольких строк такого представления приведён в таблице 1. В ней видно, что одна строка соответствует одному полю и одному прогнозируемому году: технический идентификатор и пространственно-региональные признаки сохраняют контекст поля, три предыдущих значения культуры используются как входная история, а значение в столбце target является следующей культурой, которую должна предсказать модель.

Таблица 1: Пример формирования оконной выборки

CSBID	history_1	history_2	history_3	target	target_year
3517240000000036	wheat	wheat	sorghum	sorghum	2020
3517240000000037	wheat	wheat	sorghum	sorghum	2020
3517240000000044	forage_hay	forage_hay	other_cereals	fallow	2020

Поскольку в исходных данных доступны годы с 2017 по 2024, из одной исходной записи можно сформировать несколько перекрывающихся окон. В результате полный оконный датасет содержит 40 554 350 строк.

Преимущество такой схемы состоит в том, что она позволяет использовать историю поля как явный вход модели. Тем самым задача переходит от статического анализа признаков к анализу краткой временной последовательности культур.

2.4 Фильтрация редких целевых классов

После построения оконного датасета был выполнен анализ распределения целевой переменной и фильтрация редких целевых классов. Порог редкости был выбран на уровне 1% от общего числа наблюдений. Такой порог позволяет сохранить основные массовые классы и одновременно исклю-

чить категории, для которых число наблюдений недостаточно для устойчивой оценки качества.

После фильтрации:

- в выборке осталось 38 511 210 строк;
- итоговое пространство целевых классов было сокращено до 9 культурных классов.

Итоговый набор целевых классов имеет вид:

Таблица 2: Итоговые и исключённые целевые классы

Оставшиеся целевые классы	Исключённые редкие классы
corn	oilseeds_other
cotton	sugar_crops
fallow	peanuts
forage_hay	rice
legumes	root_tubers
other_cereals	sunflower
sorghum	specialty_crops
soybeans	vegetables_melons
wheat	fruits_berries

Агрегация и последующая фильтрация целевых классов являются важной частью постановки. С одной стороны, они уменьшают разреженность и дисбаланс данных. С другой стороны, они ограничивают область применимости системы: модель работает не с полным пространством исходных культур, а с устойчивым и интерпретируемым набором укрупнённых целевых классов.

2.5 Разделение на обучающую, валидационную и тестовую выборки

После формирования итоговой выборки было выполнено единое разделение на обучающую, валидационную и тестовую выборки. Это разделение фиксируется один раз и затем переиспользуется во всех основных этапах работы. Такой подход необходим для воспроизводимости результатов: все

модели и все сравнительные эксперименты должны оцениваться на одном и том же разбиении.

Принципиально важно, что разбиение выполняется с учётом группировки по CSBID: окна, построенные для одного и того же поля, не должны одновременно попадать в разные части выборки. Такой контракт предотвращает утечку информации между разными частями выборки и делает оценку качества более корректной.

Фактические размеры выборок зафиксированы в таблице 3.

Таблица 3: Размеры выборок на этапах подготовки данных

Этап	Размер, строк	Источник	Комментарий
Очищенный набор данных	8 110 870	01_meta.json	Таблица после первичной подготовки и очистки данных
Оконная выборка	40 554 350	02_meta.json	Выборка формата «история культур → целевая культура»
Выборка после фильтрации	38 511 210	02_meta.json	Оконная выборка после исключения редких целевых классов
Обучающая выборка	26 957 630	run_meta.json	Часть фиксированного разбиения с учётом группировки по CSBID
Валидационная выборка	5 776 566	run_meta.json	Часть фиксированного разбиения для подбора и промежуточной оценки
Тестовая выборка	5 777 014	run_meta.json	Часть фиксированного разбиения для итоговой оценки

Таким образом, на данном этапе формируется единая воспроизводимая база для всех последующих экспериментов: обучения базовых и основных моделей, оценки рекомендаций, анализа уверенности и интерпретации результатов.

2.6 Итоговое признаковое представление

На основе подготовленной оконной выборки было сформировано итоговое признаковое представление, используемое на последующих этапах моделирования. Оно сочетает историю культур, региональный контекст и базовые пространственные характеристики поля.

Состав признаков и их типы приведены в таблице 4.

Таблица 4: Итоговое признаковое представление

Признак	Тип	Краткий смысл
history_1	Категориальный	Культура на поле в году $t - 3$
history_2	Категориальный	Культура на поле в году $t - 2$
history_3	Категориальный	Культура на поле в году $t - 1$, ближайшем к целевому году
STATEFIPS	Категориальный	Код штата, задающий региональный контекст наблюдения
CNTYFIPS	Категориальный	Код округа, задающий более локальный региональный контекст
CSBACRES	Числовой	Площадь поля по данным CSB
INSIDE_X	Числовой	Пространственная координата поля по оси X
INSIDE_Y	Числовой	Пространственная координата поля по оси Y

В результате подготовки данных была сформирована единая оконная выборка, связывающая историю культур на поле, пространственно-региональный контекст и целевую культуру следующего года. Полученное признаковое представление далее используется для обучения предиктивных моделей, формирования рекомендательного списка и анализа интерпретируемости результатов.

Глава 3. Базовые модели и выбор предиктивного ядра

3.1 Назначение базовых моделей

Построение рекомендательной системы по истории культур требует сравнения основной модели с более простыми ориентирами. Такое сравнение позволяет проверить, действительно ли качество достигается за счёт использования более содержательной модели, а не только за счёт частотных закономерностей или инерционных эффектов последовательности. В данной работе базовые модели задают нижнюю границу качества, помогают оценить вклад истории поля и контекстных признаков, а также обосновывают выбор основной модели на основе сравнительного анализа.

По этой причине в работе рассматриваются:

- простые базовые подходы;
- вероятностный базовый подход Markov-1;
- базовая конфигурация CatBoost;
- дополнительные исследовательские эксперименты.

Такой набор делает выбор итоговой модели методически прозрачным и воспроизводимым.

3.2 Простые базовые подходы

В качестве простых ориентиров используются два базовых подхода: `most_frequent` и `last_crop`.

3.2.1 Подход `most_frequent`

Модель `most_frequent` всегда предсказывает наиболее частый класс в обучающей выборке. Этот подход не использует ни историю конкретного поля, ни региональный контекст, ни пространственные признаки. Его практическая ценность невелика, однако он важен как минимальный ориентир: если более сложная модель не превосходит такой базовый подход, то её использование трудно считать обоснованным.

3.2.2 Подход `last_crop`

Модель `last_crop` в качестве следующей культуры выбирает последнюю наблюдаемую культуру в истории поля. В отличие от `most_frequent`, этот подход уже учитывает локальную информацию о поле, но делает это в крайне упрощённой форме. Он отражает инерционный сценарий, в котором предполагается, что следующая культура совпадает с ближайшим предыдущим состоянием.

Сравнение с этим подходом особенно важно для рассматриваемой задачи, поскольку в последовательностях культур действительно могут встречаться повторы, а значит, правило последней культуры способно давать нетривиальный результат.

3.3 Марковская модель первого порядка

Следующий базовый подход строится на одношаговой вероятностной модели переходов между культурами. В этой постановке вероятность следующей культуры зависит только от последней культуры в истории:

$$P(c_t \mid c_{t-1})$$

где c_{t-1} обозначает последнюю наблюдаемую культуру в истории поля, а c_t — целевую культуру следующего года.

Такой подход уже не является чисто эвристическим: он использует статистику переходов, наблюдаемую в обучающей выборке. При этом он по-прежнему остаётся ограниченным, поскольку игнорирует более длинную историю поля, а также дополнительные признаки региона и участка.

Markov-1 играет важную роль в работе. С одной стороны, это сильнее, чем наивные базовые стратегии. С другой стороны, он остаётся достаточно простым и интерпретируемым, чтобы служить честным ориентиром для сравнения с CatBoost. В дальнейшем именно Markov-1 используется как основной вероятностный ориентир в рекомендательной постановке.

3.4 CatBoost как основная предиктивная модель

В качестве основной предиктивной модели в работе рассматривается CatBoost. Эта модель выбрана с учётом табличной структуры данных и наличия категориальных признаков. История культур, региональные коды и пространственный контекст естественным образом включаются в её признаковое описание. В рамках архитектуры CatBoost формирует распределение вероятностей по классам культур, которое далее используется для построения ранжированного списка кандидатов.

Базовая конфигурация CatBoost использует компактный набор признаков:

- history_1, history_2, history_3;
- STATEFIPS, CNTYFIPS;
- CSBACRES;
- INSIDE_X, INSIDE_Y.

Такой набор отражает основную гипотезу работы: следующая культура определяется не только последней наблюдаемой культурой, но и более длинной историей, а также региональным и пространственным контекстом. При этом базовая конфигурация CatBoost остаётся достаточно компактной, чтобы быть воспроизводимой и удобной для последующего анализа.

Данная модель далее сопоставляется с простыми и вероятностными базовыми подходами и рассматривается как кандидат на роль предиктивного ядра системы.

3.5 Эксперимент с расширенным набором признаков

После построения базовой конфигурации CatBoost был проведён отдельный эксперимент с расширением признакового пространства. Цель этого этапа состояла в том, чтобы проверить, может ли модель выиграть от признаков, описывающих структуру истории культур более явно, чем исходные три года истории.

В эксперименте использовались дополнительные производные признаки, в том числе:

- число уникальных культур в истории;
- наличие fallow в истории;
- наличие legumes в истории;
- признаки повторяемости соседних лет;
- индикатор полного повтора истории.

Содержательно этот эксперимент проверял гипотезу о том, что явное кодирование некоторых паттернов истории может дополнительно усилить модель. Численные результаты этой экспериментальной конфигурации включены в сводную таблицу промежуточных экспериментов.

Расширение признакового пространства не привело к устойчивому улучшению качества, достаточному для усложнения основной модели. Поэтому данная конфигурация рассматривается как исследовательская, а в качестве основной модели сохранена более компактная и воспроизводимая конфигурация CatBoost.

3.6 Эксперимент с графовым переранжированием

Следующий промежуточный эксперимент был связан с попыткой усилить ранжирование CatBoost за счёт графового сигнала переходов между культурами. Идея состояла в том, чтобы объединить модельные вероятности и вероятности, полученные из графа переходов, по формуле

$$\text{score}(c) = \alpha \cdot p_{\text{CatBoost}}(c \mid x) + \beta \cdot p_{\text{graph}}(c \mid c_{t-1})$$

где $p_{\text{CatBoost}}(c \mid x)$ — вероятность кандидата c , рассчитанная моделью CatBoost, а $p_{\text{graph}}(c \mid c_{t-1})$ — графовый сигнал перехода от последней культуры в истории к кандидату.

В эксперименте проверялись несколько сочетаний весов: $(0.9, 0.1)$, $(0.8, 0.2)$ и $(0.7, 0.3)$. Лучшим вариантом оказалось соотношение $\alpha = 0.9$, $\beta = 0.1$.

Такой результат можно объяснить тем, что графовый сигнал основан на агрегированной статистике переходов и не учитывает весь набор признаков конкретного наблюдения. При прямом смешивании с вероятностями CatBoost

он может сглаживать индивидуальные различия между полями и ухудшать ранжирование. Поэтому данный эксперимент не отвергает полезность графового представления, а уточняет его роль: в финальной архитектуре графовый компонент используется для интерпретации уже сформированного списка кандидатов, тогда как CatBoost сохраняет функцию предиктивного ядра системы.

Сводные метрики эксперимента с расширенным набором признаков и эксперимента с графовым переранжированием приведены в таблице 5.

Таблица 5: Сравнение промежуточных экспериментальных конфигураций на тестовой выборке

Эксперимент	Что проверялось	Accuracy	Macro F1	Weighted F1
Baseline CatBoost	История, регион, площадь и координаты поля	0.699006	0.568485	0.689626
CatBoost + extra features	Расширение признакового пространства: число уникальных культур, наличие <code>fallow</code> и <code>legumes</code> , признаки повторяемости	0.699235	0.569473	0.689991
CatBoost + transition graph	Гибридное ранжирование по формуле $\text{score}(c) = \alpha p_{\text{CatBoost}}(c \mid x) + \beta p_{\text{graph}}(c \mid c_{t-1})$ при лучшей конфигурации $\alpha = 0.9, \beta = 0.1$	0.698714	0.564387	0.688729

3.7 Сравнение подходов и выбор основной модели

Сводное сравнение простых базовых подходов, марковской модели первого порядка и основной модели CatBoost приведено в таблице 6.

Таблица 6: Сравнение базовых подходов и основной модели CatBoost

Модель	Выборка	Accuracy	Macro F1	Weighted F1
<code>most_frequent</code>	validation	0.305306	0.051977	0.142820
<code>last_crop</code>	validation	0.354267	0.172492	0.361115
<code>markov_1</code>	validation	0.557140	0.411203	0.539053
<code>catboost</code>	validation	0.699281	0.568771	0.689966
<code>most_frequent</code>	test	0.305068	0.051946	0.142623
<code>last_crop</code>	test	0.354321	0.172575	0.361135
<code>markov_1</code>	test	0.557219	0.411371	0.539027

Модель	Выборка	Accuracy	Macro F1	Weighted F1
catboost	test	0.699006	0.568485	0.689626

Из таблицы следует, что простые базовые стратегии полезны как ориентиры, но недостаточны как основа рекомендательной системы. Markov-1 заметно превосходит наивные эвристики, что подтверждает значимость переходной статистики между культурами. При этом основная модель CatBoost устойчиво превосходит все базовые подходы, что указывает на полезность трёхлетней истории и контекстных признаков.

Промежуточные эксперименты с дополнительными признаками и графовым переранжированием не дали достаточных оснований для отказа от основной модели CatBoost. Следовательно, выбранная конфигурация CatBoost обоснованно используется в качестве основной модели и предиктивного ядра системы. Такое решение позволяет сохранить модель достаточно компактной и воспроизводимой, а дополнительные признаки и графовое переранжирование рассматривать как исследовательские расширения, проясняющие границы выбранного подхода.

Таким образом, к концу данного этапа в работе зафиксировано основное предиктивное ядро, на основе которого далее строятся рекомендательный слой, анализ уверенности и слой интерпретации рекомендаций.

Глава 4. Рекомендательный слой и оценка качества

4.1 Переход от классификации к ранжированному списку кандидатов

После выбора основной предиктивной модели следующий шаг состоит в переходе от обычной многоклассовой классификации к рекомендательной постановке. В классификационном режиме модель возвращает наиболее вероятный класс следующей культуры. Однако в прикладном сценарии такой формат не всегда является достаточным. Для специалиста полезнее видеть не один жёсткий ответ, а несколько наиболее правдоподобных кандидатов,

которые можно дополнительно интерпретировать с учётом предметного контекста.

По этой причине выход модели рассматривается как список из k культур-кандидатов.

$$P(y \mid x) = (p_1, p_2, \dots, p_m) \rightarrow R_k(x) = (c_{(1)}, c_{(2)}, \dots, c_{(k)}),$$

где $c_{(1)}, c_{(2)}, \dots, c_{(k)}$ — культуры, соответствующие наибольшим модельным вероятностям.

Такая интерпретация позволяет использовать результат модели не только как единичный прогноз, но и как ранжированный набор альтернатив для поддержки принятия решений.

4.2 Метрики рекомендательной постановки

Для оценки качества в рекомендательном режиме в работе используются три основные метрики:

- Accuracy@1
- Hit@3
- Hit@5

Показатель Accuracy@1 соответствует точности первой рекомендации и показывает, в какой доле случаев наиболее вероятная культура совпадает с фактической следующей культурой. Показатель Hit@3 показывает долю наблюдений, в которых истинная культура попадает в первые три позиции ранжированного списка. Аналогично Hit@5 показывает долю наблюдений, в которых правильный класс присутствует в первых пяти рекомендациях.

Содержательно эти метрики позволяют перейти от вопроса *«насколько часто модель угадывает один правильный класс?»* к более прикладному вопросу *«насколько часто правильная культура попадает в короткий список правдоподобных кандидатов?»*

4.3 Сравнение CatBoost и Markov-1 в рекомендательном режиме

Для проверки того, насколько полезно использование более длинной истории и контекстных признаков, основная модель CatBoost сравнивается с базовой моделью Markov-1 в той же рекомендательной постановке. Напомним, что Markov-1 использует только последнюю культуру в истории и оценивает переходы вида:

$$P(c_t \mid c_{t-1})$$

где c_{t-1} обозначает последнюю культуру в истории поля, а c_t — целевую культуру следующего года.

Таким образом, Markov-1 представляет собой не наивную эвристику, а вероятностную модель переходов между соседними культурами. В отличие от неё CatBoost использует не только последнюю культуру, но и трёхлетнюю историю вместе с контекстными признаками. Сравнение этих подходов показывает вклад более богатого признакового описания в качество рекомендаций.

Итоговые значения для CatBoost и Markov-1 на валидационной и тестовой выборках приведены в таблице 7.

Таблица 7: Сравнение CatBoost и Markov-1 в рекомендательной постановке

Модель	Выборка	Accuracy@1	Hit@3	Hit@5
CatBoost	validation	0.699281	0.951190	0.990794
Markov-1	validation	0.557140	0.855302	0.931781
CatBoost	test	0.699006	0.951236	0.990819
Markov-1	test	0.557219	0.855303	0.931717

Полученные значения показывают, что даже если ограничиться одной рекомендацией, CatBoost правильно определяет следующую культуру примерно в 70% случаев. Однако более важным является то, что при переходе к постановке с формированием короткого списка кандидатов покрытие резко

возрастает: в первые три позиции правильная культура попадает примерно в 95% случаев, а в первые пять позиций — почти в 99% случаев.

С прикладной точки зрения это означает, что CatBoost выбран не только по Accurasy@1, но и по способности формировать качественный список из k кандидатов для поддержки принятия решений.

Сравнение с Markov-1 показывает устойчивое преимущество основной модели CatBoost по всем ключевым метрикам. Это означает, что использование трёхлетней истории и контекстных признаков добавляет полезную информацию по сравнению с моделью, опирающейся только на последнюю культуру. Иными словами, следующая культура определяется не только ближайшим предыдущим состоянием, но и более широким историческим и контекстным окружением.

4.4 Поклассовый анализ качества рекомендаций

Общих метрик недостаточно для полного понимания поведения модели, поэтому в работе дополнительно анализируется качество по отдельным целевым классам. Поклассовый анализ основан на сравнении значений recall@1 и recall@3 для отдельных целевых классов. Соответствующие значения приведены в таблице 8.

Таблица 8: Поклассовое качество рекомендаций основной модели CatBoost на тестовой выборке

Класс	recall@1	recall@3	Комментарий
corn	0.7187	0.9841	Устойчивый массовый класс
cotton	0.7659	0.9665	Хорошо выраженный региональный паттерн
fallow	0.4068	0.8044	Заметный выигрыш при переходе к списку кандидатов
forage_hay	0.8505	0.9337	Высокое качество первой рекомендации
legumes	0.1384	0.7331	Сложный класс для первой рекомендации
other_cereals	0.2401	0.6394	Более разнородная группа культур
sorghum	0.3061	0.8448	Заметный выигрыш при переходе к списку кандидатов
soybeans	0.7605	0.9928	Устойчивый массовый класс
wheat	0.7304	0.9558	Один из наиболее устойчивых классов

Из таблицы видно, что качество рекомендаций различается по классам. Для устойчивых массовых культур, таких как `forage_hay`, `cotton`, `soybeans`, `wheat` и `corn`, качество первой рекомендации уже находится на сравнительно высоком уровне. Для более сложных и разнородных классов, включая `fallow`, `sorghum`, `other_cereals` и `legumes`, особенно важен переход к списку из нескольких кандидатов: даже если первая позиция оказывается ошибочной, правильный класс часто сохраняется среди ближайших альтернатив.

Например, для `legumes` качество первой рекомендации остаётся низким, однако уже в первых трёх позициях правильный класс попадает существенно чаще. Это показывает, что в сложных случаях полезность системы заключается не столько в однозначном угадывании первой позиции, сколько в способности включить правдоподобную культуру в короткий список альтернатив.

Таким образом, поклассовый анализ подтверждает общий вывод главы: качество рекомендаций зависит от устойчивости культурных паттернов и представленности классов, а рекомендательная постановка особенно полезна

для менее устойчивых классов.

4.5 Интерпретация результатов

Полученные результаты показывают, что рекомендательная постановка лучше соответствует прикладному сценарию использования системы, чем рассмотрение только первой рекомендации. Высокие значения Hit@3 и Hit@5 означают, что модель часто сохраняет правильную культуру среди ближайших альтернатив даже в тех случаях, когда первая позиция оказывается ошибочной.

При этом сравнение с Markov-1 показывает, что качество рекомендаций определяется не только статистикой ближайшего перехода $P(c_t | c_{t-1})$, но и более широким историческим и пространственно-региональным контекстом. Это подтверждает роль CatBoost как предиктивного ядра, формирующего основу для ранжированного списка кандидатов.

В результате рекомендательный слой связывает предиктивное ядро системы с последующими компонентами архитектуры: анализом уверенности и формированием интерпретационного контекста.

Глава 5. Уверенность рекомендаций и калибровка

5.1 Роль слоя оценки уверенности в рекомендательной системе

После перехода к рекомендательной постановке возникает вопрос не только о том, какие культуры попадают в короткий список кандидатов, но и о том, насколько надёжно модель формирует этот список. В прикладном сценарии это особенно важно: два наблюдения могут иметь одинаковый формат выхода в виде списка из k кандидатов, но существенно различаться по степени уверенности модельного вывода. Поэтому в работе поверх рекомендательного слоя вводится дополнительный слой оценки уверенности. Его задача состоит в том, чтобы разделять случаи на более устойчивые и более спорные и тем самым делать использование рекомендаций более интерпретируемым.

Содержательно слой оценки уверенности не заменяет модель и не формирует новое ранжирование кандидатов. Он использует уже рассчитанные ве-

роятности CatBoost и переводит их в более прикладной формат. В результате пользователь получает не только короткий список кандидатов, но и дополнительную оценку того, к какому уровню надёжности относится конкретная рекомендация. Такая логика особенно полезна в задачах поддержки принятия решений, где важно различать ситуации, в которых модель действует на устойчивом статистическом основании, и ситуации, в которых результат следует интерпретировать осторожнее.

В работе используются три группы уверенности:

- `high_confidence`;
- `medium_confidence`;
- `low_confidence`.

Пороговые правила формирования групп уверенности приведены в таблице 9.

Таблица 9: Пороги формирования групп уверенности

Техническое обозначение	Группа	Условие формирования
<code>high_confidence</code>	Высокая уверенность	$p_1 \geq 0.70$ и $\Delta_{1,2} \geq 0.25$
<code>medium_confidence</code>	Средняя уверенность	условие высокой уверенности не выполнено, но $p_1 \geq 0.50$ и $\Delta_{1,2} \geq 0.12$
<code>low_confidence</code>	Низкая уверенность	иначе

Здесь p_1 обозначает вероятность первой рекомендации, а $\Delta_{1,2} = p_1 - p_2$ — разницу между вероятностями первой и второй рекомендаций.

Тем самым итоговый вывод системы можно описать не только как ранжированный список кандидатов, но и как сочетание списка кандидатов с оценкой уверенности. Именно такое представление делает рекомендательный результат ближе к реальному сценарию использования.

5.2 Результаты по группам уверенности

Для тестовой выборки слой оценки уверенности даёт следующие результаты:

Таблица 10: Качество рекомендаций по группам уверенности на тестовой выборке

Группа	Число наблюдений	Accuracy@1	Hit@3
high_confidence	3 042 231	0.84147	0.97713
medium_confidence	1 691 260	0.60931	0.94252
low_confidence	1 043 523	0.42902	0.88987

Как видно из таблицы, группы действительно различаются по качеству рекомендаций. В зоне `high_confidence` модель показывает наиболее устойчивый результат: точность первой рекомендации превышает 0.84, а правильная культура попадает в первые три позиции почти в 98% случаев. В группе `medium_confidence` показатели снижаются, однако остаются высокими для постановки с коротким списком кандидатов. В группе `low_confidence` точность первой рекомендации уже заметно ниже, но даже здесь значение `Hit@3` остаётся достаточно высоким. Это означает, что в сложных случаях модель часто ошибается в первой позиции, но всё ещё включает фактическую следующую культуру в число нескольких наиболее вероятных кандидатов.

С практической точки зрения это разделение имеет понятную интерпретацию. В случаях высокой уверенности результат можно рассматривать как сравнительно устойчивую рекомендацию. В случаях средней уверенности пользователь, скорее, получает короткий список кандидатов, внутри которого целесообразно сравнивать несколько вариантов. В случаях низкой уверенности модельный вывод не следует скрывать, но его правильнее подавать как спорный случай, требующий более осторожной интерпретации и, возможно, дополнительной экспертной проверки. Таким образом, слой оценки уверенности делает рекомендательную систему более информативной, поскольку показывает не только направление рекомендации, но и характер её надёжности.

5.3 Интерпретация слоя оценки уверенности

Полученные результаты показывают, что группы уверенности не являются декоративным дополнением, а действительно отражают различия в качестве модельного вывода. Это важный момент для общей логики работы. Если бы качество в группах высокой, средней и низкой уверенности различалось слабо, сигнал уверенности не имел бы практического смысла. Однако в рассматриваемой системе наблюдается явная стратификация по надёжности, что подтверждает полезность выделения слоя оценки уверенности как самостоятельного уровня архитектуры.

Особенно важно, что даже в группе `low_confidence` модель сохраняет полезность именно как рекомендательная система. Низкая уверенность в данном случае не означает, что результат полностью бесполезен; она означает, что интерпретации только первой рекомендации недостаточно и что корректнее рассматривать несколько альтернатив одновременно. Это хорошо согласуется с общей постановкой работы: система ориентирована не на выдачу единственного ответа, а на формирование короткого списка вероятных вариантов с дополнительным контекстом для их анализа.

5.4 Калибровка вероятностей

Наличие слоя оценки уверенности поднимает ещё один важный вопрос: насколько вероятности, выдаваемые моделью, действительно согласуются с фактической частотой правильных ответов. Для этого в работе дополнительно рассматривается диагностический анализ калибровки вероятностей. Он позволяет проверить отсутствие грубых признаков переуверенности или недоуверенности модели на фиксированной подвыборке и рассматривать оценку уверенности как вспомогательный диагностический сигнал, связанный с надёжностью рекомендации.

Для оценки калибровки использовались две стандартные величины:

- ECE (Expected Calibration Error);
- Brier score.

Оценка калибровки вероятностей выполнялась на подвыборке из 5000

объектов, сформированной отдельно для валидационной и тестовой выборок. Данная подвыборка использовалась только для диагностического анализа вероятностных оценок модели: расчёта ECE, Brier score, средней уверенности, точности первой рекомендации и построения калибровочной кривой. Основные метрики качества рекомендательной системы, включая Accuracy@1, Hit@3 и Hit@5, рассчитывались на полных валидационной и тестовой выборках.

Использование подвыборки связано с практическими ограничениями вычислительного анализа: полные выборки содержат миллионы наблюдений, тогда как для первичной диагностики согласованности модельных вероятностей с фактической точностью достаточно диагностической подвыборки фиксированного размера. Поэтому результаты калибровочного анализа рассматриваются не как исчерпывающая статистическая оценка всех вероятностных свойств модели, а как дополнительная диагностическая проверка отсутствия грубых признаков переуверенности или недоуверенности модели. Сводные значения для валидационной и тестовой выборок приведены в таблице 11.

Таблица 11: Калибровочные метрики на подвыборках для диагностического анализа

Выборка	ECE	Brier score	Средняя уверенность	Accuracy@1	Число объектов
validation	0.02305	0.16440	0.75026	0.73560	5 000
test	0.01737	0.16120	0.75398	0.74800	5 000

Калибровочная кривая для подвыборки из 5000 объектов тестовой выборки приведена на рисунке 2. Диагональная линия соответствует идеальной калибровке, а точки показывают соотношение средней уверенности модели и фактической точности внутри интервалов вероятности.




Рис. 2: Reliability diagram для baseline CatBoost на test preview-выборке

Низкие значения ЕСЕ указывают на отсутствие грубых расхождений между вероятностями модели и фактической точностью на рассматриваемых подвыборках. Это не означает идеальную калибровку во всех областях вероятностного пространства, но дополнительно показывает, что оценку уверенности можно использовать как вспомогательный диагностический показатель, связанный с надёжностью рекомендации. Значения Brier score также поддерживают интерпретацию этих результатов как дополнительной диагностической оценки вероятностных выходов модели.

5.5 Место анализа уверенности в общей логике работы

С архитектурной точки зрения слой оценки уверенности является естественным продолжением рекомендательного слоя. Сначала модель формирует ранжированный список вероятных культур, затем анализ уверенности показывает, насколько устойчиво этот короткий список кандидатов выглядит

с точки зрения вероятностного вывода. В результате система получает ещё один уровень анализа результата, не связанный напрямую с семантическим объяснением кандидатов, но важный для практического использования.

Таким образом, слой оценки уверенности дополняет рекомендательный слой и показывает, насколько устойчиво сформирован короткий список кандидатов. В отличие от последующего графового компонента, он не объясняет предметные причины выбора культур, а характеризует вероятностную надёжность модельного вывода. Далее эти рекомендации рассматриваются уже с точки зрения семантической интерпретации с использованием графа знаний.

Глава 6. Граф знаний и интерпретация рекомендаций

6.1 Роль слоя интерпретации в работе

После построения предиктивного ядра, рекомендательного слоя и анализа уверенности возникает следующая задача: сделать результат системы более интерпретируемым. В рекомендательной постановке пользователь получает не один ответ, а короткий список вероятных следующих культур. Однако сам по себе ранжированный список вероятностей ещё не даёт содержательного объяснения, почему именно эти кандидаты оказались в верхней части списка и какие факторы поддерживают или ослабляют отдельные варианты. Поэтому в работе поверх модельного результата вводится отдельный слой интерпретации на основе графа знаний.

В данной работе используется компактный граф знаний предметной области. Он не является полноразмерной агрономической онтологией и не предназначен для объяснения внутренних механизмов CatBoost. Его задача состоит в интерпретации кандидатов, уже сформированных предиктивной моделью: через переходную статистику, региональную типичность, принадлежность к группам культур и срабатывание поддерживающих или предупреждающих правил.

Важно подчеркнуть, что граф знаний в данной работе не рассматривается как самостоятельная предиктивная модель и не заменяет CatBoost. Его

задача значительно уже: он используется для семантической интерпретации списка кандидатов, а не для построения нового основного ранжирования. Иными словами, предиктивное ядро отвечает на вопрос, какие культуры система считает наиболее вероятными, а слой интерпретации помогает интерпретировать полученный список и выделить содержательные поддерживающие и предупреждающие сигналы для отдельных культур.

Такой подход позволяет избежать смешения двух разных функций. Вероятностный вывод модели и его семантическая интерпретация в работе разведены по разным уровням. Благодаря этому графовый слой не претендует на роль «источника истины», а выступает как дополнительный инструмент анализа, помогающий показать, насколько тот или иной кандидат согласован с наблюдаемым контекстом.

6.2 Общая структура графа знаний

Граф знаний в работе построен как компактное графовое представление сущностей, связанных с задачей рекомендации следующей культуры. По метаданным запуска граф содержит 2827 узлов и 18154 ребра, а также включает 5 интерпретационных правил и набор разборов примеров, используемых для анализа типичных сценариев поведения системы.

В графе используются четыре типа сущностей:

- культуры;
- группы культур;
- регионы;
- правила.

Такая структура позволяет представить не только сами классы целевых культур, но и их более общий контекст. Культуры связываются между собой переходными отношениями, дополнительно привязываются к укрупнённым группам, рассматриваются в региональном контексте и получают интерпретационные сигналы через набор правил. Тем самым граф знаний выступает как слой предметно-ориентированного представления, который можно использовать для анализа списка кандидатов.

В самом общем виде место графа в архитектуре можно описать как последовательность:

список кандидатов модели → контекст графа и правил →
пояснение для кандидата.

Эта логика подчёркивает, что граф не порождает кандидатов сам по себе, а работает с уже полученным списком и дополняет его интерпретационным контекстом.

6.3 Типы связей в графе

Структура графа опирается на несколько видов связей. В первую очередь это переходы между культурами, построенные по статистике, рассчитанной только на обучающей выборке. Они отражают наблюдаемую частоту перехода от одной культуры к другой и позволяют использовать накопленные последовательности как источник поддерживающего сигнала для кандидатов. Кроме того, в граф включены связи принадлежности культуры к укрупнённой группе, а также связи, отражающие типичность культуры для региона. Наконец, отдельный тип связей используется для связывания интерпретационных правил с конкретными кандидатами.

Смысл каждого из этих типов связей различен. Переходные связи показывают, насколько кандидат согласуется с наблюдаемыми историческими закономерностями. Связи с группами культур позволяют анализировать более общий уровень сходства и насыщения. Региональные связи дают дополнительный сигнал о том, является ли культура типичной для рассматриваемого контекста. Связи с правилами фиксируют поддерживающие и предупреждающие эффекты, которые используются в логике интерпретации. В совокупности это позволяет не сводить анализ к одной числовой вероятности, а рассматривать кандидата в более богатом контексте.

6.4 Интерпретационные правила

Отдельный компонент слоя интерпретации образует набор правил. В работе используются пять правил; их смысл и тип интерпретационного сигнала приведены в таблице 12.

Таблица 12: Интерпретационные правила графа знаний

Правило	Смысл	Тип сигнала
repeat_crop_warning	Предупреждение, если кандидат повторяет последнюю культуру в истории поля	Предупреждающий
same_group_saturation	Предупреждение, если история насыщена одной группой культур и кандидат относится к той же группе	Предупреждающий
legume_break_bonus	Поддерживающий сигнал для кандидатов из бобовых культур, если в недавней истории не было бобовых	Поддерживающий
fallow_break_effect	Поддерживающий сигнал при переходе от fallow к культуре или предупреждение при повторном выборе fallow	Поддерживающий / предупреждающий
region_typicality	Поддерживающий сигнал для культур, типичных для региона по статистике, рассчитанной только на обучающей выборке	Поддерживающий

Каждое из них имеет интерпретационную, а не предписывающую функцию. Правила не являются полноценной экспертной агрономической системой и не должны трактоваться как универсальное основание для принятия решения. Их роль состоит в том, чтобы давать поддерживающие и предупреждающие сигналы для анализа списка кандидатов. Поэтому правила в данной работе понимаются не как формализация полной предметной истины, а как ограниченный и интерпретируемый набор семантических сигналов.

Содержательно правила можно разделить на два типа. Первый тип связан с предупреждениями: повтор одной и той же культуры или насыщение последовательности одной группой культур могут рассматриваться как предупреждающие сигналы. Второй тип связан с поддерживающими сигналами: например, логика разрыва севооборота за счёт бобовых, эффект fallow или региональная типичность культуры могут усиливать интерпретационную поддержку отдельного кандидата. Такое сочетание позволяет анализировать список кандидатов не только с точки зрения статистического ранжирования, но и с точки зрения более понятной семантической логики.

6.5 Интерпретация на уровне отдельных кандидатов

Слой интерпретации в работе применяется к отдельным позициям ранжированного списка. Граф не предназначен для объяснения «внутренностей» CatBoost напрямую и не интерпретирует веса модели в терминах причинности. Вместо этого для каждой позиции в списке из k кандидатов собирается набор дополнительных характеристик, описывающих его положение в контексте графа и правил.

Для каждого кандидата формируются следующие элементы интерпретационного вывода:

- положение кандидата в ранжированном списке;
- вероятность или оценка модели;
- принадлежность к укрупнённой группе;
- переходная поддержка;
- региональный сигнал;
- поддерживающие и предупреждающие флаги;
- итоговый `graph_support_score`;
- уровень графовой поддержки.

Тем самым выход слоя интерпретации можно описать так:

кандидат $\rightarrow$ оценка модели + контекст графа и правил + краткое пояснение

Такой формат удобен по двум причинам. Во-первых, он сохраняет связь с модельным результатом: каждый кандидат остаётся частью исходного ранжированного списка. Во-вторых, он даёт более содержательный комментарий к каждой позиции в списке. Пользователь видит не только сам факт того, что культура попала в список из k кандидатов, но и дополнительный контекст, объясняющий, какие сигналы её поддерживают или ослабляют.

6.6 Показатель графовой поддержки и его интерпретация

Одним из центральных элементов слоя интерпретации является `graph_support_score`. Этот показатель агрегирует несколько типов сигналов: переходную статистику, региональную типичность, поддержку правил и

предупреждения. Тем самым он служит сводной характеристикой того, насколько конкретный кандидат согласован с контекстом графа и правил.

При этом принципиально важно правильно интерпретировать этот показатель. Он:

- не является вероятностью;
- не должен сравниваться с модельной вероятностью как величина того же типа;
- не доказывает причинную полезность культуры;
- не заменяет основной предиктивный ранг.

Его корректное понимание состоит в следующем: `graph_support_score` показывает, насколько кандидат согласован с интерпретационным контекстом, построенным на переходной статистике, региональном сигнале и наборе правил. Это делает показатель полезным именно как интерпретационный инструмент, а не как альтернативное ядро решения.

6.7 Согласованность между моделью и интерпретационным словом

Для анализа поведения списка кандидатов в работе вводится понятие согласованности между первым выбором модели и контекстом графа и правил. Это позволяет рассматривать не только положение кандидатов в ранжировании, но и то, насколько первый кандидат модели поддержан словом интерпретации. По итогам разборов примеров были получены случаи с `strong` и `weak_alignment`; категория `medium` в данном запуске не появлялась, поскольку выбранные примеры были отнесены только к крайним типам согласованности.

Смысл этой интерпретации заключается не в делении на «правильные» и «неправильные» ответы графа. Например, `weak_alignment` не означает, что модель ошиблась, а граф оказался прав. Он означает более узкую вещь: выбранный первый кандидат модели получает относительно слабую поддержку со стороны контекста графа и правил, тогда как некоторые альтернативы из

списка кандидатов могут выглядеть семантически более поддержанными. В прикладной постановке это особенно важно, поскольку показывает, в каких случаях список кандидатов следует рассматривать внимательнее, а не ограничиваться первой позицией.

Тем самым слой интерпретации выполняет ещё одну функцию: он помогает различать простые согласованные случаи и сложные случаи с конкурирующими альтернативами. Это усиливает всю рекомендательную постановку работы, поскольку показывает, что полезность списка кандидатов заключается не только в наличии нескольких кандидатов, но и в возможности содержательно сравнивать их между собой.

6.8 Место графа знаний в общей логике работы

В общей архитектуре системы граф знаний располагается после рекомендательного слоя и слоя оценки уверенности. Сначала модель формирует список наиболее вероятных культур. Затем слой оценки уверенности показывает, насколько надёжно этот список выглядит с точки зрения вероятностного вывода. После этого граф знаний даёт пояснение на уровне отдельного кандидата. Такая последовательность важна концептуально: сначала формируется статистический результат, затем оценивается его надёжность, и только после этого добавляется интерпретационный контекст.

Благодаря такому расположению граф знаний дополняет основную модель и делает результат менее закрытым для анализа. Пользователь получает не только ранжированный список культур, но и пояснения, связанные с переходными закономерностями, региональным контекстом и интерпретационными правилами. Такое разделение ролей делает интерпретацию рекомендаций более понятной и не смешивает модельное ранжирование с предметными пояснениями.

Таким образом, граф знаний дополняет вероятностное ранжирование основной модели и используется для интерпретации уже сформированного списка кандидатов. Его назначение состоит в добавлении предметного контекста к модельному результату: переходной поддержки, региональной типичности, принадлежности к группам культур и предупреждающих сигналов.

Особенно полезным такой слой оказывается в спорных случаях, когда первая рекомендация модели не является единственным правдоподобным вариантом. Далее работа графового слоя рассматривается на отдельных примерах, где можно сопоставить историю поля, вероятности модели, уровень уверенности и интерпретационный контекст для конкретных кандидатов.

Глава 7. Анализ отдельных примеров

7.1 Роль анализа отдельных примеров в работе

После построения предиктивного ядра, перехода к рекомендательной постановке, анализа уверенности и слоя интерпретации возникает задача показать, как система ведёт себя не только на уровне усреднённых метрик, но и на уровне отдельных наблюдений. Для этого в работе используются специально отобранные примеры полей, на которых можно последовательно проследить связь между историей культур, результатом модели, уровнем уверенности и графовым интерпретационным контекстом.

Такой формат анализа важен по двум причинам. Во-первых, усреднённые метрики не показывают, как именно ранжированный список кандидатов работает в простых и сложных случаях. Во-вторых, слой интерпретации по своей природе является локальным: его смысл раскрывается не на уровне общей таблицы результатов, а на уровне конкретного списка кандидатов для конкретного поля. Поэтому анализ отдельных примеров в данной работе выступает как естественный способ показать, каким образом предиктивный слой, слой оценки уверенности и графовый слой взаимодействуют между собой.

В проекте были собраны четыре примера:

- с высокой уверенностью;
- со средней уверенностью;
- с низкой уверенностью;
- сложный пример с расхождением сигналов.

Этот набор позволяет охватить как относительно простые и устойчивые

сценарии, так и случаи, где ранжированный список кандидатов требует более внимательной интерпретации.

Сводка выбранных примеров приведена в таблице 13. Каждый пример соответствует одному конкретному наблюдению из тестового фрагмента, для которого известны фактическая следующая культура, список из трёх кандидатов модели и оценки слоя интерпретации на уровне отдельных кандидатов. Поэтому далее сравниваются не абстрактные типы ситуаций, а конкретные культуры-кандидаты: например, `forage_hay`, `corn`, `legumes`, `soybeans` и их альтернативы внутри ранжированного списка.

Таблица 13: Содержательная сводка отдельных примеров

Пример	Фактическая культура	Первые три кандидата модели	Кандидат с наибольшей статус графовой поддержкой		Ключевой вывод
Высокая уверенность	<code>forage_hay</code>	<code>forage_hay</code> ($p_1 = 0.930$), <code>corn</code> , <code>wheat</code>	<code>forage_hay</code> ($gs = 0.661$)	первая рекомендация верна; цель в первых трёх позициях; сильная согласованность	модель и граф знаний согласованы: фактическая культура совпадает с первой рекомендацией и имеет сильную графовую поддержку
Средняя уверенность	<code>corn</code>	<code>corn</code> ($p_1 = 0.669$), <code>soybeans</code> , <code>forage_hay</code>	<code>soybeans</code> ($gs = 0.508$)	первая рекомендация верна; цель в первых трёх позициях; слабая согласованность	модель выбирает правильный <code>corn</code> , но граф знаний сильнее поддерживает <code>soybeans</code> ; это пример конкурирующей альтернативы внутри ранжированного списка
Низкая уверенность	<code>legumes</code>	<code>legumes</code> ($p_1 = 0.432$), <code>soybeans</code> , <code>fallow</code>	<code>soybeans</code> ($gs = 0.568$)	первая рекомендация верна; цель в первых трёх позициях; слабая согласованность	первая рекомендация совпала с целевой культурой, но модельная уверенность и графовая поддержка для неё низкие; результат лучше читать как ранжированный список кандидатов, а не как жёсткое предписание
Сложный класс	<code>soybeans</code>	<code>corn</code> ($p_1 = 0.689$), <code>cotton</code> , <code>soybeans</code>	<code>soybeans</code> ($gs = 0.386$)	первая рекомендация неверна; цель в первых трёх позициях; слабая согласованность	фактическая культура не первая, но остаётся в ранжированном списке; граф знаний выделяет её как более семантически поддерживаемую альтернативу

p_1 — вероятность первой рекомендации CatBoost; gs — `graph_support_score`.

7.2 Пример с высокой уверенностью

Первый тип примеров соответствует ситуациям, в которых модель демонстрирует высокий уровень уверенности, а первая рекомендация выглядит содержательно согласованной с интерпретационным контекстом. В таких случаях история поля, вероятностный вывод модели и графовая поддержка обычно не противоречат друг другу. Это наиболее простой сценарий работы системы: ранжированный список остаётся полезным, но первая позиция уже выглядит достаточно устойчивой.

В рассматриваемом примере с высокой уверенностью фактической следующей культурой является `forage_hay`, и CatBoost также ставит `forage_hay` на первое место с вероятностью 0.930. Граф знаний не предлагает более сильную альтернативу: наиболее поддержанным кандидатом также остаётся `forage_hay`. Поэтому этот пример показывает согласованный сценарий, где модельная оценка, фактический целевой класс и графовая поддержка сходятся в одной культуре.

С точки зрения интерпретации этот пример показывает поведение системы в условиях относительно устойчивого паттерна. Если поле относится к хорошо распознаваемой структуре, модель формирует сильную первую рекомендацию, а графовый слой показывает, что выбранный кандидат поддержан переходной статистикой, региональным контекстом и активными правилами.

7.3 Пример со средней уверенностью

Второй тип примеров соответствует случаям средней уверенности. Здесь первая рекомендация остаётся содержательно правдоподобной, однако ранжированный список в целом становится более важным, поскольку помимо первой позиции появляются и другие кандидаты, которые могут выглядеть осмысленно с точки зрения истории поля и интерпретационного контекста.

В примере со средней уверенностью фактической культурой является `corn`, и модель правильно помещает `corn` на первую позицию. Однако графовый сигнал сильнее поддерживает альтернативу `soybeans`: для неё выше `graph_support_score`, а в объяснении присутствует поддержка через `legume_break_bonus` и региональную типичность. Поэтому этот пример по-

казывает ситуацию, где первая рекомендация формально верна, но ранжированный список содержит содержательно конкурирующую альтернативу.

Этот пример раскрывает прикладной смысл рекомендательной постановки: она полезна не только для обработки явных и простых ситуаций, но и для анализа наблюдений, где система не должна ограничиваться одним ответом. В подобных случаях ранжированный список играет роль пространства разумных альтернатив: модель указывает основное направление, а граф знаний позволяет рассматривать соседние варианты как содержательно поддерживаемые кандидаты.

7.4 Пример с низкой уверенностью

Третий тип примеров связан со случаями низкой уверенности. Именно такие наблюдения особенно хорошо показывают, почему слой оценки уверенности и рекомендательная постановка с несколькими кандидатами являются принципиально важными для всей системы. В подобных сценариях первая рекомендация может быть недостаточно устойчивой, однако ранжированный список в целом остаётся полезным, поскольку в нём по-прежнему присутствуют правдоподобные альтернативы.

В примере с низкой уверенностью фактическая культура — *legumes*. Модель ставит *legumes* на первое место, но с заметно меньшей вероятностью 0.432. При этом граф знаний сильнее поддерживает *soybeans*, то есть близкую по смыслу альтернативу из группы бобовых. Такой пример важен именно потому, что первая рекомендация оказалась правильной, но её нельзя интерпретировать как устойчивое однозначное решение: и уровень уверенности, и графовая поддержка указывают на спорность ситуации.

На уровне интерпретации это проявляется в том, что графовый контекст может поддерживать не только первую рекомендацию, но и одну или несколько альтернатив. Для пользователя это означает, что результат не следует воспринимать как сильное однозначное предписание. Напротив, низкая уверенность должна побуждать рассматривать несколько кандидатов одновременно и использовать дополнительный предметный анализ.

7.5 Сложный пример с расхождением сигналов

Четвёртый тип примеров соответствует наиболее сложным ситуациям, в которых наблюдается напряжение между первой рекомендацией модели и интерпретационным контекстом. Именно такие случаи позволяют лучше всего показать, зачем в архитектуре нужен графовый слой. В этих сценариях первая позиция списка кандидатов может не совпадать с наиболее сильно поддержанным графом кандидатом, а фактическая следующая культура может находиться не на первом месте, а среди альтернатив в списке из трёх кандидатов.

В сложном примере фактической культурой является *soybeans*, тогда как первая рекомендация модели — *corn* с вероятностью 0.689. При этом *soybeans* всё же присутствует в списке из трёх кандидатов на третьей позиции и получает более сильную поддержку со стороны графа знаний, чем первая рекомендация. Именно этот пример наиболее явно показывает ценность рекомендательной постановки: первая рекомендация оказывается ошибочной, но ранжированный список и слой интерпретации сохраняют полезную информацию о фактическом целевом классе.

На рисунке 3 показан локальный подграф интерпретации для данного примера. Он отражает связи между кандидатами, региональным контекстом, группами культур и правилами, которые формируют графовую поддержку.




Рис. 3: Подграф интерпретации для сложного примера с расхождением модельного и графового сигналов

Из рисунка видно, что первая рекомендация модели и фактическая культура относятся к разным частям интерпретационного контекста. При этом soybeans, несмотря на третью позицию в модельном ранжировании, получает более высокую графовую поддержку, чем corn. Это иллюстрирует, почему в сложных случаях важно анализировать не только первую рекомендацию, но и весь короткий список кандидатов.

Краткая сводка сложного примера в формате карточки приведена в таблице 14.

Таблица 14: Сложный пример: краткая карточка наблюдения

Параметр	Значение
История поля	corn $\rightarrow$ corn $\rightarrow$ cotton
true_target	soybeans
Первая рекомендация модели / вероятность / уверенность	corn, $p_1 = 0.6887$, средняя уверенность
true_target в ранжированном списке	Да
Список из трех кандидатов	corn (0.6887), cotton (0.2118), soybeans (0.0835)
Кандидат с наибольшей графовой поддержкой	soybeans
Графовая поддержка лучшего кандидата	0.3863
Интерпретация	Сложный пример: первая рекомендация ошибочна, но true_target присутствует в ранжированном списке и сильнее поддержан графом.

Интерпретация таких случаев особенно важна. Их не следует трактовать как прямое противопоставление модели и графа знаний. Их смысл заключается в другом: ранжированный список следует рассматривать как пространство конкурирующих вариантов, где первая позиция не всегда исчерпывает всю полезную информацию. Если слой интерпретации сильнее поддерживает альтернативного кандидата, это указывает на спорность ситуации и делает анализ примера более содержательным.

7.6 Общая интерпретация рассмотренных примеров

Рассмотренные примеры позволяют сделать несколько важных выводов. Во-первых, они подтверждают, что систему следует интерпретировать не как одновариантный классификатор, а как рекомендательный прототип, полезность которого особенно проявляется в анализе нескольких кандидатов одновременно. Во-вторых, они показывают, что слой оценки уверенности действительно задаёт различие между более устойчивыми и более спорными рекомендациями. В-третьих, они демонстрируют, что граф знаний дополняет модельный результат и помогает интерпретировать различия между кандида-

тами внутри ранжированного списка.

Таким образом, анализ отдельных примеров в работе выполняет не иллюстративную, а аналитическую функцию. Он связывает между собой историю поля, ранжированный список кандидатов, сигнал уверенности и графовый интерпретационный контекст.

Рассмотренные примеры показывают работу базовой версии графа знаний. Далее на тех же случаях анализируется, как меняется интерпретационный контекст после добавления литературных правил.

Глава 8. Расширение графа знаний с использованием литературных источников

8.1 Роль дополнительного литературного слоя

В предыдущей главе были рассмотрены отдельные примеры работы системы, показывающие, как связаны история поля, вероятностный вывод CatBoost, уровень уверенности и графовый интерпретационный контекст. Эти примеры использовались для анализа базовой версии графа знаний, построенной на статистике переходов, группах культур и региональном контексте.

Далее проверяется, можно ли сделать пояснения более содержательными за счёт добавления внешних агрономических источников. Для этого базовый граф знаний был расширен литературными правилами, задающими поддерживающие и предупреждающие сигналы для отдельных переходов между культурами.

Для проверки этой идеи в работе добавлен отдельный воспроизводимый этап. Его задача состоит в расширении уже построенного графа знаний дополнительными сигналами, основанными на внешних агрономических источниках, согласованных с географией исходного датасета USDA NASS CSB/CDL. Эти правила не меняют предиктивное ядро системы, не изменяют список кандидатов, модельные вероятности и ранжирование CatBoost, а добавляют только дополнительный интерпретационный контекст для уже сформированных рекомендаций.

8.2 Источники данных для этапа

Расширение графа построено как отдельный воспроизводимый этап, который использует уже готовые результаты интерпретационного анализа и добавляет к ним вручную сформированную таблицу литературных правил. Входными данными этапа выступают два класса источников.

В качестве первого входа используются результаты базового графового слоя: рассмотренные примеры, локальные пояснения по кандидатам, структура графа знаний, интерпретационные правила и статистика переходов между культурами. Эти данные задают исходную версию графа и базовые значения графовой поддержки, с которыми затем сравнивается версия с учётом литературных правил.

Вторым входом является компактная таблица литературных правил. Она содержит пары культур, направление сигнала, тип интерпретации и краткое обоснование, полученное из внешних агрономических источников. В данной работе такие правила используются как дополнительный интерпретационный слой, а не как механизм переобучения модели.

Результаты этапа представлены в виде расширенных пояснений по кандидатам, сводки по рассмотренным примерам и сравнения базовой и расширенной версий графа. Дополнительно формируются визуализации графов с учётом литературных правил для тех же четырёх примеров.

8.3 Используемые внешние агрономические источники

Основным источником для общих правил севооборота выступает стандарт USDA NRCS Conservation Crop Rotation. Он задаёт логику разнообразия культур, ограничения повторов, использования бобовых как источника азота, минимизации повторного fallow и учёта локального климата, почвенных условий и доступности влаги [22]. Именно этот источник задаёт большую часть общих правил типа предупреждения о повторе культуры, предупреждения о насыщении группы культур и поддерживающего сигнала для бобовых культур.

Для американского контекста переходов между corn и soybeans использовано исследование Kluger et al., в котором преимущества такой ро-

тации оцениваются на данных по США [13]. Эти сигналы используются как прямые поддерживающие правила `corn` $\rightarrow$ `soybeans` и `soybeans` $\rightarrow$ `corn`. Для перехода `corn` $\rightarrow$ `wheat` используется осторожный предупреждающий сигнал из материалов Oklahoma State University Extension: остатки кукурузы могут повышать риск фузариоза колоса (Fusarium Head Blight) для последующей пшеницы, но такой сигнал трактуется как предупреждающий, а не как запрет или универсальное агрономическое предписание [10].

Дополнительно используется методическая оговорка из современной работы Kluger et al. о том, что эффекты предшественников зависят от последовательности культур, погодных условий и регионального контекста [12]. В данном этапе эта публикация служит источником контекстной интерпретации, а не прямым источником переходных правил.

8.4 Способ интеграции литературных правил в граф

Литературные сигналы не смешиваются с переходами, извлечёнными из данных, неявным образом. Для каждого сработавшего литературного правила в графе добавляется отдельный узел интерпретации типа `support` или `warning`, связанный с кандидатом из ранжированного списка. Тем самым в расширенном графе сохраняется различие между двумя типами сигналов:

- сигналами, наблюдаемыми в данных проекта;
- сигналами, пришедшими из внешних агрономических источников.

Часть правил задаётся на прямом уровне для конкретной пары культур, а часть — на уровне `group_approx`, когда источник говорит о семействе или агрономической группе, а не об отдельном агрегированном классе проекта. Для точных повторов культуры применяется более специфичное предупреждение о повторе. В этом случае предупреждение о насыщении той же группы культур не добавляется повторно, чтобы не учитывать один и тот же фактор дважды. Для неполных повторов внутри одной группы такое предупреждение сохраняется.

Для класса `forage_hay` предупреждение о повторе задано как слабое, поскольку агрегированный класс может включать многолетние или кормовые

звенья, роль которых отличается от повторного выращивания однолетних пропашных культур.

На уровне отдельных кандидатов это приводит к пересчёту `graph_support_score`. Новый показатель по-прежнему не трактуется как вероятность и не заменяет модельный ранг; он лишь суммирует более широкий набор сигналов поддержки и предупреждения. Тем самым литературные правила изменяют интерпретационную поддержку отдельных кандидатов, не изменяя модельные вероятности и ранжирование CatBoost.

8.5 Результаты на тех же примерах

Литературное расширение было применено к тем же четырём примерам, что и в базовом интерпретационном анализе: `case_high_confidence`, `case_medium_confidence`, `case_low_confidence` и `case_difficult_class`. Это позволяет сравнивать один и тот же набор ситуаций до и после добавления литературного слоя.

На выбранных четырёх примерах литературные правила не изменили итоговую категорию согласованности, но изменили интерпретационную поддержку отдельных кандидатов. В `case_high_confidence` сохранился статус `strong`, а для трёх остальных примеров сохранился статус `weak`. При этом внутри отдельных ранжированных списков изменились значения графовой поддержки и набор сработавших интерпретационных правил.

Сводное сравнение по тем же примерам приведено в таблице 15. Она показывает, что литературные правила влияют прежде всего на интерпретационную поддержку отдельных кандидатов, а не на итоговую категорию согласованности.

Таблица 15: Изменение графовой поддержки после добавления литературных правил

Пример	Первая рекомендация модели	Базовый gs	gs с литературными правилами	Δgs первой рекомендации	Кандидат с наибольшим gs	Согласованность
Высокая уверенность	forage_hay	0.661	0.601	-0.060	forage_hay (0.601)	сильная → сильная
Средняя уверенность	corn	0.376	0.306	-0.070	soybeans (0.588)	слабая → слабая
Низкая уверенность	legumes	0.011	0.061	+0.050	soybeans (0.688)	слабая → слабая
Сложный класс	corn	0.220	0.220	0.000	soybeans (0.436)	слабая → слабая

gs — graph_support_score; Δgs — разность между значением с учётом литературных правил и базовым значением для первой рекомендации модели. Литературные правила не меняют модельный ранг и вероятности

CatBoost; таблица отражает только изменение графовой интерпретационной поддержки.

В данном разделе рассматриваются не метрики предиктивного качества модели, а изменения интерпретационных показателей графа для уже выбранных примеров. После фильтрации было зафиксировано 9 срабатываний литературных правил; при этом для 3 строк с точным повтором культуры предупреждение о насыщении той же группы было пропущено, поскольку более специфичный сигнал повтора уже был учтён. На уровне рассмотренных примеров это особенно заметно для forage_hay, где повтор интерпретируется как слабое предупреждение, и для corn, где повтор культуры ослабляет поддержку первой рекомендации, тогда как переход к soybeans получает дополнительную поддержку.

Если рассмотреть усреднённую динамику по всем кандидатам, средняя разница между расширенным и базовым значениями графовой поддержки оказывается небольшой, но положительной и составляет примерно 0.008. Для первых рекомендаций модели средняя дельта отрицательна и составляет около -0.020, тогда как для остальных кандидатов она положительна и составляет около 0.023. На уровне отдельных кандидатов изменения оказались разнонаправленными: часть кандидатов получила дополнительную поддержку, часть — предупреждающие сигналы, а часть практически не изменилась.

8.6 Интерпретация результатов и ограничения

Полученный результат важен прежде всего с точки зрения интерпретации. Литературный слой делает объяснения на уровне отдельных кандидатов более содержательными, позволяет явно фиксировать предупреждающие сигналы для повторных или нежелательных переходов и усиливает некоторые агрономически правдоподобные альтернативы в ранжированном списке. Это особенно полезно в спорных случаях, где пользователю важно видеть не один ответ, а набор конкурирующих интерпретируемых альтернатив.

Ограничения этапа также следует обозначить явно. Во-первых, сам набор литературных правил формируется вручную и остаётся относительно компактным. Во-вторых, часть правил построена на уровне `group_approx`, поскольку агрегированные классы проекта не всегда имеют прямое соответствие одной конкретной культуре из источника. В-третьих, для класса `cotton` в литературном слое используются только общие предупреждения, связанные с повтором культуры и недостаточным разнообразием. Наконец, анализ выполнялся на тех же четырёх примерах, а не на полном тестовом наборе, поэтому он характеризует прежде всего качество интерпретации.

Таким образом, литературное расширение корректнее рассматривать как дополнительный интерпретационный слой, повышающий содержательность пояснений, но не меняющий основную модель и способ формирования рекомендаций. CatBoost формирует ранжированный список кандидатов, слой оценки уверенности характеризует надёжность результата, а граф знаний добавляет предметный контекст для интерпретации отдельных вариантов. Внешние агрономические источники в этом контуре используются не как агрономический оптимизатор, а как дополнительная внешняя агрономическая аргументация для уже построенных разборов кейсов.

Глава 9. Пространственная демонстрация результатов

9.1 Назначение пространственной демонстрации

Следующим шагом после анализа отдельных примеров становится пространственная демонстрация результатов. Её задача состоит в том, чтобы

связать результаты рекомендательного и интерпретационного слоёв с конкретными полями и показать возможный сценарий визуального анализа в пользовательском интерфейсе.

Для этого были подготовлены интерактивные карты и сводные таблицы, позволяющие сопоставлять положение полей, рекомендации и интерпретационный контекст. Эти материалы показывают, как можно перейти от общего пространственного контекста к анализу конкретного поля. В итоговом варианте карта связывает три типа информации:

- геометрическое или пространственное представление поля;
- результат рекомендательного слоя для этого поля;
- интерпретационный контекст для выбранного случая.

Иными словами, пространственная демонстрация переводит результат из формата таблиц и локальных графов в более прикладной сценарий визуального анализа.

9.2 Выбор локальной области на карте

Для пространственной демонстрации используется выбор локальной области на карте. Пользователь задаёт прямоугольную область интереса, после чего система отбирает поля, расположенные внутри неё.

Выбранная область используется как пространственный фильтр. Система показывает поля, попавшие внутрь неё, и тем самым делает карту удобным средством перехода от общего обзора к локальному анализу. В демонстрации акцент сделан на локальном сценарии: выборе области, просмотре полей внутри неё и переходе к рекомендациям для конкретных участков.




Рис. 4: Пример пространственной демонстрации рекомендаций для выбранной локальной области

На рисунке 4 показан пример выбранной локальной области. Пользователь может сначала определить интересующий участок на карте, затем рассмотреть поля внутри него и перейти к анализу рекомендаций для отдельных объектов.

9.3 Анализ полей внутри выбранной области

После выбора области карта становится точкой входа в разбор конкретных полей. Для объектов, попавших внутрь выбранного участка, могут быть показаны результаты рекомендательного слоя, уровень уверенности и интерпретационный контекст.

За счёт этого пользователь может не только видеть расположение полей, но и сопоставлять соседние участки, после чего переходить к анализу рекомендаций для интересующего объекта.

В результате пространственная демонстрация показывает, как результаты системы могут использоваться на уровне отдельных полей. Пользователь выбирает локальную область на карте, видит поля внутри неё и может перейти к анализу рекомендаций для конкретного участка. Тем самым модельные результаты, оценки уверенности и интерпретационный контекст связываются с пространственным представлением данных.

Глава 10. Направления дальнейшего развития

Разработанный прототип можно развивать в нескольких направлениях. Одно из них связано с расширением признакового пространства. В текущей версии система опирается на историю культур, базовые характеристики поля и региональный контекст. Добавление почвенных, климатических, экономических и производственных признаков позволило бы приблизить рекомендации к более реалистичному сценарию поддержки принятия решений.

Отдельным направлением является адаптация предложенного подхода к российскому сельскохозяйственному контексту. Для этого необходимы локальные данные о культурах на уровне полей и годов, региональные агрономические правила, а также подключение почвенных, климатических и производственных признаков. Такая адаптация позволила бы проверить переносимость разработанной методологии и уточнить интерпретационный слой с учётом особенностей конкретных регионов.

Ещё одно направление — более детальный анализ уверенности. В работе были рассмотрены группы уверенности и диагностическая оценка калибровки вероятностей. В дальнейшем этот анализ можно расширить: отдельно изучать калибровку по классам культур, регионам, типам последовательностей и сложным случаям, где первая рекомендация модели оказывается неверной, но правильная культура сохраняется среди ближайших альтернатив.

Отдельно можно развивать граф знаний. Графовый слой может быть дополнен новыми типами связей, литературными правилами и экспертными корректировками. Это позволит сделать интерпретационный контекст более содержательным и полезным для анализа отдельных кандидатов.

Отдельным направлением является развитие пространственного интерфейса. В текущей работе карта используется как демонстрация сценария анализа результатов на уровне полей. В дальнейшем такой интерфейс можно расширить: объединить карту, список рекомендаций, оценку уверенности и пояснения графа в едином пользовательском сценарии.

Таким образом, дальнейшее развитие работы связано не только с улучшением предиктивной модели, но и с расширением всей системы поддержки принятия решений: данных, диагностического анализа уверенности, интер-

претационного слоя, интерфейса анализа и адаптации подхода к российскому сельскохозяйственному контексту.

Заключение

В дипломной работе была рассмотрена задача рекомендации следующей культуры для сельскохозяйственного поля на основе истории его использования и базовых признаков поля и региона. Работа была построена как прототип системы поддержки принятия решений, в которой результат представлен не только в виде одной наиболее вероятной культуры, но и в виде ранжированного списка кандидатов, сопровождаемого оценкой уверенности и интерпретационным контекстом.

В ходе работы были подготовлены данные USDA NASS CSB/CDL, выполнено укрупнение культурных классов, построена оконная выборка по трём предыдущим годам истории поля и зафиксировано воспроизводимое разбиение данных. На этой основе были реализованы базовые подходы, марковская модель первого порядка и основная модель CatBoost, выбранная в качестве предиктивного ядра системы.

Экспериментальная оценка показала, что CatBoost устойчиво превосходит простые базовые подходы и Markov-1. При этом основной результат работы связан с переходом от одновариантного прогноза к рекомендательной постановке: система формирует короткий список вероятных культур, в котором фактическая культура часто сохраняется среди ближайших альтернатив.

Дополнительно были реализованы слой оценки уверенности, граф знаний и пространственная демонстрация. Слой оценки уверенности помогает различать более и менее надёжные рекомендации. Граф знаний добавляет к кандидатам предметный контекст: переходные закономерности, региональную типичность, принадлежность к группам культур, а также поддерживающие и предупреждающие сигналы. Пространственная демонстрация показывает, как результаты системы могут быть представлены на уровне отдельных полей в выбранной области карты.

Основной итог работы состоит в том, что задача выбора следующей культуры может быть рассмотрена не только как задача многоклассового предсказания, но и как задача построения объяснимой рекомендательной системы поддержки принятия решений. Разработанный прототип позволяет

сформировать набор вероятных кандидатов, оценить надёжность рекомендации и получить интерпретируемый контекст для анализа.

Список литературы

- [1] Agworld. Data driven farm management software for all farms, 2026.
- [2] Forkan Uddin Ahmed, Annesha Das, and Md Zubair. A machine learning approach for crop yield and disease prediction integrating soil nutrition and weather factors, 2024.
- [3] Claire Boryan, Zhengwei Yang, Rick Mueller, and Mike Craig. Monitoring us agriculture: the u.s. department of agriculture, national agricultural statistics service, cropland data layer program. *Geocarto International*, 26(5):341–358, 2011.
- [4] Climate LLC. Climate fieldview: The all-in-one digital farming solution, 2026.
- [5] Baptiste Darnala, Florence Amardeilh, Catherine Roussey, Konstantin Todorov, and Clément Jonquet. C3po: a crop planning and production process ontology and knowledge graph. *Frontiers in Artificial Intelligence*, 6:1187090, 2023.
- [6] Stefan Fenz, Thomas Neubauer, Jürgen Kurt Friedel, and Marie-Luise Wohlmuth. Ai- and data-driven crop rotation planning. *Computers and Electronics in Agriculture*, 212:108160, 2023.
- [7] Stefan Fenz, Thomas Neubauer, Johannes Heurix, Jürgen Kurt Friedel, and Marie-Luise Wohlmuth. Ai- and data-driven pre-crop values and crop rotation matrices. *European Journal of Agronomy*, 150:126949, 2023.
- [8] Georg Goldenits, Thomas Neubauer, Sebastian Raubitzek, Kevin Mallinger, and Edgar Weippl. Tabular reinforcement learning for reward robust, explainable crop rotation policies matching deep reinforcement learning performance. *Computers and Electronics in Agriculture*, 237(Part B):110571, 2025.
- [9] Francisco Gutiérrez, Nyi Nyi Htun, Florian Schlenz, Aikaterini Kasimati, and Katrien Verbert. A review of visualisations in agricultural decision support

- systems: An hci perspective. *Computers and Electronics in Agriculture*, 163:104844, 2019.
- [10] Bob Hunger and Jeff Edwards. Considerations when rotating wheat behind corn, 2017.
- [11] John Deere. Operations center: Precision ag technology, 2026.
- [12] Dan M. Kluger, Stefania Di Tommaso, and David B. Lobell. Evaluating crop rotations around the world using satellite imagery and causal machine learning, 2025.
- [13] Dan M. Kluger, Art B. Owen, and David B. Lobell. Combining randomized field experiments with observational satellite data to assess the benefits of crop rotations on yields, 2021.
- [14] Julien Osman, Jordi Inglada, and Jean-François Dejoux. Assessment of a markov logic model of crop rotations for early crop mapping. *Computers and Electronics in Agriculture*, 113:234–243, 2015.
- [15] Christoph Pahmeyer, Thomas Kuhn, and Wolfgang Britz. ‘Fruchtfolge’: A crop rotation decision support system for optimizing cropping choices with big data and spatially explicit modeling. *Computers and Electronics in Agriculture*, 181:105948, 2021.
- [16] Vishal Pandey, Ranjita Das, and Debasmita Biswas. Agrosense: An integrated deep learning system for crop recommendation via soil image analysis and nutrient profiling, 2025.
- [17] Roberto Da Silva Gervasio Pontes, Diego Nunes Brandão, Fábio Luiz Usberti, and Laura Silva De Assis. Multi-objective models for crop rotation planning problems. *Agricultural Systems*, 219:104050, 2024.
- [18] Luca Sartore, Claire Boryan, Andrew Dau, and Patrick Willis. An assessment of crop-specific land cover predictions using high-order markov chains and deep neural networks. *Journal of Data Science*, 21(2):333–353, 2023.

- [19] Cogan Shimizu, Shirly Stephe, Adrita Barua, Ling Cai, Antrea Christou, Kitty Currier, Abhilekha Dalal, Colby K. Fisher, Pascal Hitzler, Krzysztof Janowicz, Wenwen Li, Zilong Liu, Mohammad Saeid Mahdavinejad, Dean Rehberger, Mark Schildhauer, Meilin Shi, Sanaz Saki Norouzi, Yuanyuan Tian, Sizhe Wang, Zhangyu Wang, Joseph Zalewski, Lu Zhou, and Rui Zhu. The knowwheregraph ontology, 2024.
- [20] Ozlem Turgut, Ibrahim Kok, and Suat Ozdemir. Agroxai: Explainable ai-driven crop recommendation system for agriculture 4.0, 2024. Accepted in 2024 IEEE International Conference on Big Data.
- [21] USDA National Agricultural Statistics Service. Crop sequence boundaries, 2026.
- [22] USDA Natural Resources Conservation Service. Conservation practice standard: Conservation crop rotation, code 328, 2014.
- [23] xarvio Digital Farming Solutions. xarvio field manager, 2026.
- [24] Raghu Yaramasu, Varaprasad Bandaru, and Koutilya Pnvr. Pre-season crop type mapping using deep neural networks. *Computers and Electronics in Agriculture*, 176:105664, 2020.