

Санкт–Петербургский государственный университет

Выпускная квалификационная работа
Разработка рекомендательной системы севооборота

Уровень образования: Магистратура

Направление подготовки: Программирование и информационные
технологии

Образовательная программа: Технологии искусственного интеллекта и Big
Data

Автор: Корельский Дмитрий Сергеевич

Научный руководитель: Митрофанов Евгений
Павлович

Санкт-Петербург

2026 г.

Содержание

Введение	4
Глава 1. Постановка задачи	5
Глава 2. Обзор литературы и существующих решений	7
Глава 3. Архитектура решения	10
3.1. Общая структура системы	10
3.2. Уровень данных и подготовки выборки	11
3.3. Предиктивное ядро	11
3.4. Recommendation layer	12
3.5. Confidence layer	13
3.6. Explainability layer	13
3.7. Пространственный демонстрационный слой	14
3.8. Организация решения	15
3.9. Итоговая схема архитектуры	15
Глава 4. Данные и подготовка выборки	16
4.1. Источник данных	16
4.2. Предобработка исходных данных	17
4.3. Формирование оконной выборки	17
4.4. Фильтрация редких целевых классов	18
4.5. Разделение на обучающую, валидационную и тестовую вы- борки	20
4.6. Признаки финальной модели	21
4.7. Выводы по главе	22
Глава 5. Базовые модели, промежуточные эксперименты и выбор финальной модели	23
5.1. Роль baseline-моделей	23
5.2. Простые baseline-подходы	23
5.2.1 Baseline most_frequent	24
5.2.2 Baseline last_crop	24
5.3. Markov-1 как вероятностный baseline	24
5.4. Baseline CatBoost-модель	25

5.5. Эксперимент с дополнительными признаками	26
5.6. Эксперимент с CatBoost и transition graph	26
5.7. Сравнение подходов и выбор финальной модели	29
5.8. Выводы по главе	30
Глава 6. Recommendation layer и оценка качества	30
6.1. Переход от классификации к рекомендации	30
6.2. Метрики рекомендательной постановки	31
6.3. Сравнение CatBoost и Markov-1 в рекомендательном режиме	32
6.4. Поклассовый анализ качества	33
6.5. Интерпретация результатов	34
6.6. Выводы по главе	35
Глава 7. Уверенность рекомендаций и калибровка	35
7.1. Роль confidence-слоя в рекомендательной системе	35
7.2. Результаты по confidence-группам	37
7.3. Интерпретация confidence-слоя	38
7.4. Калибровка вероятностей	38
7.5. Место confidence-анализа в общей логике работы	40
7.6. Выводы по главе	40
Глава 8. Explainability через knowledge graph	41
8.1. Роль explainability-слоя в работе	41
8.2. Общая структура knowledge graph	42
8.3. Типы связей в графе	42
8.4. Rule layer	43
8.5. Candidate-level explainability output	45
8.6. Graph support score и его интерпретация	45
8.7. Согласованность между моделью и explainability-слоем . . .	46
8.8. Место knowledge graph в общей логике работы	47
8.9. Выводы по главе	47
Глава 9. Case studies и пространственная демонстрация	48
9.1. Роль case studies в работе	48
9.2. High confidence case	50
9.3. Medium confidence case	50

9.4. Low confidence case	51
9.5. Difficult / disagreement case	52
9.6. Общая интерпретация case studies	53
9.7. Пространственная демонстрация	54
9.8. Полный spatial context и demo subset	55
9.9. Bounding box selection	55
9.10. Место spatial demo в общей работе	56
9.11. Выводы по главе	57
Глава 10. Ограничения и направления развития	57
10.1. Ограничения текущей версии системы	57
10.1.1 Ограниченность постановки задачи	57
10.1.2 Ограничения, связанные с данными	58
10.1.3 Ограничения предиктивного ядра	59
10.1.4 Ограничения explainability-слоя	59
10.1.5 Ограничения пространственной демонстрации	60
10.2. Направления дальнейшего развития	60
10.2.1 Расширение контекстных признаков	60
10.2.2 Развитие confidence-анализа	61
10.2.3 Развитие explainability-слоя	61
10.2.4 Развитие пространственного интерфейса	62
10.3. Итоговые замечания по ограничениям и развитию	62
Заключение	62
Список использованных источников	66
Список литературы	66

Введение

Севооборот относится к числу базовых практик земледелия, поскольку последовательность культур на одном и том же поле влияет на дальнейшее использование участка и на характер принимаемых агрономических решений. Выбор следующей культуры обычно не является случайным: он связан с предшествующей историей поля, особенностями региона и накопленными закономерностями смены культур. Поэтому анализ таких последовательностей представляет интерес как с практической, так и с исследовательской точки зрения.

Развитие цифровых источников данных в сельском хозяйстве делает возможным переход от ручного анализа к более формализованным методам обработки исторической информации по полям. Если ранее решение о следующей культуре в основном принималось на основе опыта специалиста и локальных наблюдений, то наличие накопленных последовательностей культур позволяет использовать методы анализа данных и машинного обучения для поиска устойчивых паттернов и формирования рекомендаций. При этом на практике важно не только получить один наиболее вероятный вариант, но и рассмотреть несколько правдоподобных альтернатив.

Наряду с этим для систем подобного рода важна интерпретируемость результата. В прикладном сценарии пользователю недостаточно знать только рекомендуемую культуру; важно также понимать, насколько уверенно сделана рекомендация и какие факторы поддерживают или ослабляют отдельных кандидатов. Поэтому при разработке подобных систем актуальной становится не только задача прогнозирования, но и задача объяснения полученного shortlist-результата.

В данной работе рассматривается построение исследовательского прототипа рекомендательной системы, которая по истории культур на конкретном поле и базовым признакам поля формирует ранжированный список вероятных следующих культур. При этом работа сознательно не претендует на создание полноценного агрономического оптимизатора и не рассматривает систему как замену экспертному решению. Основной акцент делается на построении воспроизводимого и интерпретируемого прототипа, который может

использоваться как инструмент поддержки анализа.

Работа сочетает методы анализа последовательностей культур, многоклассового прогнозирования, рекомендательных систем и explainability-подходов. Это позволяет рассматривать задачу выбора следующей культуры не только как задачу предсказания, но и как задачу формирования интерпретируемого списка вероятных кандидатов для поддержки принятия решений.

В первой части работы рассматриваются постановка задачи, её границы и место работы среди существующих подходов. Далее описываются используемые данные, этапы их подготовки и общая архитектура решения. После этого анализируются модельное ядро, рекомендательный режим, оценка уверенности, explainability-слой и пространственная демонстрация результатов.

Глава 1. Постановка задачи

В данной работе рассматривается задача рекомендации следующей культуры для конкретного сельскохозяйственного поля на основе его исторической последовательности использования и базовых признаков поля и региона.

Практически задача может быть представлена так:

$$(\text{history}_1, \text{history}_2, \text{history}_3, x) \rightarrow \text{target}$$

где:

- $\text{history}_1, \text{history}_2, \text{history}_3$ — культуры в предыдущие три года;
- x — дополнительные признаки поля и региона;
- target — культура следующего года.

Таким образом, с формальной точки зрения задача сводится к многоклассовой классификации следующего шага в последовательности культур. Однако прикладной смысл работы не ограничивается только top-1 предсказанием. В реальной задаче выбора следующей культуры специалисту полезен не один ответ, а несколько правдоподобных вариантов, которые можно дополнительно оценить с учётом внешних ограничений и предметного контекста.

Поэтому в работе используется рекомендательная интерпретация модельного результата: система формирует ранжированный список наиболее вероятных кандидатов.

Входными данными для модели являются:

- история культур за три предыдущих года;
- региональные признаки;
- признаки, описывающие само поле.

В качестве таких признаков в работе используются:

- коды штата и округа;
- площадь поля;
- пространственные координаты.

Выход системы интерпретируется в двух уровнях:

- как наиболее вероятная следующая культура;
- как Top-k shortlist вероятных кандидатов.

Логика работы в прикладном виде может быть представлена так:

история поля + признаки поля →
ранжированный список следующих культур

В этой постановке решаются три взаимосвязанные подзадачи:

- **предсказание** следующей культуры по истории поля и дополнительным признакам;
- **ранжирование** кандидатов и формирование короткого списка вероятных вариантов;
- **интерпретация** полученного shortlist с учётом уверенности модели и объяснительного контекста.

Важно подчеркнуть, что работа не ставит целью построение полного оптимизатора севооборота. Разрабатываемая система рассматривается как объяснимый рекомендательный прототип, который помогает анализировать вероятные варианты следующей культуры, но не заменяет экспертное агрономическое решение.

В более компактной формулировке задача работы заключается в следующем: по истории культур на поле и базовым признакам поля и региона требуется построить систему, которая формирует ранжированный список вероятных следующих культур, оценивает уверенность рекомендаций и предоставляет интерпретируемый контекст для анализа shortlist-кандидатов.

Для решения этой задачи необходимо:

- подготовить и структурировать исторические данные по культурам;
- сформировать обучающую выборку в виде временных окон;
- построить предиктивное ядро модели;
- оценить качество результата в Top-k постановке;
- дополнить модель confidence- и explainability-слоями.

Такая постановка позволяет рассматривать выбор следующей культуры не только как задачу классификации, но и как задачу поддержки принятия решений, в которой важны не только точность предсказания, но и удобство интерпретации результата.

Глава 2. Обзор литературы и существующих решений

Задача выбора следующей культуры в литературе рассматривается в нескольких близких, но не совпадающих постановках. Наиболее часто встречаются работы по оптимизации севооборота, по crop recommendation на основе методов машинного обучения и по системам поддержки принятия решений, в которых существенную роль играют интерпретация результата и форма его представления пользователю [1, 2, 3, 4].

В первой группе работ основное внимание уделяется построению систем, ориентированных на **планирование и оптимизацию** структуры посевов. В таких исследованиях задача формулируется как поиск наилучшей по-

следовательности культур или наилучшего распределения посевов с учетом множества ограничений. Примером является система *Fruchtfolge*, в которой выбор культур описывается как задача пространственно-явного оптимизационного планирования с использованием математического программирования [1]. Подобные решения близки к задаче полного аграрного планирования, однако они отличаются от более узкой постановки, в которой по истории конкретного поля требуется сформировать ранжированный список вероятных следующих культур.

Во второй группе работ задача ставится как **crop recommendation** на основе данных о поле, регионе, почве, климате или истории наблюдений. Здесь акцент делается на построении модели, которая по набору признаков рекомендует наиболее подходящую культуру или ранжирует несколько кандидатов [2, 5]. Для данного направления характерно использование методов машинного обучения как основного предиктивного ядра. При этом в современных исследованиях все чаще подчеркивается, что для практического применения системы одной только точности недостаточно: пользователь должен понимать, по каким причинам тот или иной вариант рекомендован, и насколько надежен результат [3], [5].

Отдельное направление составляют работы, в которых используются **графовые и онтологические представления знаний**. В подобных исследованиях knowledge graph выступает не столько как самостоятельная предиктивная модель, сколько как средство описания сущностей предметной области, их связей, ограничений и правил интерпретации. Показательным примером является проект *СЗРО*, в котором crop planning and production process ontology и knowledge graph используются как основа knowledge-based decision support systems для сельского хозяйства [4]. Для данной дипломной работы этот класс решений важен потому, что показывает возможность применять графовое представление как интерпретационный слой, дополняющий основное модельное ядро.

Существенным аспектом agricultural DSS является не только вычислительная часть, но и **форма представления результата**. В обзоре визуализаций для agricultural decision support systems отмечается, что карты являются одним из центральных интерфейсов таких систем, а также подчеркивается

растущая значимость dashboard-подходов и визуализации неопределенности [3]. Это особенно важно в задачах, где система формирует не единственный ответ, а несколько кандидатов, требующих последующего анализа и сравнения.

Если рассматривать **прикладные существующие решения**, то на рынке присутствуют крупные цифровые платформы управления полями и хозяйством. Например, John Deere Operations Center позиционируется как онлайн farm management system, позволяющая планировать, контролировать и анализировать работу хозяйства, включая управление полями, техникой и производственными операциями [6]. Аналогично harvio FIELD MANAGER ориентирован на поддержку crop production decisions, используя spatial и satellite-based данные для анализа полевых зон, seeding, crop nutrition и crop protection [7]. Однако подобные платформы охватывают значительно более широкий круг задач, чем рекомендация следующей культуры по истории поля, и поэтому не являются прямыми аналогами рассматриваемой работы. Корректнее рассматривать их как более широкую прикладную среду, в рамках которой отдельный рекомендательный модуль подобного типа потенциально может использоваться.

Таким образом, существующие исследования и прикладные решения показывают, что задача выбора культуры может рассматриваться в разных масштабах: от полного оптимизационного планирования до узких рекомендательных и интерпретационных модулей [1, 2, 3, 4, 5]. На этом фоне данная работа занимает промежуточное положение. Она не ставит целью построение полного оптимизатора севооборота и не ограничивается только одновариантным прогнозом следующей культуры. Ее особенность состоит в сочетании предиктивного ядра, Top-k рекомендательного режима, confidence-сигнала и graph-based explainability layer. В результате работа ориентирована на построение **объяснимого рекомендательного прототипа**, который формирует shortlist вероятных следующих культур и предоставляет пользователю интерпретируемый контекст для их анализа.

Глава 3. Архитектура решения

3.1 Общая структура системы

Разрабатываемая в работе система построена как последовательный исследовательский pipeline, в котором каждый этап решает отдельную подзадачу и передаёт результат следующему этапу через устойчивые артефакты. Такой подход позволяет отделить подготовку данных от обучения моделей, оценку качества — от интерпретации, а предиктивное ядро — от демонстрационного пользовательского слоя. В результате архитектура решения имеет модульный характер: система не сводится к одной модели, а состоит из нескольких взаимосвязанных уровней, каждый из которых выполняет собственную функцию.

В наиболее общем виде архитектуру можно представить следующим образом:

данные → предобработка → предиктивное ядро → recommendation →
confidence → explainability → spatial demo

Такая схема отражает основную логику работы. На входе находятся исторические данные по культурам и признакам полей. После предобработки и формирования оконной выборки они используются для обучения предиктивной модели. Далее модельный результат интерпретируется в рекомендательном режиме, то есть в виде ранжированного списка наиболее вероятных культур. Поверх этого результата добавляются два дополнительных слоя: оценка уверенности и объяснимый контекст. Наконец, итоговый результат может быть представлен в пространственном интерфейсе, где рекомендации связываются с конкретными полями на карте.

Содержательно архитектура решения включает следующие уровни:

- уровень данных;
- уровень подготовки и представления выборки;
- уровень предиктивной модели;
- уровень рекомендаций;
- уровень уверенности;

- уровень explainability;
- уровень пространственной демонстрации.

Каждый из этих уровней будет кратко рассмотрен далее.

3.2 Уровень данных и подготовки выборки

Нижний уровень архитектуры образуют исходные данные USDA NASS CSB/CDL и процедуры их подготовки. На этом уровне решаются задачи чтения исходного массива, сопоставления кодов культур, фильтрации нерелевантных классов и формирования рабочего представления данных. Именно здесь закладывается основа всей последующей системы, поскольку от способа подготовки данных зависит и качество модели, и интерпретируемость результата.

После базовой очистки данные преобразуются из годовых последовательностей в оконную выборку. Каждое наблюдение строится по схеме

$$(\text{history}_1, \text{history}_2, \text{history}_3) \rightarrow \text{target}$$

что позволяет перейти от исходной таблицы по годам к задаче предсказания следующего шага в последовательности культур. На этом же уровне выполняется фильтрация редких целевых классов и фиксируется итоговое пространство культур, с которым далее работают все последующие компоненты системы.

Таким образом, уровень подготовки данных выполняет две основные функции. Во-первых, он делает данные пригодными для машинного обучения. Во-вторых, он задаёт единый и воспроизводимый входной контракт для всех последующих этапов. Это особенно важно, поскольку в работе сравниваются разные подходы, и такое сравнение возможно только при использовании общей, заранее зафиксированной выборки.

3.3 Предиктивное ядро

Центральным элементом архитектуры является предиктивное ядро, задача которого — по истории культур и дополнительным признакам поля оценить вероятности следующих культур. В качестве финальной модели в работе

используется baseline-версия CatBoost. Выбор именно этой модели связан с тем, что задача имеет табличную природу и включает как категориальные, так и числовые признаки. CatBoost в данном случае выступает как основной компонент, извлекающий закономерности из последовательностей культур и контекстных признаков.

На этом уровне система получает на вход:

- историю культур за три предыдущих года;
- региональные признаки;
- площадь поля;
- пространственные координаты.

На выходе модель возвращает вектор вероятностей по целевым классам. Этот результат сам по себе уже позволяет решать задачу top-1 классификации, однако в данной работе он используется шире: как основа для последующего рекомендательного и интерпретационного анализа.

Важно подчеркнуть, что предиктивное ядро в архитектуре отделено от остальных слоёв. Это означает, что confidence-analysis, explainability и пространственная визуализация не заменяют модель и не подменяют её ранжирование, а работают поверх уже рассчитанного модельного результата. Такая декомпозиция делает архитектуру более прозрачной и позволяет отдельно анализировать роль каждого уровня.

3.4 Recommendation layer

Следующий уровень архитектуры связан с переходом от обычной классификации к рекомендательной постановке. Если предиктивная модель возвращает вероятности по всем классам, то recommendation layer преобразует этот результат в ранжированный список кандидатов. На практике это означает, что вместо одного класса система формирует Top-k shortlist наиболее вероятных культур.

В прикладной логике этот переход является принципиальным. Для поддержки принятия решений важен не только наиболее вероятный вариант, но и несколько альтернатив, которые могут быть дополнительно оценены пользователем. Поэтому recommendation layer выполняет не просто техническую

сортировку вероятностей, а переводит модельный выход в формат, удобный для дальнейшего использования.

На данном уровне результат может быть описан как

модельные вероятности → ранжированный список кандидатов

В дальнейшем именно этот shortlist становится основным объектом анализа: для него оценивается качество по метрикам Top-k, для него рассчитываются confidence-сигналы и именно для его элементов формируется explainability-контекст.

3.5 Confidence layer

После формирования shortlist к архитектуре добавляется уровень оценки уверенности. Его задача состоит в том, чтобы различать случаи, где рекомендации модели выглядят более устойчивыми, и случаи, где результат следует интерпретировать осторожнее. Таким образом, confidence layer дополняет сам shortlist информацией о степени надёжности модельного вывода.

С архитектурной точки зрения этот слой использует уже рассчитанные вероятности модели и преобразует их в более прикладной формат. На выходе пользователь получает не только список кандидатов, но и сигнал о том, относится ли случай к более уверенным или менее уверенным рекомендациям. Это важно потому, что одинаковый по форме Top-k результат может иметь разную степень практической надёжности.

Введение confidence layer делает систему ближе к реальному сценарию поддержки принятия решений. Пользователь видит не только, какие культуры предложены моделью, но и насколько устойчивым выглядит данный прогноз. В архитектуре это означает, что предиктивное ядро и recommendation layer дополняются ещё одним уровнем, отвечающим за качество интерпретации результата.

3.6 Explainability layer

Отдельный уровень архитектуры составляет explainability layer, построенный на основе knowledge graph и набора интерпретационных правил. Его

задача не в том, чтобы заменить основную модель или построить альтернативное ранжирование, а в том, чтобы дать пользователю содержательный контекст для анализа shortlist-кандидатов.

Этот слой использует несколько типов информации: переходные закономерности между культурами, укрупнённые группы культур, региональный контекст и набор правил поддержки или предупреждения. На выходе для кандидатов из shortlist формируются дополнительные сигналы, которые позволяют интерпретировать их не только как вероятностные ответы модели, но и как варианты, обладающие определённой степенью согласованности с графовым и rule-based контекстом.

Архитектурно explainability layer расположен **поверх** recommendation layer. Это принципиально важно. В работе knowledge graph не рассматривается как второе предиктивное ядро и не используется как самостоятельная экспертная система. Его роль ограничена интерпретацией уже сформированного shortlist. Иначе говоря, модель отвечает на вопрос, *что рекомендовать*, а explainability-слой помогает ответить на вопрос, *как интерпретировать этот список кандидатов*.

Такое разделение делает общую архитектуру более устойчивой концептуально. Предсказание, уверенность и интерпретация разведены по разным уровням, что позволяет анализировать их независимо и не смешивать вероятностный вывод модели с объяснительным контекстом.

3.7 Пространственный демонстрационный слой

Верхний уровень архитектуры представляет собой spatial demo layer. Его назначение состоит в том, чтобы связать рекомендации с конкретными полями и показать, как результат системы может выглядеть в пользовательском интерфейсе. Этот уровень не влияет на предиктивные свойства модели и не меняет рассчитанные метрики. Его функция — визуальная и аналитическая демонстрация.

Пространственный слой использует геометрию полей или их пространственные представления, а также уже рассчитанные recommendation и explainability результаты. На карте поле становится точкой входа в анализ:

пользователь может выбрать интересующую область, увидеть поля в ней и затем перейти к просмотру рекомендаций и объяснений для конкретного участка.

С архитектурной точки зрения `spatial demo layer` является завершающим представлением результата. Он не создаёт новую модель, а интегрирует все ранее сформированные уровни:

- данные о поле;
- результат предиктивного ядра;
- `shortlist` кандидатов;
- `confidence`-сигнал;
- `explainability`-контекст.

Таким образом, карта выступает не как отдельный вычислительный компонент, а как интерфейсная форма представления уже рассчитанного результата.

3.8 Организация решения

Работа выполнена в формате последовательности Jupyter Notebook, где каждый ноутбук отвечает за отдельный этап исследования: подготовку данных, формирование выборки, обучение моделей, оценку рекомендаций, `explainability`-анализ и пространственную демонстрацию.

Промежуточные результаты сохраняются в виде артефактов. Это позволяет не пересчитывать заново все этапы при каждом изменении, а также использовать уже полученные данные и модели для последующего анализа, визуализации и сравнения результатов.

Такой способ организации удобен для исследовательской работы, поскольку делает процесс поэтапным, воспроизводимым и пригодным для дальнейшего изучения отдельных компонентов системы.

3.9 Итоговая схема архитектуры

В обобщённом виде архитектуру решения можно описать следующим образом:

USDA NASS CSB/CDL

- data preparation
- window dataset
- predictive core
- Top-k recommendation
- confidence analysis
- graph-based explainability
- spatial demo

Такая архитектура отражает основную идею работы: от исторических данных по полям последовательно перейти к рекомендательному результату, а затем дополнить его слоями уверенности, интерпретации и пространственного представления. Благодаря этому система рассматривается не как отдельная модель, а как целостный объяснимый прототип поддержки принятия решений по выбору следующей культуры.

Глава 4. Данные и подготовка выборки

4.1 Источник данных

В работе используются данные **USDA NASS CSB/CDL** за 2017–2024 годы. CDL предоставляет годовые классы культур, а CSB-слой используется как источник полевых идентификаторов, площади и пространственного контекста. Такой набор данных позволяет перейти от анализа отдельных наблюдений к анализу историй использования конкретных полей.

На уровне исходной записи данные содержат:

- идентификатор поля;
- площадь поля;
- региональные признаки;
- пространственные координаты;
- годовые значения культурных классов за несколько последовательных лет.

Использование именно такого источника данных принципиально важно для постановки задачи. В работе исследуется не абстрактная рекомендация

культуры для региона в целом, а рекомендация следующей культуры для конкретного поля с учётом его исторической последовательности.

4.2 Предобработка исходных данных

На первом этапе исходные данные были приведены к виду, пригодному для последующего моделирования. Основная задача предобработки состояла в том, чтобы перейти от исходных CDL-кодов к более интерпретируемому представлению культур и удалить классы, не соответствующие целевой постановке исследования. Для каждого года выполнялось сопоставление кодов с названиями культур и их укрупненными группами. После этого из выборки исключались нерелевантные для задачи классы, например неаграрные или неопределённые категории. Итогом этого этапа стал очищенный датасет `artifacts/data/01_df_prepared_filtered.pkl`.

По метаданным артефакта после базовой очистки выборка имеет следующие характеристики:

- 8 110 870 строк;
- 33 столбца;
- 8 годовых CDL-столбцов.

Предобработка на этом этапе была необходима не только для очистки исходного массива, но и для формирования единообразного представления культур, пригодного для дальнейшего анализа временных последовательностей.

4.3 Формирование оконной выборки

После очистки исходная таблица была преобразована в оконный датасет, который используется для обучения модели. Вместо того чтобы работать с отдельной строкой как с изолированным наблюдением, каждая запись была преобразована в окно вида

$$(\text{history}_1, \text{history}_2, \text{history}_3) \rightarrow \text{target}$$

где `history_1`, `history_2`, `history_3` — последовательность культур за три предыдущих года, а `target` — культура следующего года.

Пример нескольких строк такого представления приведён в таблице 1. В ней видно, что одна строка соответствует одному полю и одному прогнозируемому году: технический идентификатор и пространственно-региональные признаки сохраняют контекст поля, три предыдущих значения культуры используются как входная история, а значение в столбце `target` является следующей культурой, которую должна предсказать модель.

Таблица 1: Пример строк оконного датасета с признаками

CSBID	CSBACRES	STATEFIPS	CNTYFIPS	INSIDE_X	INSIDE_Y	history_1	history_2	history_3	target	target_year
351724000000036	20.942217	35	021	-664007.6193	1.445271·10 ⁶	wheat	wheat	sorghum	sorghum	2020
351724000000037	10.916051	35	021	-664304.1197	1.445202·10 ⁶	wheat	wheat	sorghum	sorghum	2020
351724000000044	17.243968	35	021	-664688.1027	1.445128·10 ⁶	forage_hay	forage_hay	other_cereals	fallow	2020

Таблица показывает технический идентификатор поля, базовые пространственно-региональные признаки, историю культур и целевую культуру следующего года. Источник: сохранённый вывод `window_df.head(3)` в `notebooks/02_window_dataset_and_feature_table.ipynb`.

Такой формат соответствует логике задачи: система должна предсказывать не культуру “вообще”, а следующий шаг в последовательности использования поля. Поскольку в исходных данных доступны годы с 2017 по 2024, из одной исходной записи можно сформировать несколько перекрывающихся окон. В результате полный оконный датасет содержит 40 554 350 строк.

Преимущество такой схемы состоит в том, что она позволяет использовать историю поля как явный вход модели. Тем самым задача переходит от статического анализа признаков к анализу краткой временной последовательности культур.

4.4 Фильтрация редких целевых классов

После построения оконного датасета был выполнен анализ распределения целевой переменной и фильтрация редких `target`-классов. Порог редкости был выбран на уровне 1% от общего числа наблюдений. Такое решение связано с тем, что слишком малые классы создают сильный дисбаланс и затрудняют корректную оценку качества многоклассовой модели.

После фильтрации:

- в выборке осталось 38 511 210 строк;
- итоговое пространство целевых классов было сокращено до 9 культурных классов.

Итоговый набор целевых классов имеет вид:

- corn
- cotton
- fallow
- forage_hay
- legumes
- other_cereals
- sorghum
- soybeans
- wheat

Из выборки были исключены следующие редкие классы:

- oilseeds_other
- sugar_crops
- peanuts
- rice
- root_tubers
- sunflower
- specialty_crops
- vegetables_melons
- fruits_berries

Агрегация и последующая фильтрация целевых классов являются важной частью постановки. С одной стороны, они уменьшают разреженность и дисбаланс данных. С другой стороны, они ограничивают область применимости системы: модель работает не с полным пространством исходных культур, а с устойчивым и интерпретируемым набором укрупнённых целевых классов.

4.5 Разделение на обучающую, валидационную и тестовую выборки

После формирования итоговой выборки было выполнено единое разделение на train, validation и test. Это разделение фиксируется один раз и затем переиспользуется во всех основных этапах работы. Такой подход необходим для воспроизводимости результатов: все модели и все сравнительные эксперименты должны оцениваться на одном и том же разбиении.

Принципиально важно, что split выполняется **group-aware по CSBID**. Это означает, что окна, построенные для одного и того же поля, не должны одновременно попадать в разные части выборки. Такой контракт предотвращает утечку информации между train и test и делает оценку качества более корректной.

Используется `random_state = 42`. Фактические размеры выборок составляют:

- train: 26 957 630 строк;
- validation: 5 776 566 строк;
- test: 5 777 014 строк.

Таблица 2: Размеры выборок на этапах подготовки данных

Этап	Размер, строк	Источник	Комментарий
Prepared dataset	8 110 870	01_meta.json	Очищенная таблица после первичной подготовки данных
Window dataset	40 554 350	02_meta.json	Оконная выборка формата history -> target
Filtered dataset	38 511 210	02_meta.json	Оконная выборка после фильтрации редких target-классов
Train	26 957 630	run_meta.json	Обучающая часть фиксированного group-aware split по CSBID

Этап	Размер, строк	Источник	Комментарий
Validation	5 776 566	run_meta.json	Валидационная часть фиксированного split
Test	5 777 014	run_meta.json	Тестовая часть фиксированного split

Источники значений: artifacts/data/01_meta.json, artifacts/data/02_meta.json, artifacts/results/knowledge_graph_explainability/run_meta.json.

Таким образом, на данном этапе формируется единая воспроизводимая база для всех последующих экспериментов: простых baseline-моделей, CatBoost, recommendation-оценки, confidence-анализа и explainability-слоя.

4.6 Признаки финальной модели

Финальная baseline-модель использует компактный набор признаков, который сочетает краткую историю поля, региональный контекст и базовые характеристики участка. Состав признаков и их типы зафиксированы в метаданных финальной CatBoost-модели и приведены в таблице 3.

Таблица 3: Признаки финальной baseline-модели CatBoost

Признак	Тип	Краткий смысл
history_1	Категориальный	Культура в первом году исторического окна поля
history_2	Категориальный	Культура во втором году исторического окна поля
history_3	Категориальный	Культура в третьем, ближайшем к целевому году исторического окна
STATEFIPS	Категориальный	Код штата, задающий региональный контекст наблюдения
CNTYFIPS	Категориальный	Код округа, задающий более локальный региональный контекст
CSBACRES	Числовой	Площадь поля по данным CSB
INSIDE_X	Числовой	Пространственная координата поля по оси X

Признак	Тип	Краткий смысл
INSIDE_Y	Числовой	Пространственная координата поля по оси Y

Источник состава признаков: `artifacts/catboost/baseline/meta.json`.

Такой набор отражает основную гипотезу работы: следующая культура зависит не только от ближайшего предыдущего состояния, но и от более длинной истории, а также от регионального и пространственного контекста. При этом состав признаков остаётся достаточно компактным, что упрощает воспроизводимость и последующую интерпретацию.

Отдельно в проекте была проверена экспериментальная ветка `improved`, в которой использовались `derived`-признаки истории, например количество уникальных культур, наличие `fallow` или `legumes` в истории и различные индикаторы повторяемости. Однако в итоговой версии работы эта ветка рассматривается как дополнительный эксперимент, а не как финальная модель.

4.7 Выводы по главе

На этапе подготовки данных был сформирован воспроизводимый набор для решения задачи рекомендации следующей культуры по истории поля. Основными результатами этого этапа являются:

- очистка и интерпретация исходных данных USDA NASS CSB/CDL;
- переход от годовых наблюдений к оконной постановке `history -> target`;
- сокращение пространства целевых классов до устойчивого набора из 9 культур;
- фиксированное `group-aware` разделение по CSBID;
- формирование компактного признакового пространства для финальной `baseline`-модели.

Таким образом, подготовка данных создала основу для всех последующих этапов работы: построения `baseline`-моделей, перехода

к Top-k recommendation-постановке, confidence-анализа и explainability-интерпретации результатов.

Глава 5. Базовые модели, промежуточные эксперименты и выбор финальной модели

5.1 Роль baseline-моделей

Построение рекомендательной системы по истории культур требует не только обучения основной модели, но и сравнения её с более простыми ориентирами. Без такого сравнения невозможно понять, действительно ли итоговое качество связано с использованием более содержательной модели, а не достигается за счёт простых частотных закономерностей или инерционных эффектов последовательности.

В данной работе baseline-модели выполняют несколько функций. Во-первых, они задают нижнюю границу качества, с которой можно сопоставлять более сложные методы. Во-вторых, они позволяют проверить, насколько полезными оказываются история поля и дополнительные признаки по сравнению с простыми правилами. В-третьих, baseline-блок помогает обосновать выбор финальной модели не декларативно, а на основе сравнительного анализа.

По этой причине в работе рассматриваются:

- простые baseline-подходы;
- вероятностный baseline Markov-1;
- baseline-модель CatBoost;
- промежуточные экспериментальные ветки.

Такой набор делает выбор итоговой модели методически прозрачным и воспроизводимым.

5.2 Простые baseline-подходы

В качестве простых ориентиров используются два базовых подхода: `most_frequent` и `last_crop`.

5.2.1 Baseline most_frequent

Модель `most_frequent` всегда предсказывает наиболее частый класс в обучающей выборке. Этот подход не использует ни историю конкретного поля, ни региональный контекст, ни пространственные признаки. Его практическая ценность невелика, однако он важен как минимальный ориентир: если более сложная модель не превосходит такой `baseline`, то её использование трудно считать обоснованным.

5.2.2 Baseline last_crop

Модель `last_crop` в качестве следующей культуры выбирает последнюю наблюдаемую культуру в истории поля. В отличие от `most_frequent`, этот `baseline` уже учитывает локальную информацию о поле, но делает это в крайне упрощённой форме. Он отражает инерционный сценарий, в котором предполагается, что следующая культура совпадает с ближайшим предыдущим состоянием.

Сравнение с этим `baseline` особенно важно для рассматриваемой задачи, поскольку в последовательностях культур действительно могут встречаться повторы, а значит, правило последней культуры способно давать нетривиальный результат.

5.3 Markov-1 как вероятностный baseline

Следующий `baseline`-подход строится на одношаговой вероятностной модели переходов между культурами. В этой постановке вероятность следующей культуры зависит только от последней культуры в истории:

$$P(\text{target} \mid \text{history}_3)$$

Такой подход уже не является чисто эвристическим: он использует статистику переходов, наблюдаемую в обучающей выборке. При этом он по-прежнему остаётся ограниченным, поскольку игнорирует более длинную историю поля, а также дополнительные признаки региона и участка.

Markov-1 играет важную роль в работе. С одной стороны, это сильнее, чем наивные `baseline`-стратегии. С другой стороны, он остаётся достаточно

простым и интерпретируемым, чтобы служить честным ориентиром для сравнения с CatBoost. В дальнейшем именно Markov-1 используется как основной baseline для recommendation-сравнения по метрикам Accuracy@1, Hit@3 и Hit@5.

5.4 Baseline CatBoost-модель

Центральным предиктивным компонентом системы является baseline-версия модели CatBoost. Выбор этой модели связан с характером задачи: данные имеют табличную структуру и содержат как категориальные, так и числовые признаки. История культур и региональные коды естественным образом выступают как категориальные признаки, а площадь поля и координаты — как числовой контекст.

Baseline CatBoost использует компактный набор признаков:

- history_1, history_2, history_3;
- STATEFIPS, CNTYFIPS;
- CSBACRES;
- INSIDE_X, INSIDE_Y.

Такой набор отражает основную гипотезу работы: следующая культура определяется не только последней наблюдаемой культурой, но и более длинной историей, а также региональным и пространственным контекстом. При этом baseline-модель остаётся достаточно компактной, чтобы быть воспроизводимой и удобной для последующего анализа.

Финальная baseline-модель на test показывает:

- Accuracy@1 = 0.69901;
- Macro F1 = 0.56849;
- Weighted F1 = 0.68963.

Эти значения показывают, что CatBoost уже на уровне базовой конфигурации существенно превосходит более простые ориентиры. Тем самым baseline-модель становится кандидатом на роль финального предиктивного ядра системы.

5.5 Эксперимент с дополнительными признаками

После построения baseline-модели был проведён отдельный эксперимент с расширением признакового пространства. Цель этого этапа состояла в том, чтобы проверить, может ли модель выиграть от признаков, описывающих структуру истории культур более явно, чем исходные три года истории. Такой эксперимент был реализован в отдельной ветке `05_catboost_improved.ipynb`.

В эксперименте использовались дополнительные derived-признаки, в том числе:

- число уникальных культур в истории;
- наличие `fallow` в истории;
- наличие `legumes` в истории;
- признаки повторяемости соседних лет;
- индикатор полного повтора истории.

Содержательно эта ветка проверяла гипотезу о том, что явное кодирование некоторых паттернов истории может дополнительно усилить модель. Однако по итогам проекта данное направление не было выбрано как основное. Причина состоит не в том, что эксперимент оказался бесполезным, а в том, что он не дал достаточных оснований для смены финального проектного контракта. В результате `improved`-ветка рассматривается как исследовательский эксперимент, полезный для понимания возможных направлений улучшения, но не как финальная модель диплома.

5.6 Эксперимент с CatBoost и transition graph

Следующий промежуточный эксперимент был связан с попыткой усилить ранжирование CatBoost за счёт графового сигнала переходов между культурами. Идея состояла в том, чтобы объединить модельные вероятности и вероятности, полученные из transition graph, по формуле

$$\text{score} = \alpha p_{\text{catboost}} + \beta p_{\text{graph}}$$

где `p_catboost` — вероятность, рассчитанная моделью, а `p_graph` — графовый сигнал переходов. В эксперименте проверялись несколько сочетаний весов: $(0.9, 0.1)$, $(0.8, 0.2)$ и $(0.7, 0.3)$. Лучшим вариантом оказалось соотношение $\alpha = 0.9, \beta = 0.1$.

Однако даже в лучшей конфигурации гибридный вариант на test показал:

- Accuracy = 0.69871;
- Macro F1 = 0.56439;
- Weighted F1 = 0.68873;
- Hit@3 = 0.94956.

Эти значения оказались немного хуже, чем у чистого CatBoost. Следовательно, простой graph reranking не был принят как финальная стратегия. В то же время сам эксперимент имеет важное методическое значение. Он показывает, что графовый сигнал можно интегрировать в модельный pipeline, но в текущей конфигурации его полезнее использовать не как механизм замены ранжирования, а как источник explainability-контекста для shortlist-кандидатов. Именно этот отрицательный результат позже становится важным основанием для архитектурного разведения предиктивного ядра и knowledge graph explainability layer.

Таблица 4: Промежуточные эксперименты и выбор финальной модели

Эксперимент	Что проверялось	Итог
Baseline CatBoost	Компактная модель на признаках истории, региона, площади и координат поля	Выбран. Зафиксирован как активная финальная модель в <code>artifacts/model_registry.json</code> ; на test: Accuracy = 0.699006, Macro F1 = 0.568485, Weighted F1 = 0.689626

Эксперимент	Что проверялось	Итог
CatBoost + extra features	Расширение признакового пространства derived-признаками истории: число уникальных культур, наличие fallow и legumes, признаки повторяемости	Не выбран. На test: Accuracy = 0.699235, Macro F1 = 0.569473, Weighted F1 = 0.689991. Несмотря на близкое качество, ветка сохранена как экспериментальная improved и не заменяет baseline в финальном проектном контракте
CatBoost + transition graph	Гибридное ранжирование по формуле $\text{score} = \alpha p_{\text{catboost}} + \beta p_{\text{graph}}$ с лучшей конфигурацией $\alpha = 0.9, \beta = 0.1$	Не выбран. Лучший hybrid-вариант на test немного уступил чистому CatBoost: Accuracy = 0.698714, Macro F1 = 0.564387, Weighted F1 = 0.688729; graph-сигнал оставлен как explainability layer

Источники: artifacts/model_registry.json, artifacts/catboost/improved/meta.json,
notebooks/05_catboost_improved.ipynb,
artifacts/results/classification_quality/catboost_baseline_metrics.csv,
artifacts/results/graph_hybrid/hybrid_metrics.csv.

Таблица 5: Компактное сравнение CatBoost-экспериментов на test-выборке

Эксперимент	Что проверялось	Accuracy	Macro F1	Weighted F1
Baseline CatBoost	История, регион, площадь и координаты поля	0.699006	0.568485	0.689626
CatBoost + extra features	Расширение признакового пространства: число уникальных культур, наличие fallow и legumes, признаки повторяемости	0.699235	0.569473	0.689991
CatBoost + transition graph	Гибридное ранжирование по формуле $\text{score} = \alpha p_{\text{catboost}} + \beta p_{\text{graph}}$ с лучшей конфигурацией $\alpha = 0.9, \beta = 0.1$	0.698714	0.564387	0.688729

Источники: artifacts/results/classification_quality/catboost_baseline_metrics.csv,
artifacts/catboost/improved/meta.json, artifacts/results/graph_hybrid/hybrid_metrics.csv.

5.7 Сравнение подходов и выбор финальной модели

Сравнение основных baseline-подходов показывает, что CatBoost baseline заметно превосходит простые и вероятностные ориентиры по ключевым классификационным метрикам. Для validation и test были получены результаты, приведённые в таблице 6.

Таблица 6: Сравнение baseline-подходов и финальной CatBoost-модели

Модель	Выборка	Accuracy	Macro F1	Weighted F1
most_frequent	validation	0.305306	0.051977	0.142820
last_crop	validation	0.354267	0.172492	0.361115
markov_1	validation	0.557140	0.411203	0.539053
catboost	validation	0.699281	0.568771	0.689966
most_frequent	test	0.305068	0.051946	0.142623
last_crop	test	0.354321	0.172575	0.361135
markov_1	test	0.557219	0.411371	0.539027
catboost	test	0.699006	0.568485	0.689626

Источник значений:

`artifacts/results/classification_quality/baseline_catboost_comparison_metrics.csv`.

Из этой таблицы следует несколько выводов.

Во-первых, простые baseline-стратегии действительно полезны как ориентиры, но недостаточны как основа рекомендательной системы. Во-вторых, Markov-1 оказывается заметно сильнее наивных эвристик, что подтверждает полезность переходной статистики между культурами. В-третьих, baseline CatBoost устойчиво превосходит все baseline-подходы, что подтверждает полезность трёхлетней истории и контекстных признаков. Наконец, промежуточные эксперименты с дополнительными признаками и с графовым reranking не дали достаточных оснований для отказа от baseline-модели как финального варианта.

Следовательно, именно baseline CatBoost обоснованно выбирается в качестве финального предиктивного ядра системы. Это решение согласуется и с проектным контрактом репозитория, где baseline зафиксирован как основная

модель, а improved и graph-based экспериментальные ветки рассматриваются как non-final направления исследования.

5.8 Выводы по главе

В данной главе были рассмотрены baseline-подходы, промежуточные эксперименты и логика выбора финальной модели. Полученные результаты показывают, что:

- простые baseline-стратегии полезны как нижняя граница качества, но недостаточны как основа системы;
- Markov-1 является сильным интерпретируемым ориентиром, однако уступает модели, использующей более длинную историю и контекстные признаки;
- baseline CatBoost демонстрирует наилучшее качество и поэтому выбран как финальная модель;
- эксперимент с дополнительными признаками и эксперимент с CatBoost + transition graph важны как исследовательские ветки, но не меняют итоговый выбор;
- графовый сигнал оказался полезнее как explainability-компонент, чем как механизм reranking.

Таким образом, к концу данного этапа в работе зафиксировано финальное предиктивное ядро, на основе которого далее строятся recommendation layer, confidence-анализ и explainability-слой.

Глава 6. Recommendation layer и оценка качества

6.1 Переход от классификации к рекомендации

После выбора финальной предиктивной модели следующий шаг состоит в переходе от обычной многоклассовой классификации к рекомендательной постановке. В классификационном режиме модель возвращает наиболее вероятный класс следующей культуры. Однако в прикладном сценарии такой формат не всегда является достаточным. Для специалиста полезнее видеть

не один жёсткий ответ, а несколько наиболее правдоподобных кандидатов, которые можно дополнительно интерпретировать с учётом предметного контекста.

По этой причине в работе выход модели рассматривается в формате **Тор-к рекомендации**. Для каждого поля формируется ранжированный список культур, отсортированных по вероятности, рассчитанной моделью. В наиболее простом виде эта логика может быть записана следующим образом:

модельные вероятности по классам → сортировка → Top-k shortlist

Такая интерпретация позволяет использовать результат модели как основу для поддержки принятия решений. Вместо одного ответа пользователь получает короткий список наиболее вероятных вариантов, что лучше соответствует реальной практике анализа и выбора следующей культуры.

6.2 Метрики рекомендательной постановки

Для оценки качества в рекомендательном режиме в работе используются три основные метрики:

- Accuracy@1
- Hit@3
- Hit@5

Показатель Accuracy@1 совпадает с обычной top-1 accuracy и показывает, в какой доле случаев наиболее вероятная культура совпадает с фактической следующей культурой. Показатель Hit@3 показывает долю наблюдений, в которых истинная культура попадает в первые три позиции ранжированного списка. Аналогично Hit@5 показывает долю наблюдений, в которых правильный класс присутствует в первых пяти рекомендациях.

Содержательно эти метрики позволяют перейти от вопроса *«насколько часто модель угадывает один правильный класс?»* к более прикладному вопросу *«насколько часто правильная культура попадает в короткий список правдоподобных кандидатов?»*

Именно такая постановка является центральной для данной работы.

6.3 Сравнение CatBoost и Markov-1 в рекомендательном режиме

Для проверки того, насколько полезно использование более длинной истории и контекстных признаков, CatBoost сравнивается с Markov-1 baseline в той же рекомендательной постановке. Напомним, что Markov-1 использует только последнюю культуру в истории и оценивает переходы вида:

$$P(\text{target} \mid \text{history}_3)$$

Итоговые значения для CatBoost и Markov-1 на validation и test приведены в таблице 7.

Таблица 7: Сравнение CatBoost и Markov-1 в рекомендательной постановке

Модель	Выборка	Accuracy@1	Hit@3	Hit@5
CatBoost	validation	0.699281	0.951190	0.990794
Markov-1	validation	0.557140	0.855302	0.931781
CatBoost	test	0.699006	0.951236	0.990819
Markov-1	test	0.557219	0.855303	0.931717

Источник значений:

`artifacts/results/recommendation/recommendation_model_comparison_metrics.csv`.

Полученные значения показывают, что даже если ограничиться одной рекомендацией, CatBoost правильно определяет следующую культуру примерно в 70% случаев. Однако более важным является то, что при переходе к shortlist-постановке покрытие резко возрастает: в Top-3 правильная культура попадает примерно в 95% случаев, а в Top-5 — почти в 99% случаев.

С прикладной точки зрения это означает, что модель особенно полезна именно как **shortlist-рекомендатель**. Даже в тех случаях, когда top-1 вариант не совпадает с фактической следующей культурой, правильный класс очень часто присутствует среди нескольких первых кандидатов. Тем самым рекомендательный режим оказывается более естественной формой использования системы, чем жёсткая одновариантная классификация.

Сравнение с CatBoost показывает устойчивое преимущество финальной модели по всем ключевым метрикам:

- по Accuracy@1;
- по Hit@3;
- по Hit@5.

Это означает, что использование трёхлетней истории и дополнительных признаков действительно добавляет полезную информацию по сравнению с моделью, опирающейся только на последнюю культуру. Иными словами, следующая культура определяется не только ближайшим предыдущим состоянием, но и более широким историческим и контекстным окружением.

6.4 Поклассовый анализ качества

Общих метрик недостаточно для полного понимания поведения модели, поэтому в работе дополнительно анализируется качество по отдельным целевым классам. Результаты показывают, что модель работает неравномерно: для части культур top-1 качество является высоким уже в базовой постановке, тогда как для других классов наиболее полезным оказывается именно переход к Top-k рекомендациям.

На test-выборке наиболее устойчивыми классами являются:

- forage_hay
- cotton
- soybeans
- wheat
- corn

Для них recall@1 уже находится на сравнительно высоком уровне, а recall@3 дополнительно возрастает и подтверждает устойчивость shortlist-подхода.

Наиболее сложными классами являются:

- fallow
- sorghum
- other_cereals
- legumes

Именно эти классы особенно важны для анализа в рекомендательной постановке. Например, для `legumes` top-1 качество остаётся низким, однако уже в Top-3 правильный класс попадает существенно чаще. Это показывает, что в сложных случаях полезность системы заключается не столько в однозначном угадывании первой позиции, сколько в способности включить правдоподобную культуру в короткий список альтернатив.

Таким образом, поклассовый анализ подтверждает общий вывод главы: модель особенно сильна не как жёсткий одновариантный классификатор, а как система, формирующая содержательный shortlist вероятных вариантов.

6.5 Интерпретация результатов

С практической точки зрения результаты рекомендательной оценки позволяют сделать несколько важных выводов.

Во-первых, CatBoost baseline даёт достаточно сильный top-1 результат сам по себе. Это означает, что модель может использоваться как качественное предиктивное ядро.

Во-вторых, переход к Top-k постановке существенно повышает прикладную ценность результата. Если в ряде случаев один наиболее вероятный ответ может быть недостаточно надёжным, то короткий список из трёх или пяти кандидатов уже почти всегда содержит фактическую следующую культуру.

В-третьих, сравнение с Markov-1 показывает, что полученное качество нельзя объяснить только статистикой простых переходов между соседними культурами. Существенный прирост CatBoost подтверждает, что модель действительно извлекает дополнительную информацию из более длинной истории и контекстных признаков.

Наконец, поклассовый анализ показывает, что именно рекомендательная постановка позволяет частично компенсировать трудности на менее устойчивых и более сложных классах. Это особенно важно для дальнейших глав, где результат модели будет дополнительно анализироваться через confidence- и explainability-слои.

6.6 Выводы по главе

Переход к рекомендательной постановке является одним из ключевых шагов в работе. Он позволяет рассматривать выход модели не только как top-1 классификацию, но и как shortlist наиболее вероятных следующих культур.

Основные выводы главы состоят в следующем:

- финальная CatBoost-модель демонстрирует высокое качество в Top-k режиме;
- shortlist из трёх и пяти кандидатов существенно повышает прикладную полезность системы;
- CatBoost устойчиво превосходит Markov-1 baseline по всем ключевым рекомендательным метрикам;
- наиболее заметная практическая ценность системы проявляется в сложных случаях, где top-1 ответ может быть недостаточен, но правильная культура остаётся в пределах shortlist.

Тем самым именно рекомендательная постановка задаёт основной прикладной формат всей дальнейшей работы. В следующих разделах модельный shortlist будет дополнен оценкой уверенности и explainability-контекстом, что позволит перейти от простого ранжирования кандидатов к более содержательной системе поддержки принятия решений.

Глава 7. Уверенность рекомендаций и калибровка

7.1 Роль confidence-слоя в рекомендательной системе

После перехода к рекомендательной постановке возникает вопрос не только о том, **какие** культуры попадают в shortlist, но и о том, **насколько надёжно** модель формирует этот список. В прикладном сценарии это особенно важно: два наблюдения могут иметь одинаковый формат выхода в виде Top-k кандидатов, но существенно различаться по степени уверенности модельного вывода. Поэтому в работе поверх recommendation layer вводится дополнительный confidence-слой. Его задача состоит в том, чтобы разделять

случаи на более устойчивые и более спорные и тем самым делать использование рекомендаций более интерпретируемым.

Содержательно confidence-слой не заменяет модель и не формирует новое ранжирование кандидатов. Он использует уже рассчитанные вероятности CatBoost и переводит их в более прикладной формат. В результате пользователь получает не только shortlist культур, но и дополнительный сигнал о том, к какому уровню надёжности относится конкретная рекомендация. Такая логика особенно полезна в задачах поддержки принятия решений, где важно различать ситуации, в которых модель действует на устойчивом статистическом основании, и ситуации, в которых результат следует интерпретировать осторожнее.

В работе используются три confidence-группы:

- high_confidence;
- medium_confidence;
- low_confidence.

Пороговые правила формирования confidence-групп приведены в таблице 8.

Таблица 8: Пороги формирования confidence-групп

Группа	top1_proba	margin_top1_top2
high_confidence	top1_proba >= 0.70	margin_top1_top2 >= 0.25
medium_confidence	top1_proba >= 0.50	0.25 >= margin_top1_top2 >= 0.12
low_confidence	top1_proba < 0.50	margin_top1_top2 <= 0.12

Источник правил: notebooks/07_recommendation_confidence.ipynb (правила high/medium/low confidence).

Тем самым итоговый вывод системы можно описать не только как ранжированный список кандидатов, но и как комбинацию двух компонентов:

shortlist кандидатов + confidence signal

Именно такое представление делает рекомендательный результат ближе к реальному сценарию использования.

7.2 Результаты по confidence-группам

Для test-выборки confidence-слои даёт следующие результаты:

Таблица 9: Качество рекомендаций по confidence-группам на test-выборке

Группа	Число наблюдений	Accuracy@1	Hit@3
high_confidence	3 042 231	0.84147	0.97713
medium_confidence	1 691 260	0.60931	0.94252
low_confidence	1 043 523	0.42902	0.88987

Источник значений: `artifacts/results/recommendation/confidence_summary_baseline.csv`.

Как видно из таблицы, группы действительно различаются по качеству рекомендаций. В зоне `high_confidence` модель показывает наиболее устойчивый результат: top-1 точность превышает 0.84, а правильная культура попадает в Top-3 почти в 98% случаев. В группе `medium_confidence` показатели снижаются, однако остаются высокими для shortlist-постановки. В группе `low_confidence` top-1 точность уже заметно ниже, но даже здесь значение Hit@3 остаётся достаточно высоким. Это означает, что в сложных случаях модель часто ошибается в первой позиции, но всё ещё включает фактическую следующую культуру в число нескольких наиболее вероятных кандидатов.

С практической точки зрения это разделение имеет понятную интерпретацию. В случаях высокой уверенности результат можно рассматривать как сравнительно устойчивую рекомендацию. В случаях средней уверенности пользователь, скорее, получает shortlist, внутри которого целесообразно сравнивать несколько вариантов. В случаях низкой уверенности модельный вывод не следует скрывать, но его правильнее подавать как спорный случай, требующий более осторожной интерпретации и, возможно, дополнительной экспертной проверки. Таким образом, confidence-слой делает рекомендательную систему более информативной, поскольку показывает не только направление рекомендации, но и характер её надёжности.

7.3 Интерпретация confidence-слоя

Полученные результаты показывают, что confidence buckets не являются декоративным дополнением, а действительно отражают различия в качестве модельного вывода. Это важный момент для общей логики работы. Если бы качество в группах high, medium и low различалось слабо, confidence-сигнал не имел бы практического смысла. Однако в рассматриваемой системе наблюдается явная стратификация по надёжности, что подтверждает полезность выделения confidence-слоя как самостоятельного уровня архитектуры.

Особенно важно, что даже в группе low_confidence модель сохраняет полезность именно как рекомендательная система. Низкая уверенность в данном случае не означает, что результат полностью бесполезен; она означает, что top-1 интерпретация недостаточна и что корректнее рассматривать несколько альтернатив одновременно. Это хорошо согласуется с общей постановкой работы: система ориентирована не на выдачу единственного ответа, а на формирование shortlist вероятных вариантов с дополнительным контекстом для их анализа.

7.4 Калибровка вероятностей

Наличие confidence-слоя поднимает ещё один важный вопрос: насколько вероятности, выдаваемые моделью, действительно согласуются с фактической частотой правильных ответов. Для этого в работе дополнительно рассматривается калибровка вероятностей. Если модель хорошо откалибрована, то её confidence-сигналы можно интерпретировать не только как внутренний score ранжирования, но и как более содержательный показатель надёжности.

Для оценки калибровки использовались две стандартные величины:

- ECE (Expected Calibration Error);
- Brier score.

Калибровка анализировалась на preview-выборках по 5000 объектов. Сводные значения для validation и test приведены в таблице 10.

Таблица 10: Калибровочные метрики на preview-выборках

Split	ECE	Brier	Mean confidence	Accuracy@1	Число объектов
validation	0.02305	0.16440	0.75026	0.73560	5 000
test	0.01737	0.16120	0.75398	0.74800	5 000

Источник значений: artifacts/results/recommendation/calibration_metrics_baseline.csv.

Калибровочная кривая для test preview-выборки приведена на рисунке 1. Диагональная линия соответствует идеальной калибровке, а точки показывают соотношение средней уверенности модели и фактической точности внутри интервалов вероятности.




Рис. 1: Reliability diagram для baseline CatBoost на test preview-выборке

Низкие значения ECE указывают на то, что вероятности модели в целом согласованы с фактической точностью на рассматриваемых preview-

выборках. Это не означает идеальную калибровку во всех областях вероятностного пространства, но подтверждает, что confidence-сигнал можно использовать не только для сортировки кандидатов, но и как содержательный показатель уверенности. Значения Brier score также поддерживают вывод о приемлемом качестве вероятностного вывода модели.

7.5 Место confidence-анализа в общей логике работы

С архитектурной точки зрения confidence-слой является естественным продолжением recommendation layer. Сначала модель формирует ранжированный список вероятных культур, затем confidence-анализ показывает, насколько устойчиво этот shortlist выглядит с точки зрения вероятностного вывода. В результате система получает ещё один уровень интерпретации, не связанный напрямую с семантическим объяснением кандидатов, но важный для практического использования.

Это делает confidence-анализ связующим звеном между recommendation-постановкой и explainability-слоем. Recommendation layer отвечает на вопрос, какие кандидаты входят в shortlist. Confidence layer показывает, насколько надёжно этот shortlist сформирован. Далее explainability-слой уже интерпретирует сами кандидаты и их взаимное положение внутри списка. Такое разделение ролей делает общую архитектуру системы более прозрачной и позволяет не смешивать вероятностную надёжность результата с его семантической интерпретацией.

7.6 Выводы по главе

В данной главе было показано, что рекомендательная система должна оцениваться не только по составу shortlist, но и по степени уверенности модельного вывода. Для этого в работе введён confidence-слой, который разделяет случаи на группы high_confidence, medium_confidence и low_confidence. Результаты на test-выборке показывают, что такое разделение действительно отражает различия в качестве рекомендаций: в высокоуверенных случаях модель заметно точнее, а в низкоуверенных случаях сохраняет полезность прежде всего как shortlist-рекомендатель.

Дополнительный анализ калибровки показывает, что вероятности модели в целом согласованы с фактической точностью на preview-выборках. Это усиливает практическую ценность confidence-сигнала и позволяет рассматривать его как самостоятельный компонент системы поддержки принятия решений. Тем самым confidence-слой делает рекомендательный результат более содержательным и подготавливает переход к следующему уровню анализа — explainability через knowledge graph.

Глава 8. Explainability через knowledge graph

8.1 Роль explainability-слоя в работе

После построения предиктивного ядра, рекомендательного слоя и confidence-анализа возникает следующая задача: сделать результат системы более интерпретируемым. В рекомендательной постановке пользователь получает не один ответ, а shortlist вероятных следующих культур. Однако сам по себе ранжированный список вероятностей ещё не даёт содержательного объяснения, почему именно эти кандидаты оказались в верхней части списка и какие факторы поддерживают или ослабляют отдельные варианты. Поэтому в работе поверх модельного результата вводится отдельный explainability-слой на основе knowledge graph.

Важно подчеркнуть, что knowledge graph в данной работе не рассматривается как самостоятельная предиктивная модель и не заменяет CatBoost. Его задача значительно уже: он используется для **семантической интерпретации shortlist-кандидатов**, а не для построения нового основного ранжирования. Иными словами, предиктивное ядро отвечает на вопрос, какие культуры система считает наиболее вероятными, а explainability-слой помогает интерпретировать полученный shortlist и выделить содержательные support- и warning-сигналы для отдельных кандидатов.

Такой подход позволяет избежать смешения двух разных функций. Вероятностный вывод модели и его семантическая интерпретация в работе разведены по разным уровням. Благодаря этому graph-based слой не претендует на роль «источника истины», а выступает как дополнительный инструмент

анализа, помогающий объяснить, насколько тот или иной кандидат согласован с наблюдаемым контекстом.

8.2 Общая структура knowledge graph

Knowledge graph в работе построен как компактное графовое представление сущностей, связанных с задачей рекомендации следующей культуры. По метаданным запуска граф содержит 2827 узлов и 18154 ребра, а также включает 5 интерпретационных правил и набор case studies, используемых для анализа типичных сценариев поведения системы.

В графе используются четыре типа сущностей:

- культуры;
- группы культур;
- регионы;
- правила.

Такая структура позволяет представить не только сами классы целевых культур, но и их более общий контекст. Культуры связываются между собой переходными отношениями, дополнительно привязываются к укрупнённым группам, рассматриваются в региональном контексте и получают интерпретационные сигналы через набор правил. Тем самым knowledge graph выступает как слой предметно-ориентированного представления, который можно использовать для анализа shortlist-кандидатов.

В самом общем виде место графа в архитектуре можно описать как последовательность:

model shortlist → graph/rule context → candidate-level explanation.

Эта логика подчёркивает, что граф не порождает кандидатов сам по себе, а работает с уже полученным списком и дополняет его объяснительным контекстом.

8.3 Типы связей в графе

Структура графа опирается на несколько видов связей. В первую очередь это **переходы между культурами**, построенные по train-only статистике.

Они отражают наблюдаемую частоту перехода от одной культуры к другой и позволяют использовать накопленные последовательности как источник support-сигнала для кандидатов. Кроме того, в граф включены связи принадлежности культуры к укрупнённой группе, а также связи, отражающие типичность культуры для региона. Наконец, отдельный тип связей используется для связывания интерпретационных правил с конкретными кандидатами.

Смысл каждого из этих типов связей различен. Переходные связи показывают, насколько кандидат согласуется с наблюдаемыми историческими закономерностями. Связи с группами культур позволяют анализировать более общий уровень сходства и насыщения. Региональные связи дают дополнительный сигнал о том, является ли культура типичной для рассматриваемого контекста. Связи с правилами фиксируют support- и warning-эффекты, которые используются в explainability-логике. В совокупности это позволяет не сводить анализ к одной числовой вероятности, а рассматривать кандидата в более богатом контексте.

8.4 Rule layer

Отдельный компонент explainability-слоя образует набор правил. В работе используются пять правил; их смысл и тип интерпретационного сигнала приведены в таблице 11.

Таблица 11: Интерпретационные правила knowledge graph

Правило	Смысл	Тип сигнала
repeat_crop_warning	предупреждение, если кандидат повторяет последнюю культуру в истории поля	warning
same_group_saturation	предупреждение, если история насыщена одной группой культур и кандидат относится к той же группе	warning
legume_break_bonus	поддерживающий сигнал для кандидатов из бобовых культур, если в недавней истории не было бобовых	support
fallow_break_effect	поддержка возврата из fallow к культуре или предупреждение при повторном выборе fallow	support / warning
region_typicality	поддерживающий сигнал для культур, типичных для региона по train-only статистике	support

Источник: artifacts/results/knowledge_graph_explainability/kg_rules.csv.

Каждое из них имеет интерпретационную, а не предписывающую функцию. Правила не являются полноценной экспертной агрономической системой и не должны трактоваться как универсальное основание для принятия решения. Их роль состоит в том, чтобы давать **support/warning clues** для анализа shortlist-кандидатов. Поэтому правила в данной работе понимаются не как формализация полной предметной истины, а как ограниченный и интерпретируемый набор семантических сигналов.

Содержательно правила можно разделить на два типа. Первый тип связан с предупреждениями: повтор одной и той же культуры или насыщение последовательности одной группой культур могут рассматриваться как warning-сигналы. Второй тип связан с поддерживающими сигналами: например, legume-based break logic, эффект fallow или региональная типичность культуры могут усиливать интерпретационную поддержку отдельного кандидата. Такое сочетание позволяет анализировать shortlist не только с точки зрения статистического ранжирования, но и с точки зрения более понятной semantic-логики.

8.5 Candidate-level explainability output

Explainability-слой в работе строится на уровне **отдельных кандидатов** из shortlist. Это принципиально важный момент. Граф не объясняет «внутренности» CatBoost напрямую и не интерпретирует веса модели в терминах причинности. Вместо этого для каждого кандидата из Top-k списка собирается набор дополнительных характеристик, описывающих его положение в графовом и rule-based контексте.

Для каждого кандидата формируются следующие элементы explainability-output:

- положение кандидата в ранжированном списке;
- вероятность или score модели;
- принадлежность к укрупнённой группе;
- переходная поддержка;
- региональный сигнал;
- support- и warning-флаги;
- итоговый graph_support_score;
- уровень графовой поддержки.

Тем самым выход explainability-слоя можно описать так:

candidate $\rightarrow$ model score + graph/rule context + short explanation

Такой формат удобен по двум причинам. Во-первых, он сохраняет связь с модельным результатом: каждый кандидат остаётся частью исходного shortlist. Во-вторых, он даёт более содержательный комментарий к каждой позиции в списке. Пользователь видит не только сам факт того, что культура попала в Top-k, но и дополнительный контекст, объясняющий, какие сигналы её поддерживают или ослабляют.

8.6 Graph support score и его интерпретация

Одним из центральных элементов explainability-слоя является graph_support_score. Этот показатель агрегирует несколько типов сигналов: переходную статистику, региональную типичность, поддержку правил и

предупреждения. Тем самым он служит сводной характеристикой того, насколько конкретный кандидат согласован с графовым и rule-based контекстом.

При этом принципиально важно правильно интерпретировать этот score. Он:

- не является вероятностью;
- не должен сравниваться с модельной вероятностью как величина того же типа;
- не доказывает причинную полезность культуры;
- не заменяет основной предиктивный ранг.

Его корректное понимание состоит в следующем: `graph_support_score` показывает, **насколько кандидат согласован с интерпретационным контекстом**, построенным на переходной статистике, региональном сигнале и наборе правил. Это делает score полезным именно как explainability-инструмент, а не как альтернативное ядро решения.

8.7 Согласованность между моделью и explainability-слоем

Для анализа поведения shortlist в работе вводится понятие согласованности между top-1 выбором модели и graph/rule evidence. Это позволяет рассматривать не только положение кандидатов в ранжировании, но и то, насколько первый кандидат модели поддержан explainability-слоем. По итогам case studies были получены случаи с strong и weak alignment; категория medium в данном запуске не появилась, поскольку выбранные кейсы были отнесены только к крайним типам согласованности.

Смысл этой интерпретации заключается не в делении на «правильные» и «неправильные» ответы графа. Например, weak alignment не означает, что модель ошиблась, а граф оказался прав. Он означает более узкую вещь: выбранный top-1 кандидат модели получает относительно слабую поддержку со стороны graph/rule context, тогда как некоторые альтернативы из shortlist могут выглядеть семантически более поддержанными. В прикладной постановке это особенно важно, поскольку показывает, в каких случаях shortlist следует рассматривать внимательнее, а не ограничиваться первой позицией.

Тем самым объяснимый слой выполняет ещё одну функцию: он помогает различать **простые согласованные случаи** и **сложные случаи с конкурирующими альтернативами**. Это усиливает всю рекомендательную постановку работы, поскольку показывает, что полезность shortlist заключается не только в наличии нескольких кандидатов, но и в возможности содержательно сравнивать их между собой.

8.8 Место knowledge graph в общей логике работы

В общей архитектуре системы knowledge graph располагается после recommendation и confidence layers. Сначала модель формирует shortlist наиболее вероятных культур. Затем confidence-слой показывает, насколько надёжно этот shortlist выглядит с точки зрения вероятностного вывода. После этого knowledge graph даёт candidate-level semantic interpretation. Такая последовательность важна концептуально: сначала формируется статистический результат, затем оценивается его надёжность, и только после этого добавляется объяснительный контекст.

Благодаря такому расположению knowledge graph не конфликтует с основной моделью, а дополняет её. Работа тем самым избегает двух крайностей. С одной стороны, результат не остаётся полностью «чёрным ящиком». С другой стороны, explainability-слой не превращается в псевдоэкспертную систему, которая пытается подменить собой модельное ранжирование. Такое архитектурное решение делает весь прототип более устойчивым и методически аккуратным.

8.9 Выводы по главе

В данной главе был рассмотрен explainability-слой системы, построенный на основе knowledge graph и набора интерпретационных правил. Показано, что его назначение состоит не в построении новой предиктивной модели, а в семантической интерпретации shortlist-кандидатов, сформированных CatBoost. Граф объединяет культуры, группы культур, регионы и правила, а на уровне отдельных кандидатов формирует support- и warning-сигналы, итоговый graph_support_score и краткий объяснительный контекст.

Такой подход позволяет дополнить вероятностное ранжирование модельного ядра более содержательной интерпретацией результата. Особенно полезным это оказывается в спорных случаях, где первая позиция shortlist не является единственным правдоподобным вариантом. В таких ситуациях graph-based explainability помогает увидеть, какие альтернативы получают более сильную семантическую поддержку и почему shortlist следует анализировать как набор конкурирующих кандидатов, а не только как top-1 прогноз. Тем самым knowledge graph усиливает работу как explainable recommendation prototype и подготавливает переход к следующей части — анализу case studies и пространственной демонстрации.

Глава 9. Case studies и пространственная демонстрация

9.1 Роль case studies в работе

После построения предиктивного ядра, перехода к рекомендательной постановке, confidence-анализа и explainability-слоя возникает задача показать, как система ведёт себя не только на уровне усреднённых метрик, но и на уровне отдельных наблюдений. Для этого в работе используются case studies — специально отобранные примеры полей, на которых можно последовательно проследить связь между историей культур, результатом модели, уровнем уверенности и графовым интерпретационным контекстом.

Такой формат анализа важен по двум причинам. Во-первых, усреднённые метрики не показывают, как именно shortlist работает в простых и сложных случаях. Во-вторых, explainability-слой по своей природе является локальным: его смысл раскрывается не на уровне общей таблицы результатов, а на уровне конкретного списка кандидатов для конкретного поля. Поэтому case studies в данной работе выступают как естественный способ показать, каким образом предиктивный, confidence- и graph-based слои взаимодействуют между собой.

В проекте были собраны четыре case studies:

- high confidence;
- medium confidence;

- low confidence;
- difficult / disagreement case.

Этот набор позволяет охватить как относительно простые и устойчивые сценарии, так и случаи, где shortlist требует более внимательной интерпретации.

Сводка выбранных case studies приведена в таблице 12. Каждый кейс соответствует одному конкретному наблюдению из тестового фрагмента, для которого известны фактическая следующая культура, Top-3 shortlist модели и candidate-level оценки explainability-слоя. Поэтому далее сравниваются не абстрактные типы ситуаций, а конкретные культуры-кандидаты: например, forage_hay, corn, legumes, soybeans и их альтернативы внутри shortlist.

Таблица 12: Содержательная сводка case studies

Case	Фактическая культура	Top-3 CatBoost	Самый поддерживанный KG кандидат	Статус	Ключевой вывод
High confidence	forage_hay	forage_hay ($p_1 = 0.930$), corn, wheat	forage_hay ($gs = 0.661$)	top-1 верен; target в Top-3; alignment strong	модель и KG согласованы: фактическая культура совпадает с top-1 и имеет сильную графовую поддержку
Medium confidence	corn	corn ($p_1 = 0.669$), soybeans, forage_hay	soybeans ($gs = 0.508$)	top-1 верен; target в Top-3; alignment weak	модель выбирает правильный corn, но KG сильнее поддерживает soybeans; это пример конкурирующей альтернативы внутри shortlist
Low confidence	legumes	legumes ($p_1 = 0.432$), soybeans, fallow	soybeans ($gs = 0.568$)	top-1 верен; target в Top-3; alignment weak	top-1 совпал с target, но модельная уверенность и graph support для него низкие; результат лучше читать как shortlist, а не как жёсткое предписание
Difficult class	soybeans	corn ($p_1 = 0.689$), cotton, soybeans	soybeans ($gs = 0.386$)	top-1 неверен; target в Top-3; alignment weak	фактическая культура не первая, но остаётся в shortlist; KG выделяет её как более семантически поддержанную альтернативу

p_1 — вероятность top-1 кандидата CatBoost; gs — graph_support_score. Источники:

artifacts/results/knowledge_graph_explainability/case_summary.csv,

artifacts/results/knowledge_graph_explainability/case_explanations.csv.

9.2 High confidence case

Первый тип case studies соответствует ситуациям, в которых модель демонстрирует высокий уровень уверенности, а top-1 кандидат выглядит содержательно согласованным с explainability-контекстом. В таких случаях история поля, вероятностный вывод модели и graph-based support обычно не противоречат друг другу. Это наиболее простой сценарий работы системы: shortlist остаётся полезным, но первая позиция уже выглядит достаточно устойчивой.

В рассматриваемом high-confidence кейсе фактической следующей культурой является forage_hay, и CatBoost также ставит forage_hay на первое место с вероятностью 0.930. Knowledge graph не предлагает более сильную альтернативу: наиболее поддержанным кандидатом также остаётся forage_hay. Поэтому этот пример показывает согласованный сценарий, где модельный score, фактический target и graph support сходятся в одной культуре.

С точки зрения интерпретации такой кейс важен потому, что показывает нормальное поведение системы в условиях относительно «чистой» структуры данных. Если поле относится к хорошо распознаваемому паттерну, модель формирует сильный top-1 прогноз, а explainability-слой подтверждает, что выбранный кандидат согласуется с переходной статистикой, региональным контекстом и активными правилами. Для пользователя это означает, что система не просто выдаёт высокий score, но и делает это в достаточно понятной и интерпретируемой ситуации.

9.3 Medium confidence case

Второй тип case studies соответствует случаям средней уверенности. Здесь top-1 кандидат остаётся содержательно правдоподобным, однако shortlist в целом становится более важным, поскольку помимо первой позиции появляются и другие кандидаты, которые могут выглядеть осмысленно с точки зрения истории поля и explainability-контекста.

В medium-confidence кейсе фактической культурой является corn, и модель правильно помещает corn на первую позицию. Однако KG-сигнал сильнее поддерживает альтернативу soybeans: для неё выше

graph_support_score, а в объяснении присутствует поддержка через legume_break_bonus и региональную типичность. Поэтому кейс показывает ситуацию, где top-1 формально верен, но shortlist содержит содержательно конкурирующую альтернативу.

Такой кейс особенно важен для прикладной логики работы. Он показывает, что рекомендательная постановка полезна не только для обработки явных и простых ситуаций, но и для анализа наблюдений, где система не должна ограничиваться одним ответом. В подобных случаях shortlist играет роль пространства разумных альтернатив: модель указывает основное направление, но explainability-слой позволяет рассматривать и соседние варианты как содержательно поддержанные кандидаты.

9.4 Low confidence case

Третий тип case studies связан со случаями низкой уверенности. Именно такие наблюдения особенно хорошо показывают, почему confidence-слой и Top-k постановка являются принципиально важными для всей системы. В low-confidence сценариях top-1 рекомендация может быть недостаточно устойчивой, однако shortlist в целом остаётся полезным, поскольку в нём по-прежнему присутствуют правдоподобные альтернативы.

В low-confidence кейсе фактическая культура — legumes. Модель ставит legumes на первое место, но с заметно меньшей вероятностью 0.432. При этом KG сильнее поддерживает soybeans, то есть близкую по смыслу альтернативу из legume-группы. Такой пример важен именно потому, что top-1 оказался правильным, но его нельзя интерпретировать как устойчивое однозначное решение: confidence и graph support указывают на спорность ситуации.

На уровне explainability это проявляется в том, что graph-based context может поддерживать не только top-1 кандидата, но и одну или несколько альтернатив. Для пользователя это означает, что результат не следует воспринимать как сильное однозначное предписание. Напротив, низкая уверенность должна побуждать рассматривать несколько кандидатов одновременно и использовать дополнительный предметный анализ. Такой кейс хорошо де-

монстрирует, что при слабом модельном сигнале shortlist-подход остаётся более устойчивым форматом вывода, чем жёсткий одновариантный ответ.

9.5 Difficult / disagreement case

Четвёртый тип case studies соответствует наиболее сложным ситуациям, в которых наблюдается напряжение между top-1 выбором модели и explainability-контекстом. Именно такие кейсы позволяют лучше всего показать, зачем в архитектуре вообще нужен graph-based слой. В этих сценариях первая позиция shortlist может не совпадать с наиболее сильно поддержанным графом кандидатом, а фактическая следующая культура может находиться не на первом месте, а среди альтернатив внутри Top-k списка.

В difficult-case примере фактической культурой является soybeans, тогда как top-1 модели — corn с вероятностью 0.689. При этом soybeans всё же присутствует в Top-3 shortlist на третьей позиции и получает более сильную поддержку со стороны KG, чем top-1 кандидат. Именно этот кейс наиболее явно показывает ценность рекомендательной постановки: если смотреть только на top-1, результат является ошибкой, но shortlist и explainability сохраняют полезную информацию о фактическом целевом классе.

Краткая сводка difficult-case в формате case-card приведена в таблице 13.

Таблица 13: Difficult-case: краткая карточка наблюдения

Параметр	Значение
История поля	corn $\rightarrow$ corn $\rightarrow$ cotton
true_target	soybeans
Топ-1 модели / вероятность / уверенность	corn, $p_1 = 0.6887$, medium_confidence
true_target в shortlist	Да
Shortlist (Топ-3)	corn (0.6887), cotton (0.2118), soybeans (0.0835)
Лучший кандидат по graph support	soybeans
Graph support (best candidate)	0.3863
Интерпретация	Сложный кейс: top-1 ошибается, но true_target присутствует в shortlist и сильнее поддержан графом.

Источники: artifacts/results/knowledge_graph_explainability/case_summary.csv,
artifacts/results/knowledge_graph_explainability/case_explanations.csv,
notebooks/09_knowledge_graph_explainability.ipynb.

Интерпретация таких случаев является особенно важной. Они не означают, что модель бесполезна или что граф «лучше» модели. Их смысл заключается в другом: shortlist следует рассматривать как пространство конкурирующих вариантов, где первая позиция не всегда исчерпывает всю полезную информацию. Если explainability-слой сильнее поддерживает альтернативного кандидата, это указывает на спорность ситуации и делает case-level анализ более содержательным. Для задачи поддержки принятия решений такой результат даже важнее, чем ещё один простой случай правильного top-1 прогноза, поскольку он показывает, как система ведёт себя в неоднозначных наблюдениях.

9.6 Общая интерпретация case studies

Рассмотренные case studies позволяют сделать несколько важных выводов. Во-первых, они подтверждают, что система должна интерпретироваться не как одновариантный классификатор, а как рекомендательный прототип, полезность которого особенно проявляется в анализе нескольких кандидатов одновременно. Во-вторых, они показывают, что confidence-слой действитель-

но задаёт различие между более устойчивыми и более спорными рекомендациями. В-третьих, они демонстрируют, что knowledge graph полезен не как замена модели, а как механизм интерпретации shortlist и сравнения кандидатов внутри него.

Таким образом, case studies в работе выполняют не иллюстративную, а аналитическую функцию. Они связывают между собой все уровни системы:

- историю поля;
- модельный shortlist;
- confidence-сигнал;
- graph-based explanation.

9.7 Пространственная демонстрация

Следующим шагом после case-level анализа становится пространственная демонстрация результатов. Её задача состоит в том, чтобы связать рекомендации с конкретными полями и показать, как итоговый результат может быть представлен в пользовательском интерфейсе. Пространственный слой не создаёт новой модели и не влияет на метрики качества. Он выполняет демонстрационную и аналитическую функцию: переносит recommendation и explainability-результаты в карту полей.

В проекте были сформированы несколько spatial artifacts, в том числе:

- `spatial_explainable_demo_map.html`;
- `spatial_bbox_overview_map.html`;
- `spatial_bbox_demo_map.html`;
- `spatial_layer_comparison_summary.csv`;
- `spatial_bbox_selection_summary.csv`.

Эти артефакты используются для того, чтобы показать, как пользователь может перейти от общего spatial context к анализу конкретного поля. В итоговом варианте карта связывает три типа информации:

- геометрическое или пространственное представление поля;
- recommendation output для этого поля;

- explainability-контекст для выбранного кейса.

Иными словами, spatial demo позволяет перевести результат из формата таблиц и локальных графов в более прикладной сценарий визуального анализа.

9.8 Полный spatial context и demo subset

На одном из этапов пространственного анализа было важно понять, не выглядит ли демонстрационная карта искусственно разреженной из-за того, что для показа отбирается только небольшой набор case studies. Для этого был выполнен отдельный анализ spatial layers. Он показал, что полный региональный слой содержит 19 919 полей, а после фильтрации до рабочего пространства из 9 целевых классов сохраняется 16 663 поля, то есть около 83.7% полного слоя. При этом сам демонстрационный subset включает лишь 20 полей.

Этот результат важен для интерпретации spatial demo. Он показывает, что визуальная «разреженность» демо-кейсов связана не с тем, что фильтрация классов разрушила spatial структуру региона, а с тем, что на карте выделяется очень маленький curated subset для explainability-анализа. В финальной логике демонстрации это привело к двухслойной подаче:

- фоновый слой показывает полный filtered spatial context;
- поверх него выделяются demo cases, используемые для подробного анализа.

Такое решение делает карту более содержательной: пользователь видит, что рассматриваемые поля принадлежат плотному сельскохозяйственному региону, а выбранные кейсы являются не случайными точками, а подмножеством общего spatial context.

9.9 Bounding box selection

Для повышения читаемости и удобства демонстрации в работу был добавлен отдельный этап локального spatial selection через bounding box. Его

задача состоит в том, чтобы ограничить карту компактной областью, внутри которой можно удобно анализировать поля и связанные с ними рекомендации. Такой подход полезен не только для презентации, но и для самой логики spatial demo: пользователь работает не со всем регионом сразу, а с локальным фрагментом, где поля визуально сгруппированы и доступны для детального просмотра.

По данным `spatial_bbox_selection_summary.csv`, внутри выбранного bbox-контекста содержится 157 полей, из которых с test-строками сопоставлено 23 поля; итоговый clickable demo dataset также содержит 23 поля. Это означает, что bounding box selection позволяет перейти от общего spatial context к более компактному и управляемому пространственному подмножеству, не теряя при этом связки между полем, рекомендацией и explainability-контекстом.

С архитектурной точки зрения bounding box selection не меняет саму систему рекомендаций. Он лишь добавляет spatial filtering mechanism, который делает демонстрацию более наглядной и ближе к реальному пользовательскому сценарию. Благодаря этому пространственная часть работы воспринимается не как отдельный GIS-эксперимент, а как естественное продолжение explainable recommendation prototype.

9.10 Место spatial demo в общей работе

Пространственная демонстрация завершает прикладную часть исследования. Если предыдущие главы были сосредоточены на данных, модели, recommendation-логике, confidence и explainability, то spatial demo показывает, как эти результаты могут быть представлены в интерфейсе, ориентированном на работу с конкретными полями. Это особенно важно для дипломной работы, поскольку позволяет продемонстрировать не только качество модели как таковой, но и форму её практического использования.

При этом spatial demo не изменяет основной научный вывод работы. Финальным предиктивным ядром остаётся baseline CatBoost, а карта и bbox-selection выступают как интерфейсно-аналитические надстройки. Их роль заключается в том, чтобы сделать recommendation и explainability-результаты

более наглядными и пригодными для визуального анализа.

9.11 Выводы по главе

В данной главе были рассмотрены case studies и пространственная демонстрация результатов. Case studies показали, как система ведёт себя в различных типах наблюдений — от простых high-confidence случаев до сложных disagreement-сценариев. Это подтвердило, что полезность системы заключается не только в top-1 предсказании, но и в возможности анализировать shortlist кандидатов с учётом confidence- и graph-based сигналов.

Пространственная демонстрация дополнила эту логику визуальным уровнем представления. Она позволила связать рекомендации с геометрией полей, выделить demo cases на фоне полного filtered spatial context и организовать локальный анализ через bounding box selection. В результате итоговая система может рассматриваться не только как модель и набор метрик, но и как целостный explainable recommendation prototype, для которого предусмотрен наглядный сценарий пользовательской работы.

Глава 10. Ограничения и направления развития

10.1 Ограничения текущей версии системы

Несмотря на полученные результаты, разработанную систему следует рассматривать как исследовательский прототип с ограниченной областью применимости. Эти ограничения связаны как с природой исходных данных, так и с выбранной постановкой задачи, архитектурой решения и способом интерпретации результатов. Их явное указание важно для корректной оценки вклада работы и для понимания того, в каких границах полученные выводы остаются обоснованными.

10.1.1 Ограниченность постановки задачи

Прежде всего, система не является полноценным оптимизатором севооборота. В работе решается более узкая задача: по истории культур на конкретном поле и базовым признакам формируется ранжированный список

вероятных следующих культур. Такой подход полезен как инструмент поддержки принятия решений, однако он не охватывает весь набор факторов, влияющих на выбор культуры в реальном хозяйстве. В частности, в текущей постановке не учитываются:

- экономические показатели;
- погодные сценарии и сезонные прогнозы;
- почвенные ограничения;
- логистические и ресурсные ограничения хозяйства;
- многолетнее планирование на уровне севооборотной схемы.

Следовательно, даже качественный shortlist не должен интерпретироваться как окончательное или гарантированно оптимальное решение. Корректнее рассматривать его как набор вероятных и содержательно интерпретируемых вариантов, которые могут быть использованы специалистом как исходная база для дальнейшего анализа.

10.1.2 Ограничения, связанные с данными

Существенное ограничение связано с используемым пространством целевых классов. После агрегации и фильтрации редких культур модель обучается и оценивается на наборе из девяти классов. Такое решение было необходимо для стабилизации постановки и для уменьшения дисбаланса классов, однако оно сокращает полноту исходного пространства культур. В результате система не охватывает редкие и специализированные случаи, присутствующие в исходных данных.

Кроме того, модель опирается на исторические закономерности, наблюдаемые в имеющихся последовательностях культур. Это означает, что качество рекомендаций зависит от структуры и покрытия исходного датасета. Если для определённых типов полей, регионов или культур исторических наблюдений недостаточно, то и модельный результат для них будет менее устойчивым. В этом смысле система лучше работает в пространстве часто встречающихся и хорошо представленных паттернов, чем в редких или нетипичных сценариях.

10.1.3 Ограничения предиктивного ядра

Хотя baseline CatBoost показывает сильный результат в Top-k постановке, сама модель остаётся статистическим инструментом, извлекающим зависимости из данных. Она не обладает причинным пониманием агрономической полезности культуры и не может интерпретировать свои рекомендации как агрономические правила. Это означает, что высокий модельный score следует понимать как отражение наблюдаемой закономерности в данных, а не как доказательство того, что данная культура объективно является наилучшей с агрономической точки зрения.

Кроме того, качество модели неодинаково по классам. Для части культур top-1 качество высоко уже в базовой постановке, тогда как для более сложных классов полезность системы проявляется главным образом в формате shortlist. Это ограничивает интерпретацию результата: в некоторых случаях система может быть надёжна уже как top-1 предиктор, но в других корректнее использовать её именно как рекомендательную, а не классификационную систему.

10.1.4 Ограничения explainability-слоя

Knowledge graph и rule-based слой в данной работе играют интерпретационную, а не предиктивную роль. Это важное достоинство с точки зрения прозрачности архитектуры, но одновременно и ограничение. Explainability-слой:

- не является причинной моделью;
- не доказывает агрономическую обоснованность кандидата;
- не должен трактоваться как независимая экспертная система;
- опирается на компактный набор интерпретационных правил.

Следовательно, graph-based explanation не следует понимать как окончательное объяснение «почему именно эта культура правильна». Он даёт лишь дополнительный семантический контекст для анализа shortlist-кандидатов и позволяет различать более и менее поддержанные альтернативы. Такой уро-

вень интерпретации полезен для задачи поддержки принятия решений, но он не заменяет предметную экспертную оценку.

10.1.5 Ограничения пространственной демонстрации

Spatial demo и bounding box selection также имеют ограниченный характер. Они не являются отдельной рекомендательной системой и не создают новую модель; их функция состоит в визуализации и демонстрации уже рассчитанных результатов. Пространственная карта показывает, как recommendation- и explainability-слои могут быть встроены в пользовательский интерфейс, однако сама по себе она не расширяет предиктивные возможности системы. Поэтому spatial demo следует рассматривать как презентационно-аналитический слой, а не как отдельный объект оценки качества.

10.2 Направления дальнейшего развития

Несмотря на перечисленные ограничения, полученный прототип задаёт несколько естественных направлений дальнейшего развития. Эти направления связаны не с полной перестройкой работы, а с логичным расширением уже построенного контура.

10.2.1 Расширение контекстных признаков

Одним из наиболее очевидных направлений является добавление новых признаков, отражающих внешний контекст выбора культуры. В первую очередь к таким признакам можно отнести:

- климатические характеристики;
- почвенные признаки;
- дополнительные региональные агрономические показатели;
- экономические ограничения и предпочтения.

В текущей работе подобные источники сознательно не включались в основную постановку, чтобы сохранить воспроизводимость и управляемую

сложность модели. Однако в дальнейшем их использование может усилить прикладную значимость системы и приблизить её к более реалистичным decision-support сценариям.

10.2.2 Развитие confidence-анализа

Ещё одним направлением развития может стать более глубокая работа с оценкой уверенности. В текущей версии confidence-слой уже показывает, что случаи естественным образом разделяются по уровню надёжности. Однако возможны более детальные исследования, например:

- уточнение confidence calibration;
- анализ confidence по отдельным классам и регионам;
- построение более формальных uncertainty-aware процедур для shortlist-вывода.

Такое развитие позволило бы сделать confidence-компонент не просто полезным дополнением, а более формализованной частью рекомендательной системы.

10.2.3 Развитие explainability-слоя

Knowledge graph в текущей версии уже выполняет роль семантического explainability-слоя, однако его можно развивать в нескольких направлениях. Во-первых, возможно расширение набора интерпретационных правил. Во-вторых, можно усложнить сам графовый контекст за счёт введения новых типов сущностей и связей. В-третьих, перспективным представляется сценарий **expert-in-the-loop**, в котором пользователь или предметный специалист может корректировать отдельные rule-based сигналы и анализировать, как это влияет на интерпретацию shortlist-кандидатов.

Такое развитие особенно интересно потому, что оно усиливает именно explainability-компонент работы, не превращая систему в полноценную экспертную базу знаний. В результате graph-based слой может стать более гибким и более полезным с точки зрения пользовательского анализа сложных кейсов.

10.2.4 Развитие пространственного интерфейса

Пространственная демонстрация уже показывает, как рекомендации могут быть связаны с полями на карте, однако она пока остаётся исследовательским демо-интерфейсом. В дальнейшем пространственный слой можно развивать как более полноценный пользовательский инструмент. Возможные направления здесь включают:

- расширение сценариев spatial filtering;
- более удобную навигацию по регионам и полям;
- richer interaction between map, case card and explainability graph;
- интеграцию пространственного интерфейса с rule-based пользовательскими настройками.

Такое развитие сделало бы систему ближе к полноценному интерфейсу поддержки принятия решений, сохранив при этом уже построенное предиктивное и explainability-ядро.

10.3 Итоговые замечания по ограничениям и развитию

Перечисленные ограничения не обесценивают полученные результаты, а задают корректные границы их интерпретации. Разработанная система не претендует на роль полного агрономического оптимизатора, однако в своей целевой постановке она решает содержательную и практически значимую задачу: формирует shortlist вероятных следующих культур, сопровождает его confidence-сигналом и дополняет интерпретируемым explainability-контекстом.

Направления дальнейшего развития показывают, что работа может быть расширена как в сторону усиления предиктивного контекста, так и в сторону развития explainability и интерфейсной части. При этом уже в текущем виде прототип демонстрирует целостный контур решения и может рассматриваться как основа для дальнейших исследовательских и прикладных продолже-

Заключение

В дипломной работе была рассмотрена задача рекомендации следующей культуры для конкретного сельскохозяйственного поля на основе его исторической последовательности использования и базовых признаков поля и региона. Работа изначально строилась не как попытка создать полный оптимизатор севооборота, а как исследовательский прототип объяснимой рекомендательной системы, ориентированной на поддержку принятия решений. Такой выбор постановки позволил сосредоточиться на построении воспроизводимого контура анализа, в котором сочетаются предиктивное ядро, рекомендательный режим, оценка уверенности и интерпретационный слой.

В ходе работы были подготовлены и структурированы данные USDA NASS CSB/CDL, выполнено сопоставление и укрупнение культурных классов, построена оконная выборка вида `history_1`, `history_2`, `history_3` -> `target`, а также зафиксировано воспроизводимое разделение данных на обучающую, валидационную и тестовую выборки. Это позволило сформировать единую основу для всех последующих этапов исследования и обеспечить корректное сравнение различных подходов.

На этапе моделирования были рассмотрены простые baseline-стратегии, вероятностный ориентир Markov-1 и модель CatBoost. Сравнение показало, что финальная baseline-модель CatBoost заметно превосходит более простые подходы по основным классификационным и рекомендательным метрикам. Это подтвердило, что использование трёхлетней истории и контекстных признаков даёт существенный прирост качества по сравнению с моделями, опирающимися только на частотные или одношаговые переходные закономерности.

Одним из ключевых результатов работы стал переход от обычной многоклассовой классификации к рекомендательной постановке. Было показано, что наиболее естественным прикладным форматом использования модели является не top-1 предсказание, а Top-k shortlist вероятных следующих культур. Полученные результаты продемонстрировали, что даже в тех случаях, когда первая рекомендация оказывается недостаточно точной, правильный класс часто присутствует в числе нескольких наиболее вероятных кандидатов. Это позволяет рассматривать систему именно как рекомендательный инструмент, а не как жёсткий одновариантный классификатор.

Важной частью работы стал confidence-анализ. Введение confidence-

слоя позволило показать, что рекомендации модели неоднородны по степени надёжности и естественным образом разделяются на более устойчивые и более спорные случаи. Анализ показал, что в группе высокой уверенности модель существенно точнее, чем в среднем по выборке, а в случаях низкой уверенности сохраняет практическую полезность прежде всего как shortlist-рекомендатель. Дополнительный анализ калибровки подтвердил, что вероятности модели могут использоваться не только для ранжирования кандидатов, но и как содержательный confidence-сигнал.

Следующим значимым результатом стало построение explainability-слоя на основе knowledge graph и набора интерпретационных правил. В работе показано, что knowledge graph целесообразно использовать не как вторую предиктивную модель и не как полноценную экспертную систему, а как семантический слой для интерпретации shortlist-кандидатов. Такой подход позволил дополнить модельный вывод support- и warning-сигналами, графовой поддержкой и кратким объяснительным контекстом. Особенно важным это оказалось для сложных и неоднозначных случаев, в которых полезность shortlist проявляется сильнее всего.

Для демонстрации практического сценария использования результатов был разработан пространственный демонстрационный слой. Он связал рекомендации и explainability-контекст с конкретными полями на карте и показал, как модельный результат может быть представлен в форме пользовательского интерфейса. При этом spatial demo не изменяет предиктивное ядро системы, а выступает как аналитическая и интерфейсная надстройка, делающая результаты более наглядными и удобными для интерпретации.

Таким образом, в работе был построен целостный воспроизводимый прототип рекомендательной системы по севообороту, включающий:

- подготовку данных и построение временной выборки;
- baseline-сравнение моделей;
- финальное предиктивное ядро на основе CatBoost;
- рекомендательный Top-k режим;
- confidence-layer;
- explainability-слой на основе knowledge graph;

- пространственную демонстрацию результатов.

Основной итог работы состоит в том, что задача выбора следующей культуры может быть продуктивно рассмотрена в формате *explainable recommendation / decision-support prototype*. В этой постановке система не подменяет экспертное решение, но помогает пользователю анализировать вероятные варианты, видеть уровень уверенности модели и получать интерпретируемый контекст для *shortlist*-кандидатов. Именно в таком виде разработанный прототип представляет практический и исследовательский интерес.

В качестве направлений дальнейшего развития могут рассматриваться расширение признакового пространства за счёт внешних агрономических факторов, углубление *confidence*-анализа, развитие *knowledge graph* и правил интерпретации, а также дальнейшее развитие пространственного интерфейса. Однако даже в текущем виде работа демонстрирует завершённый и методически согласованный контур решения, достаточный для того, чтобы рассматривать её как полноценный результат дипломного исследования.

Список литературы

- [1] *Fruchtfolge: A crop rotation decision support system for optimizing cropping choices with big data and spatially explicit modeling*. Computers and Electronics in Agriculture, 2021.
- [2] *A Decision Support System for Crop Recommendation Using Machine Learning Classification Algorithms*. Agriculture, 2024.
- [3] *A review of visualisations in agricultural decision support systems: An HCI perspective*. Computers and Electronics in Agriculture.
- [4] *C3PO: a crop planning and production process ontology and knowledge graph*. Frontiers in Artificial Intelligence, 2023.
- [5] *Enhancing crop recommendation systems with explainable artificial intelligence: a study on agricultural decision-making*. Neural Computing and Applications, 2024.
- [6] John Deere Operations Center — официальный сайт продукта.
- [7] xarvio FIELD MANAGER — официальный сайт продукта.