

САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ

Направление: 02.04.02 «Фундаментальная информатика и информационные технологии»

ОП: Технологии искусственного интеллекта и Big Data

**ОТЧЕТ
О НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ ПРАКТИКЕ**

Тема задания: Разработка рекомендательной системы севооборота

Выполнил: Корельский Дмитрий Сергеевич
номер группы: 24.М11-пу

Руководитель практики:
Митрофанов Евгений Павлович
доцент кафедры «Технологии программирования»

Санкт-Петербург
2026

Содержание отчета

Содержание

1	Введение и цель практики	2
2	Постановка задачи	2
3	Данные и подготовка выборки	3
3.1	Источник данных	3
3.2	Предобработка и оконное представление	4
3.3	Фильтрация классов и split	5
4	Формирование признаков и frozen split	7
5	Базовые методы и выбор финальной модели	8
5.1	Baseline-подходы	8
5.2	Финальная baseline-модель CatBoost	8
6	Эксперимент CatBoost + transition graph	9
7	Заключение	11

1 Введение и цель практики

Производственная практика была посвящена анализу и систематизации результатов проекта по разработке рекомендательной системы выбора следующей культуры в севообороте. Практическая цель состояла не в создании полного агрономического оптимизатора, а в построении объяснимого рекомендательного прототипа, который по истории конкретного поля и базовому региональному контексту формирует краткий список вероятных следующих культур.

Актуальность рассматриваемой темы связана с тем, что задача выбора следующей культуры в севообороте на практике редко сводится к одному простому правилу. На решение одновременно влияют история конкретного поля, особенности региона, накопленные переходные закономерности между культурами и необходимость интерпретировать полученный результат. В этих условиях особенно полезен не жесткий автоматический выбор одной культуры, а инструмент, который помогает сузить пространство вариантов и показать наиболее правдоподобные кандидаты.

В ходе практики решались три взаимосвязанные задачи. Во-первых, необходимо было построить и проверить воспроизводимость исследовательского пайплайна: от предобработки данных до выбора финальной модели. Во-вторых, требовалось последовательно описать ключевые этапы работы и полученные результаты. В-третьих, важно было представить результаты в форме, пригодной для последовательного анализа и обсуждения.

Содержательно работа была сосредоточена на тех этапах проекта, которые формируют основное предиктивное ядро: подготовке данных, построении оконной выборки, сравнении простых и вероятностных baseline-подходов, обучении baseline-модели CatBoost и проверке промежуточной гипотезы о возможности улучшить результат с помощью графового сигнала переходов. Такое ограничение по содержанию позволяет сохранить целостность отчета и при этом показать логику выбора финальной модели.

Источник фактов и метрик: текущие материалы проекта и связанные текстовые материалы репозитория.

2 Постановка задачи

Рассматриваемая задача формулируется как рекомендация следующей культуры по краткой истории использования поля. Для каждого поля используются культуры за три предыдущих года и набор контекстных признаков:

$$(\text{history}_1, \text{history}_2, \text{history}_3, x) \rightarrow \text{target},$$

где `history_1`, `history_2`, `history_3` обозначают последовательность культур, а `x` включает региональные и пространственные признаки поля. В отличие от обычной

top-1 классификации, в проекте важен рекомендательный режим: модель должна не только предсказать наиболее вероятную культуру, но и сформировать содержательный список кандидатов.

Такая постановка принципиально отличается от полной задачи планирования севооборота. Полный оптимизационный подход требует учитывать большее число ограничений: экономику хозяйства, свойства почвы, погодные факторы, ресурсы техники, долгосрочные агротехнические ограничения и многие другие параметры. В данном проекте такая всеобъемлющая постановка сознательно не ставится. Вместо этого исследуется более узкая, но практически полезная задача: по уже имеющимся историческим данным поля сформировать правдоподобную рекомендацию следующего шага.

Именно поэтому отчет использует формулировку «прототип поддержки принятия решений». В этом режиме система не подменяет специалиста и не обещает гарантированно оптимальный выбор. Ее цель состоит в том, чтобы:

- структурировать историческую информацию о поле;
- оценить вероятности возможных следующих культур;
- показать, насколько модель выигрывает у простых ориентиров;
- дать основу для дальнейшей интерпретации полученного результата.

На уровне архитектуры рассматриваемый фрагмент работы можно представить как переход от исходных данных через подготовку и обучение модели к итоговому предиктивному ядру. Эта логика отражена на рисунке 1.

В рамках практического отчета акцент сделан именно на этом ядре решения: подготовке данных, выборе baseline-модели и проверке исследовательской гипотезы о возможности усиления CatBoost графовым сигналом переходов между культурами.

3 Данные и подготовка выборки

3.1 Источник данных

В работе используются данные **USDA NASS CSB/CDL** за 2017–2024 годы. Слой CDL предоставляет годовые классы культур, а CSB служит источником идентификаторов полей, площади и пространственного контекста. Такой источник данных позволяет перейти от абстрактной региональной классификации к анализу последовательностей использования конкретных полей.

Практическая ценность такого набора данных состоит в том, что он соединяет два вида информации. С одной стороны, доступны последовательности культур по годам, а значит, можно анализировать смену культур во времени. С другой стороны,




Рис. 1: Общая схема исследовательского решения

сохраняется привязка к конкретным полям и регионам, что позволяет не терять пространственный контекст наблюдений. Для задачи рекомендации следующей культуры это существенно: одинаковая история может интерпретироваться по-разному в зависимости от масштаба и положения поля.

3.2 Предобработка и оконное представление

На первом этапе исходные записи были приведены к интерпретируемому виду: CDL-коды культур сопоставлялись с названиями и укрупненными группами, после чего из выборки исключались нерелевантные для задачи категории. После базовой очистки подготовленный датасет содержит 8 110 870 строк.

Следующий этап заключался в преобразовании годовых последовательностей в оконное представление вида `history_1, history_2, history_3 -> target`. Благодаря этому одна исходная история поля порождает несколько перекрывающихся обучающих окон, а задача приобретает форму предсказания следующего шага в последовательности культур. Полный window dataset содержит 40 554 350 строк.

Смысл этого преобразования состоит в том, что модель начинает работать не с отдельным годом как изолированным наблюдением, а с короткой историей. Для каждого окна фиксируются три предыдущих значения культур и одна следующая культура, которую необходимо предсказать. В результате появляется естественная учебная постановка, близкая к задаче рекомендовать следующий элемент последовательности. Схема

такого преобразования показана на рисунке 2.

CSBID	CSBACRES	STATEFIPS	CNTYFIPS	INSIDE_X	INSIDE_Y	history_1	history_2	history_3	target	target_year
351724000000036	20.942217	35	021	-664007.6193	1.445271·10 ⁶	wheat	wheat	sorghum	sorghum	2020
351724000000037	10.916051	35	021	-664304.1197	1.445202·10 ⁶	wheat	wheat	sorghum	sorghum	2020
351724000000044	17.243968	35	021	-664688.1027	1.445128·10 ⁶	forage_hay	forage_hay	other_cereals	fallow	2020

Рис. 2: Переход от годовых наблюдений к оконной постановке

Этот шаг особенно важен для всей дальнейшей работы, потому что именно он связывает предметную постановку с формой, пригодной для машинного обучения. Если бы модель использовала только последний год, она сильнее напоминала бы простую модель переходов. Использование трехлетней истории позволяет учесть более длинные паттерны повторяемости и смены культур.

3.3 Фильтрация классов и split

Для стабилизации многоклассовой постановки редкие целевые классы были отфильтрованы, и итоговое пространство целей было сокращено до 9 культурных классов: `corn`, `cotton`, `fallow`, `forage_hay`, `legumes`, `other_cereals`, `sorghum`, `soybeans`, `wheat`. После фильтрации в выборке осталось 38 511 210 строк.

Фильтрация редких целевых классов была необходима не только для уменьшения дисбаланса, но и для сохранения устойчивой области применимости модели. Если оставить все исходные классы, то значительная часть из них будет представлена слишком малым числом наблюдений, что делает сравнительный анализ менее надежным и ухудшает интерпретируемость результатов. В результате проект сознательно сосредоточен на устойчивом наборе классов, который достаточно широко представлен в данных.

Разделение на обучающую, валидационную и тестовую выборки было выполнено как **group-aware split по CSBID**. Это означает, что окна, относящиеся к одному и тому же полю, не попадают одновременно в разные части выборки, что уменьшает риск утечки информации. Используется фиксированное значение `random_state=42`. Итоговые размеры выборок составляют 26 957 630 строк для `train`, 5 776 566 для `validation` и 5 777 014 для `test`.

Именно здесь формируется один из ключевых контрактов проекта. Если бы окна одного и того же поля оказались и в обучении, и в тесте, то итоговая оценка качества была бы завышенной: модель частично «узнавала» бы уже виденные истории. Групповое разбиение по `CSBID` устраняет этот риск и делает дальнейшее сравнение моделей методически корректным. Визуально структура такого разбиения приведена на рисунке 3.

Таблица 1: Ключевые размеры выборок на этапах подготовки данных

Этап	Размер, строк	Источник	Комментарий
Подготовленный датасет	8 110 870	01_meta.json	Таблица после первичной очистки и приведения культурных кодов к рабочему виду
Оконный датасет	40 554 350	02_meta.json	Набор формата history_1, history_2, history_3 -> target
Итоговый датасет после фильтрации	38 511 210	02_meta.json	Оконная выборка после исключения редких целевых классов
Train	26 957 630	служебные метаданные проекта	Обучающая часть фиксированного разбиения по CSBID
Validation	5 776 566	служебные метаданные проекта	Валидационная часть того же разбиения
Test	5 777 014	служебные метаданные проекта	Тестовая часть того же разбиения

Этап	Размер, строк	Источник	Комментарий
Prepared dataset	8 110 870	01_meta.json	Очищенная таблица после первичной подготовки данных
Window dataset	40 554 350	02_meta.json	Оконная выборка формата history -> target
Filtered dataset	38 511 210	02_meta.json	Оконная выборка после фильтрации редких target-классов
Train	26 957 630	run_meta.json	Обучающая часть фиксированного group-aware split по CSBID
Validation	5 776 566	run_meta.json	Валидационная часть фиксированного split
Test	5 777 014	run_meta.json	Тестовая часть фиксированного split

Рис. 3: Схема фиксированного разбиения выборки

4 Формирование признаков и frozen split

Финальная baseline-модель использует компактный и интерпретируемый набор признаков:

- история культур за три предыдущих года: `history_1`, `history_2`, `history_3`;
- региональные признаки: `STATEFIPS`, `CNTYFIPS`;
- характеристики поля: `CSBACRES`;
- пространственный контекст: `INSIDE_X`, `INSIDE_Y`.

Такой набор признаков отражает основную гипотезу проекта: следующая культура зависит не только от последней культуры, но и от более длинной локальной истории, а также от региона и базовых пространственных характеристик участка. При этом признаки остаются достаточно простыми, чтобы пайплайн был воспроизводимым и удобным для дальнейшего сравнения с baseline-подходами.

Каждый из этих признаков играет отдельную роль. Исторические признаки дают модели информацию о последовательности смены культур. Региональные коды помогают учитывать различия между территориями, которые могут быть связаны с региональной специализацией и сложившимися паттернами возделывания. Площадь поля позволяет модели использовать очень грубую, но полезную характеристику масштаба участка. Пространственные координаты дополняют региональный контекст более непрерывным описанием положения поля.

Таблица 2: Признаки финальной baseline-модели CatBoost

Признак	Тип	Смысл
<code>history_1</code>	категориальный	Культура в первом году исторического окна поля
<code>history_2</code>	категориальный	Культура во втором году исторического окна поля
<code>history_3</code>	категориальный	Культура в ближайшем к целевому году исторического окна
<code>STATEFIPS</code>	категориальный	Код штата как общий региональный контекст
<code>CNTYFIPS</code>	категориальный	Код округа как более локальный региональный контекст
<code>CSBACRES</code>	числовой	Площадь поля по данным CSB
<code>INSIDE_X</code>	числовой	Пространственная координата поля по оси X
<code>INSIDE_Y</code>	числовой	Пространственная координата поля по оси Y

Зафиксированное разбиение по `CSBID` является важной частью исследовательского контракта. Благодаря frozen split все модели и эксперименты оцениваются на одном и том же разделении данных, а сравнение baseline-подходов, CatBoost и graph-гибрида

остаётся корректным. Фиксация `random_state=42` здесь также важна: она гарантирует, что при повторном обращении к этим этапам сохраняется одна и та же логика разбиения, а результаты разных моделей сопоставимы не только содержательно, но и технически.

Таким образом, на данном этапе формируется компактное, но устойчивое представление задачи. Оно достаточно информативно для обучения модели и достаточно прозрачно для анализа, что особенно важно в исследовательском контексте практического отчета.

5 Базовые методы и выбор финальной модели

5.1 Baseline-подходы

До перехода к CatBoost были рассмотрены несколько ориентировочных baseline-моделей. Стратегия `most_frequent` всегда выбирает самый частый класс обучающей выборки и задает нижнюю границу качества. Стратегия `last_crop` повторяет последнюю наблюдаемую культуру в истории поля и позволяет оценить, насколько полезен простой инерционный сценарий.

Дополнительно использовался вероятностный baseline `Markov-1`, основанный на одношаговой модели переходов:

$$P(\text{target} \mid \text{history}_3).$$

Этот подход уже учитывает статистику переходов между культурами, но по-прежнему игнорирует более длинную историю и дополнительные признаки региона и поля. На `test Markov-1` показывает Accuracy 0.557219, Macro F1 0.411371 и Weighted F1 0.539027.

Сравнение этих ориентиров важно не само по себе, а как способ понять, какой вклад дают разные уровни сложности модели. Если бы результат CatBoost был близок к `most_frequent`, это означало бы, что задача фактически сводится к доминированию нескольких частых классов. Если бы CatBoost был близок к `last_crop`, это бы говорило о сильной инерционности последовательностей. Если бы он почти не выигрывал у `Markov-1`, то можно было бы заключить, что одной последней культуры в истории почти достаточно для предсказания.

5.2 Финальная baseline-модель CatBoost

Финальным предиктивным ядром проекта является baseline-версия CatBoost. Выбор этой модели обусловлен табличной природой задачи и сочетанием категориальных и числовых признаков. CatBoost использует компактный набор признаков и возвращает

вероятности по всем целевым классам, что делает модель пригодной как для top-1 предсказания, так и для рекомендательного режима.

На test baseline CatBoost показывает следующие значения:

- Accuracy = 0.699006;
- Macro F1 = 0.568485;
- Weighted F1 = 0.689626.

Полученные значения существенно превосходят простые baseline-подходы и подтверждают, что использование трехлетней истории вместе с региональным и пространственным контекстом дает устойчивый выигрыш в качестве. Именно поэтому модель baseline зафиксирована как финальная и рассматривается как основа рассматриваемого решения.

Практически это означает, что baseline CatBoost извлекает из данных больше информации, чем простые правила и даже одношаговая вероятностная модель переходов. Модель использует не только ближайшую культуру, но и более длинный исторический контекст, а также сведения о положении и масштабе поля. За счет этого она лучше различает ситуации, где несколько культур выглядят правдоподобно, но их вероятности должны быть расставлены по-разному.

На рисунке 4 и в таблице 3 показано, что baseline CatBoost устойчиво опережает остальные базовые варианты. Это и стало главным аргументом в пользу выбора именно этой модели как финального предиктивного ядра.

Модель	Выборка	Accuracy	Macro F1	Weighted F1
most_frequent	validation	0.305306	0.051977	0.142820
last_crop	validation	0.354267	0.172492	0.361115
markov_1	validation	0.557140	0.411203	0.539053
catboost	validation	0.699281	0.568771	0.689966
most_frequent	test	0.305068	0.051946	0.142623
last_crop	test	0.354321	0.172575	0.361135
markov_1	test	0.557219	0.411371	0.539027
catboost	test	0.699006	0.568485	0.689626

Рис. 4: Сравнение baseline-подходов и baseline-модели CatBoost

6 Эксперимент CatBoost + transition graph

После обучения baseline-модели была проверена гипотеза о том, что ранжирование кандидатов можно улучшить за счет графового сигнала переходов между культурами. Для

Таблица 3: Сравнение baseline-подходов и основных CatBoost-экспериментов на test-выборке

Подход	Краткая характеристика	Accuracy	Macro F1	Weighted F1
<code>most_frequent</code>	Всегда выбирается самый частый класс обучающей выборки	0.305068	0.051946	0.142623
<code>last_crop</code>	Следующая культура приравнивается к последней наблюдаемой культуре поля	0.354321	0.172575	0.361135
<code>Markov-1</code>	Одношаговая вероятностная модель переходов вида $P(\text{target} \mid \text{history}_3)$	0.557219	0.411371	0.539027
Baseline CatBoost	История, регион, площадь и координаты поля	0.699006	0.568485	0.689626
CatBoost + extra features	Дополнительные признаки истории: разнообразие культур, индикаторы повторяемости, наличие отдельных групп культур	0.699235	0.569473	0.689991
CatBoost + transition graph	Гибридная оценка $\alpha p_{\text{catboost}} + \beta p_{\text{graph}}$ с лучшей конфигурацией $\alpha = 0.9$, $\beta = 0.1$	0.698714	0.564387	0.688729

этого рассматривалась гибридная оценка:

$$\text{score} = \alpha \cdot p_{\text{catboost}} + \beta \cdot p_{\text{graph}},$$

где p_{catboost} — вероятность, рассчитанная моделью CatBoost, а p_{graph} — сигнал графа переходов. Проверялись несколько сочетаний весов; лучшим вариантом оказался $\alpha = 0.9$ и $\beta = 0.1$.

Смысл этого эксперимента заключался в проверке следующей гипотезы: если в данных присутствуют устойчивые переходы между культурами, то отдельный графовый сигнал может помочь улучшить модельное ранжирование. В таком случае вероятности CatBoost и оценки переходов не конкурировали бы друг с другом, а взаимно дополнялись. На уровне идеи это выглядело вполне правдоподобно, поскольку проект изначально связан с анализом последовательностей культур.

Однако даже в лучшей конфигурации гибридный вариант уступил чистому CatBoost. На test были получены Accuracy 0.698714, Macro F1 0.564387 и Weighted F1 0.688729. Разница невелика, но она показывает, что простое переранжирование на основе графового сигнала не дает достаточных оснований для смены финальной модели.

Этот отрицательный результат имеет важное исследовательское значение. Во-первых, он показывает, что baseline CatBoost уже достаточно хорошо извлекает переходные закономерности из исходного представления данных, и простой внешний графовый сигнал не дает автоматического выигрыша. Во-вторых, он помогает развести в проекте две разные роли: предсказание и интерпретацию. Если графовый компонент не улучшает качество как самостоятельная добавка к ранжированию, его разумнее использовать не как замену модели, а как дополнительный аналитический слой для объяснения результата.

Таким образом, эксперимент CatBoost + transition graph остается важной частью исследовательской логики проекта, но не меняет финальный выбор. Он показывает, что проверка даже неудачной гипотезы полезна, если она помогает лучше понять

границы применимости выбранной модели и уточнить архитектуру решения.

7 Заключение

В ходе производственной практики были систематизированы ключевые результаты проекта, посвященного рекомендации следующей культуры по истории поля. Подтверждена воспроизводимая структура исследовательского пайплайна: от очистки исходных данных и построения оконной выборки до выбора финальной модели и проверки промежуточных экспериментальных веток.

Главным результатом работы стало последовательное описание проекта как объяснимого рекомендательного прототипа поддержки принятия решений. В текст отчета включены только основные этапы до эксперимента `CatBoost + transition graph`, что позволяет сохранить разумный объем и при этом показать логику выбора финальной модели `baseline`.

В ходе работы было показано, что путь от исходных данных до финальной модели включает несколько принципиально важных решений: выбор рабочей формы данных, фильтрацию пространства классов, корректное разбиение по полям, сравнение с простыми ориентирами и проверку промежуточных экспериментальных гипотез. Благодаря этому выбор `baseline CatBoost` выступает не как декларация, а как результат последовательного сравнения моделей и анализа их поведения.

Дальнейшее развитие проекта включает более поздние этапы, связанные с рекомендательной оценкой, анализом уверенности, объяснимым графовым слоем и пространственной демонстрацией. В настоящем отчете эти направления не раскрываются подробно, поскольку основной задачей было зафиксировать базовое исследовательское ядро рассматриваемого решения.